

思考题 2

证明回归树均方误差不断下降

221900180 田永铭 tianym2022@smail.nju.edu.cn

2024 年 10 月 30 日

一、一种感性的理解

上一次我们证明了决策树的信息增益在划分后是恒为正的，回归树其实也是一种划分，它这里拟合的是上一步的误差，通过一步步的划分使得总体误差越来越小，也相当于一种“增益”，可以感性理解到均方误差一定会不断下降。

二、一种严格的证明

这里我给出个人独立写的证明：记 $x_i (i = 1, 2, \dots, n)$ 为数据的自变量，其中 n 为数据的个数。记 $y_i (i = 1, 2, \dots, n)$ 为数据的因变量（已全部归一化为正值）， $\mathcal{L}(\cdot)$ 表示均方误差函数， $\bar{y}$ 表示 y 的均值，即 $\sum_i y_i$ ，训练误差用均方误差表示。我们以下证明每一次划分，回归树的均方误差都在下降，不妨探讨从树 T 划分为树 T' 的过程，假设划分为了两块，每块数据量分别为 $n_1, n_2 (n_1 + n_2 = n)$ （注意是按照序号顺序划分的，即前 n_1 个为第一块），划分后均值分别为 $\bar{y}_{(1)}, \bar{y}_{(2)}$ 。

划分前的误差为：

$$\begin{aligned}\mathcal{L}(T) &= \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \\ &= \frac{\sum_{i=1}^n y_i^2 - n\bar{y}^2}{n}.\end{aligned}$$

划分后的误差（注意是加起来一起除以 n ，这是准确的定义）为：

$$\begin{aligned}\mathcal{L}(T') &= \frac{\sum_{i=1}^{n_1} y_i^2 - n_1 \bar{y}_{(1)}^2 + \sum_{i=n_1+1}^{n_1+n_2} y_i^2 - n_2 \bar{y}_{(2)}^2}{n} \\ &= \frac{\sum_{i=1}^n y_i^2 - n_1 \bar{y}_{(1)}^2 - n_2 \bar{y}_{(2)}^2}{n}.\end{aligned}$$

欲证

$$\mathcal{L}(T') \leq \mathcal{L}(T),$$

即证：

$$n_1 \bar{y}_{(1)}^2 + n_2 \bar{y}_{(2)}^2 \geq n \bar{y}^2,$$

即证：

$$\frac{(\sum_{i=1}^{n_1} y_i)^2}{n_1} + \frac{(\sum_{i=n_1+1}^n y_i)^2}{n_2} \geq \frac{(\sum_{i=1}^n y_i)^2}{n}.$$

由于 y 均归一化为正值，所以通过权方和不等式可得到结论：

$$\frac{(\sum_{i=1}^{n_1} y_i)^2}{n_1} + \frac{(\sum_{i=n_1+1}^n y_i)^2}{n_2} \geq \frac{(\sum_{i=1}^{n_1} y_i + \sum_{i=n_1+1}^n y_i)^2}{n_1 + n_2} = \frac{(\sum_{i=1}^n y_i)^2}{n}.$$

□