

2024-2025学年 第1学期(秋)



数据挖掘

知识点复习

2024 年 12 月

期末考试安排

- **考核方式：**随堂表现（**10%**）+ 平时作业（**30%**）+ 期末考试（**60%**）
- **题型：**选择题（单项/多项），判断题，计算题，简答题
- **考试时间：**2025-01-09 14:00-16:00 (星期四)
- **考试地点：**南雍-西105, 南雍-西209

允许携带无通信功能的计算器

01 绪论

数据、信息、知识

客户信息表

年龄	收入（万）	工作时间（年）	顾客类型
25	10	2	优
29	12	3	优
32	9	6	良
38	7	12	良
36	18	13	中
30	15	4	优
...	...	...	...

数据、信息、知识

客户信息表

年龄	收入 (万)	工作时间 (年)	顾客类型
25	10	数据 2	优
29	12	3	优
32	9	6	良
38	7	12	良
36	18	信息 13	中
30	15	4	优
...	...	...	...

25<年龄<30, 收入>10, 工作时间>2年的消费者是优质顾客


知识

数据挖掘的定义


- 数据挖掘是从**大量的、不完全的、有噪声的、模糊的、随机的数据**中提取**隐含在其中的、人们事先不知道的、但又是潜在有用的信息和知识**的过程。
- Data Mining is the process of automatically extracting **interesting** and **useful hidden** patterns from usually **massive**, incomplete and noisy data. [Wikipedia]



数据挖掘过程



数据挖掘的主要内容



02 认识数据


数据对象

- **数据集**由数据对象组成
- 一个**数据对象**代表一个实体
- 例子
 - 销售数据库：客户，商店物品，销售额
 - 医疗数据库：患者，治疗信息
 - 大学数据库：学生，教授，课程信息
- 称为样品，示例，实例，数据点，对象，元组 (tuple)
- 数据对象所描述的属性
 - 数据库中的行 -> 数据对象
 - 列 -> “属性”

Objects	Attributes			
	Tid	Refund	Marital Status	Taxable Income
	1	Yes	Single	125K
	2	No	Married	100K
	3	No	Single	70K
	4	Yes	Married	120K
	5	No	Divorced	95K
	6	No	Married	60K
	7	Yes	Divorced	220K
	8	No	Single	85K
	9	No	Married	75K
	10	No	Single	90K

属性和度量

- An **attribute** (属性) is a property or characteristic of an object
 - Example: 人的身高, 体重, 眼睛的颜色等
- **Attribute values** (属性值: 定义属性的特定的特征或参数) are numbers or symbols assigned to an attribute
 - Example: 175cm, 70kg, 黑色



单选题

创建时间 = 1 月 2 日

- ☐ A 创建时间表示属性，1 月 2 日表示属性
- ☐ B 创建时间表示属性值，1 月 2 日表示属性值
- ☒ C 创建时间表示属性，1 月 2 日表示属性值
- ☐ D 创建时间表示属性值，1 月 2 日表示属性

属性的类型

- 常见的四类属性：

- 标称 (Nominal)

- Examples: ID numbers, zip codes

- 序数 (Ordinal)


- Examples: rankings (e.g., taste of potato chips on a scale from 1-10), grades, height in {tall, medium, short}

- 区间 (Interval)

- Examples: calendar dates, temperatures in Celsius or Fahrenheit.

- 比率 (Ratio)

- Examples: temperature in Kelvin, length, time, counts



属性的类型小结

表 不同的属性类型

属性类型		描 述	例 子	操 作
分类的 (定性的)	标称	标称属性的值仅仅只是不同的名字，即标称值只提供足够的信息以区分对象 (=, ≠)	邮政编码、雇员ID号、眼球颜色、性别	众数、熵、列联相关、 χ^2 检验
	序数	序数属性的值提供足够的信息确定对象的序 (<, >)	矿石硬度、{好, 较好, 最好}、成绩、街道号码	中值、百分位、秩相关、游程检验、符号检验
数值的 (定量的)	区间	对于区间属性，值之间的差是有意义的，即存在测量单位 (+, -)	日历日期、摄氏或华氏温度	均值、标准差、皮尔逊相关、 t 和 F 检验
	比率	对于比率变量，差和比率都是有意义的 (+, -, *, /)	绝对温度、货币量、计数、年龄、质量、长度、电流	几何平均、调和平均、百分比变差

数据统计汇总


- 动机
 - 为了更好地理解数据：集中趋势，分布
- 数据的统计特性
 - 最大值，最小值，中位数，位数，离群值，方差等。

当前薪金

性别	薪资分组	均值	N	极小值	极大值	合计 N 的 %
女	低收入	17850.00	32	15750	19950	6.8%
	中收入	26046.07	173	20100	38850	36.5%
	高收入	49611.36	11	40800	58125	2.3%
	总计	26031.92	216	15750	58125	45.6%
男	低收入	19650.00	1	19650	19650	.2%
	中收入	29719.94	164	21300	39900	34.6%
	高收入	62346.88	93	40050	135000	19.6%
	总计	41441.78	258	19650	135000	54.4%
总计	低收入	17904.55	33	15750	19950	7.0%
	中收入	27833.95	337	20100	39900	71.1%
	高收入	60999.86	104	40050	135000	21.9%
	总计	34419.57	474	15750	135000	100.0%

中性化趋势度量：均值、中位数和众数

- 平均值一组数据的均衡点。
- 但是，均值对离群值很敏感。
- 因此，中位数和截断均值也很常用。
- 众数指一组数据中出现次数最多的数据值。



$$\text{mean}(x) = \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$


$$\text{median}(x) = \begin{cases} x_{(r+1)} & \text{if } m \text{ is odd, i.e., } m = 2r + 1 \\ \frac{1}{2}(x_{(r)} + x_{(r+1)}) & \text{if } m \text{ is even, i.e., } m = 2r \end{cases}$$

经验公式 $\text{mean} - \text{mode} = 3 \times (\text{mean} - \text{median})$

单选题


中位数、平均数、众数三者的关系

- ☐ A 中位数=平均数=众数
- ☐ B 中位数>平均数>众数
- ☒ C 平均数>中位数>众数
- ☐ D 中位数<平均数<众数



离散度量

- 方差和标准差
- 分位数
 - 分位数: Q1 (第25百分位) , Q3 (第75百分位)
 - 分位数极差: $IQR = Q3 - Q1$
- 五点概况:
 - min, Q1, median, Q3, max
- 盒状图 (boxplot) : min, Q1, median, Q3, max; 单独添加胡须表示离群点
- 离群点: 通常情况下, 一个值高于/低于 $1.5 \times IQR$



$$IQR = Q3 - Q1$$

$$\max = Q3 + 1.5 \times IQR$$

$$\min = Q1 - 1.5 \times IQR$$

度量数据的相似性和相异性

- **相似度Similarity**
 - 度量两个数据对象有多相似
 - 值越大就表示数据对象越相似
 - 通常取值范围为 $[0,1]$
- **相异度Dissimilarity** (e.g., distance)
 - 度量两个数据对象的差别程度
 - 值越小就表示数据越相似
 - 最小相异度通常为0
- **邻近性Proximity**
 - 指相似度或者相异度

数值属性的邻近性度量

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5

数值属性的邻近性度量

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5

- 闵可夫斯基距离

$$d(i, j) = \sqrt[h]{|x_{i1} - x_{j1}|^h + |x_{i2} - x_{j2}|^h + \cdots + |x_{ip} - x_{jp}|^h}$$

- 性质

- $d(i, j) > 0$ if $i \neq j$, and $d(i, i) = 0$ (正定性)
- $d(i, j) = d(j, i)$ (对称性)
- $d(i, j) \leq d(i, k) + d(k, j)$ (三角不等性)

数值属性的邻近性度量

$$d(i, j) = \sqrt[h]{|x_{i1} - x_{j1}|^h + |x_{i2} - x_{j2}|^h + \cdots + |x_{ip} - x_{jp}|^h}$$

- $h = 1$: 曼哈顿距离

$$d(i, j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{ip} - x_{jp}|$$

- $h = 2$: 欧氏距离

$$d(i, j) = \sqrt{(|x_{i1} - x_{j1}|^2 + |x_{i2} - x_{j2}|^2 + \cdots + |x_{ip} - x_{jp}|^2)}$$

- $h \rightarrow \infty$. “上确界距离”.

$$d(i, j) = \lim_{h \rightarrow \infty} \left(\sum_{f=1}^p |x_{if} - x_{jf}|^h \right)^{\frac{1}{h}} = \max_f |x_{if} - x_{jf}|$$

余弦相似性

- 余弦相似性
 - 一个文档可以用词频向量来表示（注意：词的对齐）

<i>Document</i>	<i>team coach</i>		<i>hockey</i>	<i>baseball</i>	<i>soccer</i>	<i>penalty</i>	<i>score</i>	<i>win</i>	<i>loss</i>	<i>season</i>
Document1	5	0	3	0	2	0	0	2	0	0
Document2	3	0	2	0	1	1	0	1	0	1
Document3	0	7	0	2	1	0	0	3	0	0
Document4	0	1	0	0	1	2	2	0	3	0

Baseball wins a score in the season (0,0,1,1,0,1,1,0,1)

In the season, soccer loss a score (0,0,0,0,1,0,1,0,1,1)

- 余弦度量
 - $\cos(d1, d2) = (d1 \bullet d2) / ||d1|| \ ||d2||$,

余弦相似性

$$\cos(d_1, d_2) = (d_1 \bullet d_2) / \|d_1\| \|d_2\| ,$$

- 例如:

$$d1 = (5, 0, 3, 0, 2, 0, 0, 2, 0, 0)$$

$$d2 = (3, 0, 2, 0, 1, 1, 0, 1, 0, 1)$$

$$d1 \bullet d2 = 5*3+0*0+3*2+0*0+2*1+0*1+0*1+2*1+0*0+0*1 = 25$$

$$\|d1\| = (5*5+0*0+3*3+0*0+2*2+0*0+0*0+2*2+0*0+0*0)^{0.5} = (42)^{0.5} = 6.481$$

$$\|d2\| = (3*3+0*0+2*2+0*0+1*1+1*1+0*0+1*1+0*0+1*1)^{0.5} = (17)^{0.5} = 4.12$$

$$\cos(d1, d2) = 0.94$$

03 数据预处理

数据预处理 —— 主要任务

- **数据清理**

- 填写缺失值，平滑噪声数据，识别或删除离群，并解决不一致问题

- **数据集成**

- 整合多个数据库，多维数据集或文件

- **数据规约**

- 降维
- 降数据
- 数据压缩

- **数据转换**

- 规范化
- 离散化

数据清洗

- 属性值缺失：
 - 例如，职业= “ ” (丢失)
- 噪音，错误或离群
 - 例如，工资= “-10” (错误)
- 不一致的代码或不符的名称
 - 年龄= “42” 生日= “03/07/1997”
 - 曾经评级 “1,2,3” , 现在评级 “A, B, C”

数据清洗 —— 如何处理丢失数据？

- **忽略元组**：当类标号缺少时通常这么做（监督式机器学习中训练集缺乏类标签）。当每个属性缺少值比例比较大时，效果比较差
- **手动填写遗漏值**：工作量大
- **自动填写**
 - 使用属性的平均值填充空缺值【代码见下链接，请同学们课后实践】
 - 最有可能的值：基于诸如贝叶斯公式或决策树推理

6.4.2. Univariate feature imputation

The `SimpleImputer` class provides basic strategies for imputing missing values. Missing values can be imputed with a provided constant value, or using the statistics (mean, median or most frequent) of each column in which the missing values are located. This class also allows for different missing values encodings.

The following snippet demonstrates how to replace missing values, encoded as `np.nan`, using the mean value of the columns (axis 0) that contain the missing values:


```
import numpy as np
from sklearn.impute import SimpleImputer
imp = SimpleImputer(missing_values=np.nan, strategy='mean')
imp.fit([[1, 2], [np.nan, 3], [7, 6]])

X = [[np.nan, 2], [6, np.nan], [7, 6]]
print(imp.transform(X))
```

<https://scikit-learn.org/stable/modules/impute.html#impute>

数据清洗 —— 如何处理噪声数据？

- 箱线图检测离群数据：删除离群点




数据清洗 —— 如何处理不一致数据？

- **不一致的代码或不符的名称**
 - 年龄= “42” 生日= “09/24/1998”
 - 曾经评级 “1,2,3” , 现在评级 “A, B, C”
- **方法**
 - 计算推理、替换
 - 全局替换

数据集成

- 数据集成

—— 将来自多个数据源的数据组合成一个连贯的数据源



相关分析

- 相关系数（也称为皮尔逊相关系数）

$$r_{p,q} = \frac{\sum(p - \bar{p})(q - \bar{q})}{(n - 1)\sigma_p\sigma_q} = \frac{\sum(pq) - n\bar{p}\bar{q}}{(n - 1)\sigma_p\sigma_q}$$

- 其中n是元组的数目，而p和q是各属性的具体值， σ_p 和 σ_q 是各自的标准偏差

姓名	病人数目
长沙	30000
武汉	50000
广州	80000
...	...

姓名	小偷数目
长沙	2000
武汉	3500
广州	6000
...	...

相关分析

$$r_{p,q} = \frac{\sum(p - \bar{p})(q - \bar{q})}{(n - 1)\sigma_p\sigma_q} = \frac{\sum(pq) - n\bar{p}\bar{q}}{(n - 1)\sigma_p\sigma_q}$$

- 当 $r > 0$ 时，表示两变量正相关， $r < 0$ 时，两变量为负相关。
- 当 $|r| = 1$ 时，表示两变量为完全线性相关，即为函数关系。
- 当 $r = 0$ 时，表示两变量间无线性相关关系。
- 当 $0 < |r| < 1$ 时，表示两变量存在一定程度的线性相关。且 $|r|$ 越接近1，两变量间线性关系越密切； $|r|$ 越接近于0，表示两变量的线性相关越弱。
- 一般可按三级划分： $|r| < 0.4$ 为低度线性相关； $0.4 \leq |r| < 0.7$ 为显著性相关； $0.7 \leq |r| < 1$ 为高度线性相关。

协方差

- 协方差

$$Cov(p, q) = E((p - \bar{p})(q - \bar{q})) = \frac{\sum_{i=1}^n (p_i - \bar{p})(q_i - \bar{q})}{n}$$

$$r_{p,q} = \frac{Cov(p, q)}{\sigma_p \sigma_q}$$

- 其中n是元组的数目， p和q是各自属性的具体值， σ_p 和 σ_q 是各自的标准差。
 - 正相关： $COV(p, q) > 0$
 - 负相关： $COV(p, q) < 0$
 - 不相关： $COVP(p, q) = 0$
- 可具有某些对随机变量的协方差为0， 但不是独立的。一些额外的假设（例如，数据是否服从多元正态分布）做了协方差为0意味着独立。

协方差 —— 举例

$$Cov(A, B) = E((A - \bar{A})(B - \bar{B})) = \frac{\sum_{i=1}^n (a_i - \bar{A})(b_i - \bar{B})}{n}$$

- 它可以简化计算

$$Cov(A, B) = E(A \cdot B) - \bar{A}\bar{B}$$

- 假设两只股票A和B具有在1个星期的以下值：

(2, 5) , (3, 8) , (5, 10) , (4, 11) , (6, 14)

- 问题：如果股票都受到同行业的趋势，他们的价格一起上升或下降？
- $E(A) = (2+3+5+4+6) / 5 = 20/5 = 4$
- $E(B) = (5+8+10+11+14) / 5 = 48/5 = 9.6$
- $COV(A, B) = (2 \times 5 + 3 \times 8 + 5 \times 10 + 4 \times 11 + 6 \times 14) / 5 - 4 \times 9.6 = 4$
- 结论：A和B在一起上升，因为 $Cov(A, B) > 0$ 。

数据规约策略

- 为什么数据规约 (**data reduction**) ?
 - 由于数据仓库可以存储TB的数据，因此在一个完整的数据集上运行时，复杂的数据分析可能需要一个很长的时间
- 降维
- 降数据
- 数据压缩

降维典型方法 —— PCA主成分分析法


- PCA主成分分析法核心idea
 - 数据中很多属性之间可能存在这样或那样的相关性
 - 能不能找到一个方法，将多个相关性的属性组合仅仅形成一个属性？

学生代码	数学	物理	化学	语文	历史	英语
1	65	61	72	84	81	79
2	77	77	76	64	70	55
3	67	63	49	65	67	57
4	80	69	75	74	74	63
5	74	70	80	84	81	74
6	78	84	75	62	71	64
7	66	71	67	52	65	57
8	77	71	57	72	86	71
9	83	100	79	41	67	50
...	...	...	...	...	...	...

数据规约策略


- 为什么数据规约 (data reduction) ?
 - 由于数据仓库可以存储TB的数据，因此在一个完整的数据集上运行时，复杂的数据分析可能需要一个很长的时间
- 降维
- 降数据
- 数据压缩

降数据典型方法 —— 抽样法




抽样类型

- 简单随机抽样(Simple Random Sampling)
 - 相等的概率选择
 - 不放回抽样(Sampling without replacement)
 - 一旦对象被选中，则将其删除
 - 有放回抽样(Sampling with replacement)
 - 选择对象不会被删除
- 分组抽样
 - 每组抽相近个数
 - 用于偏斜数据




样本大小对数据质量的影响


- 从8000个点分别抽2000和500个点
 - 2000个点的样本保留了数据集的大部分结构
 - 500个点的样本丢失了许多结构



8000 points



2000 Points




500 Points

数据规约策略

- 为什么数据规约 (data reductio) ?
 - 由于数据仓库可以存储TB的数据，因此在一个完整的数据集上运行时，复杂的数据分析可能需要一个很长的时间
- 降维
- 降数据
- 数据压缩

数据压缩



数据转换

- **函数映射：** 给定的属性值更换了一个新的表示方法，每个旧值与新的值可以被识别
- **方法**
 - **规范化：** 按比例缩放到一个具体区间
 - 最小 - 最大规范化
 - z-得分正常化
 - 小数定标规范化
 - **离散化**

数据转换 —— 规范化方法

- 最小-最大规范化

$$v' = \frac{v - \min A}{\max A - \min A} (\text{new_max}A - \text{new_min}A) + \text{new_min}A$$

- v 即需要规范的数据

- z-分数规范化

$$v' = \frac{v - \text{均值}A}{\text{标准差}_A}$$

数据转换——离散化方法

- 非监督离散化法

- 等宽法


- 根据属性的值域来划分，使每个区间的宽度相等

- 等频法


- 根据取值出现的频数来划分，将属性的值域划分成个小区间，并且要求落在每个区间的样本数目相等

- 聚类


- 利用聚类将数据划分到不同的离散类别




Data



Equal interval width等宽



Equal frequency等频



K-means K-均值

04 朴素贝叶斯分类

分类概念


- 什么是分类?
 - 找出描述和区分数据类或概念的模型，以便能够使用模型预测类标号未知的对象的类标号
- 概念区分
 - 分类与回归
 - 分类是预测分类（离散、无序）标号
 - 回归建立连续值函数模型
 - 分类与聚类
 - 分类是有监督学习，提供了训练元组的类标号
 - 聚类是无监督学习，不依赖有类标号的训练实例

极大后验假设

- 极大后验假设定义
 - 学习器在候选假设集合H中寻找给定数据D时可能性最大的假设h，h被称为极大后验假设（Maximum a posteriori: MAP）
 - 确定MAP的方法是用贝叶斯公式计算每个候选假设的后验概率，计算式如下

$$\begin{aligned}h_{MAP} &= \max_{h \in H} P(h|D) \\&= \max_{h \in H} P(D|h)P(h)/P(D) \\&= \max_{h \in H} P(D|h)P(h)\end{aligned}$$

$$\begin{aligned}P(h_1|D) &= \frac{P(D|h_1)P(h_1)}{P(D)} \\P(h_2|D) &= \frac{P(D|h_2)P(h_2)}{P(D)} \\P(h_n|D) &= \frac{P(D|h_n)P(h_n)}{P(D)}\end{aligned}$$



对象是一个多维向量

- 已知：对象D是由多个属性组成的向量

- $D = \langle a_1, a_2, \dots, a_n \rangle$

- 目标

一个收入中等、信用度
良好的青年爱好游戏顾客。
是否会购买电脑呢？

$$\begin{aligned} h_{MAP} &= \max_{h \in H} P(h|D) \\ &= \max_{h \in H} P(D|h)P(h)/P(D) \\ &= \max_{h \in H} P(D|h)P(h) \end{aligned}$$



$$\begin{aligned} h_{MAP} &= \max_{h \in H} P(h | \langle a_1, a_2, \dots, a_n \rangle) \\ &= \max_{h \in H} P(\langle a_1, a_2, \dots, a_n \rangle | h)P(h) \end{aligned}$$

- 问题

- 计算 $P(\langle a_1, a_2, \dots, a_n \rangle | h)$ 时，当维度过高时，可用数据变得很稀疏，难以获得结果。

独立性假设

Diagram illustrating the relationship between prior, likelihood, and posterior probabilities:

- $P(h|D)$ is labeled as **h的后验概率** (Posterior probability of h).
- $P(D|h)$ is labeled as **h的似然概率** (Likelihood of h).
- $P(h)$ is labeled as **h的先验概率** (Prior probability of h).
- $P(D)$ is labeled as **D的先验概率** (Prior probability of D).

The formula for the posterior probability is:

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

Legend:

- D : 待测试数据
- h : 假设类别

Arrows indicate the flow from the prior and likelihood to the posterior, and from the posterior to the MAP hypothesis calculation.

$$h_{MAP} = \max_{h \in H} P(h | \langle a_1, a_2, \dots, a_n \rangle) \\ = \max_{h \in H} P(\langle a_1, a_2, \dots, a_n \rangle | h) P(h)$$

● 解决方法

● 假设D的属性 a_i 之间相互独立

$$P(\langle a_1, a_2, \dots, a_n \rangle | h) = \prod_i P(a_i | h)$$

$$\begin{aligned} h_{MAP} &= \max_{h \in H} P(h | \langle a_1, a_2, \dots, a_n \rangle) \\ &= \max_{h \in H} P(\langle a_1, a_2, \dots, a_n \rangle | h) P(h) \\ &= \max_{h \in H} \prod_i P(a_i | h) P(h) \end{aligned}$$

● 优点

- 获得估计的 $P(a_i | h)$ 比 $P(\langle a_1, a_2, \dots, a_n \rangle | h)$ 容易很多
- 如果D的属性之间不满足相互独立，朴素贝叶斯分类的结果是贝叶斯分类的近似

朴素贝叶斯分类案例

训练集

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

测试集

一个收入中等、信用度良好的青年爱好游戏顾客。
是否会购买电脑呢？

h的似然概率

h的先验概率

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

D：待测试数据
h：假设类别

h的后验概率

D的先验概率

$$\begin{aligned} h_{MAP} &= \max_{h \in H} P(h | \langle a_1, a_2, \dots, a_n \rangle) \\ &= \max_{h \in H} P(\langle a_1, a_2, \dots, a_n \rangle | h) P(h) \end{aligned}$$

$$\begin{aligned} h_{MAP} &= \max_{h \in H} P(h | \langle a_1, a_2, \dots, a_n \rangle) \\ &= \max_{h \in H} P(\langle a_1, a_2, \dots, a_n \rangle | h) P(h) \\ &= \max_{h \in H} \prod_i P(a_i | h) P(h) \end{aligned}$$

垃圾邮件分类

- 问题

- 给定一封邮件，判定它是否属于垃圾邮件。按照先例，用 D 来表示邮件（注意 D 由 n 个单词的属性合取 $\langle a_1, a_2, \dots, a_n \rangle$ 组成）。用 $h+$ 来表示垃圾邮件， $h-$ 表示正常邮件，即目标空间 $H = \langle h+, h- \rangle$ 。

- 形式化描述：

- $P(h+|D) = P(h+) * P(D|h+)/P(D)$
- $P(h-|D) = P(h-) * P(D|h-)/P(D)$



垃圾邮件分类

$$P(h+|D) = P(h+) * P(D|h+)/P(D)$$

- 已知

- 训练集中垃圾邮件的比例为 $P(h+) = 0.2$
- 训练集中正常邮件的比例为 $P(h-) = 0.8$
- 单词出现频率表

分词	在垃圾邮件中出现的比例	在正常邮件中出现的比例
免费	0.3	0.01
奖励	0.2	0.01
网站	0.2	0.2

- 求解

- 判断一封邮件 $D = \langle \text{“免费”}, \text{“奖励”}, \text{“网站”} \rangle$ 是否是垃圾邮件


贝叶斯分类器总结

- 本质上是同时考虑了先验概率和似然概率的重要性
- 特点
 - 属性可以离散、也可以连续
 - 数学基础坚实、分类效率稳定
 - 对缺失和噪声数据不太敏感
 - 属性如果不相关，分类效果很好

05 决策树分类

引言

- 树状结构，可以很好的对数据进行分类；
- 决策树的根节点到叶节点的每一条路径构建一条规则；
- 具有互斥且完备的特点，即每一个样本均被且只能被一条路径所覆盖；
- 只要提供的数据量足够庞大真实，通过数据挖掘模式，就可以构造决策树。



构造决策树

- 有许多决策树算法：
 - Hunt算法 (1966)
 - 信息增益——Information gain (ID3)
 - 增益比率——Gain ratio (ID3, C4.5)
 - 基尼指数——Gini index (CART, SLIQ)


Hunt 算法

设 D_t 是与节点 t 相关联的训练记录集，

算法步骤：

- 如果 D_t 中所有记录都属于同一个类 y_t ，则 t 是叶节点，用 y_t 标记
- 如果 D_t 中包含属于多个类的记录，则**选择一个属性测试条件**，将记录划分成较小的子集
- 对于测试条件的每个输出，创建一个子结点，并根据**测试结果将 D_t 中的记录分布到子结点中**。然后，对于每个子结点，递归地调用该算法

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes



构造决策树

- **Hunt算法采用贪心策略构建决策树**
 - 在选择划分数据的属性时，采取一系列局部最优决策来构造决策树。
- **决策树归纳的设计问题**
 - 如何分裂训练记录？
 - 怎样为不同类型的属性指定测试条件？
 - 怎样评估每种测试条件？
 - 如何停止分裂过程？

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

怎样为不同类型的属性指定测试条件？

- 依赖于属性的类型

- 标称

- 序数


- 连续

- 依赖于划分的路数

- 多路划分

- 二元划分

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes




决策树

- 决策树归纳的设计问题
 - 如何分裂训练记录
 - 怎样为不同类型的属性指定测试条件?
 - 怎样评估每种测试条件?
 - 如何停止分裂过程

怎样选择最佳划分?

- 在划分前: 10 个记录 class 0, 10 个记录 class 1



怎样选择最佳划分？

- 选择最佳划分的度量通常是根据划分后子节点纯性的程度。

纯性的程度越高，类分布就越倾斜，划分结果越好。

- 结点纯性的度量：

C0:5
C1:5

纯性小
(不纯性大)

C0:9
C1:1

纯性大

Entropy 基于熵 —— 信息增益算法ID3

$$Entropy(S) = -\sum_{i=1}^C p_i \log(p_i)$$

p_i : the proportion of instances in the dataset that take the i^{th} target value

购买的比例为: 9/14

不购买的比例为: 5/14

顾客数据的熵值:

$$Entropy(S) = -\frac{9}{14} \log_2 \frac{9}{14} - \frac{5}{14} \log_2 \frac{5}{14} = 0.940$$

$$Gain(S, A) = Entropy(S) - \sum_{v \in A} \frac{|S_v|}{|S|} Entropy(S_v)$$


id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

S_v : the subset of S where attribute A takes the value v .

Entropy 基于熵 —— 信息增益算法ID3

1、假设以年龄为树的根节点

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否



id	收入	爱好	信用	购买
4	中	否	中	是
5	低	是	中	是
6	低	是	优	否
10	中	是	中	是
14	中	否	优	否

id	收入	爱好	信用	购买
1	高	否	中	否
2	高	否	优	否
8	中	否	中	否
9	低	是	中	是
11	中	是	优	是

id	收入	爱好	信用	购买
3	高	否	中	是
7	低	是	优	是
12	中	否	优	是
13	高	是	中	是

Entropy 基于熵 —— 信息增益算法ID3

$$Gain(S, A) = Entropy(S) - \sum_{v \in A} \frac{|S_v|}{|S|} Entropy(S_v)$$

原始数据分类所需的期望信息：

$$Info(D) = I(9,5) = -\frac{9}{14} \log_2\left(\frac{9}{14}\right) - \frac{5}{14} \log_2\left(\frac{5}{14}\right) = 0.940$$

按照年龄分类所需的期望信息：

$$Info_{age}(D) = \frac{5}{14} I(2,3) + \frac{4}{14} I(0,4) + \frac{5}{14} I(3,2) = 0.694$$

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

id	收入	爱好	信用	购买
4	中	否	中	是
5	低	是	中	是
6	低	是	优	否
10	中	是	中	是
14	中	否	优	否

id	收入	爱好	信用	购买
1	高	否	中	否
2	高	否	优	否
8	中	否	中	否
9	低	是	中	是
11	中	是	优	是

id	收入	爱好	信用	购买
3	高	否	中	是
7	低	是	优	是
12	中	否	优	是
13	高	是	中	是

Entropy 基于熵 —— 信息增益算法ID3

原始数据分类所需的期望信息：

$$Info(D) = I(9,5) = -\frac{9}{14} \log_2\left(\frac{9}{14}\right) - \frac{5}{14} \log_2\left(\frac{5}{14}\right) = 0.940$$

按照年龄分类所需的期望信息：

$$Info_{age}(D) = \frac{5}{14} I(2,3) + \frac{4}{14} I(4,0) + \frac{5}{14} I(3,2) = 0.694$$

信息增益：

$$Gain(S, A) = Entropy(S) - \sum_{v \in A} \frac{|S_v|}{|S|} Entropy(S_v)$$

$$Gain(age) = Info(D) - Info_{age}(D) = 0.246$$

Entropy 基于熵 —— 信息增益算法ID3

相似的

$$\text{Gain}(\text{age}) = 0.246$$

$$\text{Gain}(\text{income}) = 0.029$$

$$\text{Gain}(\text{fancy}) = 0.151$$

$$\text{Gain}(\text{credit_rating}) = 0.048$$

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

Entropy 基于熵 —— 信息增益算法ID3


相似的

$$Gain(age) = 0.246$$

$$Gain(income) = 0.029$$

$$Gain(fancy) = 0.151$$

$$Gain(credit_rating) = 0.048$$



id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

考虑增益率 (Gain Ratio) C4.5算法


解决该问题的策略有两种：

- 限制测试条件只能是二元划分
- 使用增益率，K越大，SplitINFO越大，增益率被平衡。

id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

$$GainRATIO_{split} = \frac{GAIN_{Split}}{SplitINFO}$$

$$SplitINFO = -\sum_{i=1}^k \frac{n_i}{n} \log \frac{n_i}{n}$$



考虑增益率 (Gain Ratio) C4.5算法

$$Gain(age) = 0.246$$

$$Gain(income) = 0.029$$

$$Gain(fancy) = 0.151$$

$$Gain(credit_rating) = 0.048$$

$$GainRatio_{split} = \frac{GAIN_{Split}}{SplitINFO}$$

$$SplitINFO = -\sum_{i=1}^k \frac{n_i}{n} \log \frac{n_i}{n}$$


id	年龄	收入	爱好	信用	购买
1	青	高	否	中	否
2	青	高	否	优	否
3	中	高	否	中	是
4	老	中	否	中	是
5	老	低	是	中	是
6	老	低	是	优	否
7	中	低	是	优	是
8	青	中	否	中	否
9	青	低	是	中	是
10	老	中	是	中	是
11	青	中	是	优	是
12	中	中	否	优	是
13	中	高	是	中	是
14	老	中	否	优	否

$$SplitInfo_{income}(D) = -\frac{4}{14} \times \log_2\left(\frac{4}{14}\right) - \frac{6}{14} \times \log_2\left(\frac{6}{14}\right) - \frac{4}{14} \times \log_2\left(\frac{4}{14}\right) = 1.557$$


$$gain_ratio(income) = 0.029/1.557 = 0.019$$

数据是连续的怎么办

- **二元划分:** $(A < v)$ or $(A \geq v)$
 - 考虑所有的划分点, 选择一个**最优划分点** v
- **多路划分:** $v_i \leq A < v_{i+1}$ ($i=1, \dots, k$)



Binary split



Multi-way split

总结

- 特点:

- 决策树是一种构建**分类（回归）**模型的非参数方法
- 不需要昂贵的的计算代价
- 决策树相对容易解释
- 决策树是学习离散值函数的典型代表
- 决策数对于噪声的干扰具有相当好的鲁棒性
- 冗余属性不会对决策树的准确率造成不利影响
- 数据碎片问题：随着树的生长，可能导致叶结点记录数太少，**对于叶结点代表的类，不能做出具有统计意义的判决**
- **子树可能在决策树中重复多次**，使决策树过于复杂
- 决策树无法学习特征之间的线性关系，难以完成**特征构造**

06 基于规则的分类

基于规则的分类

- 使用一组 “if...then...” 规则进行分类
- 规则: (Condition) $\rightarrow$ y
 - 其中
 - Condition 是属性测试的合取
 - y 是类标号
 - 左部: 规则的前件 (或前提) (Rule antecedent)
 - 右部: 规则的后件 (或结论) (Rule consequent)
 - 分类规则的例子:
 - (Blood Type=Warm) $\wedge$ (Lay Eggs=Yes) $\rightarrow$ Birds
 - (Taxable Income < 50K) $\wedge$ (Refund=Yes) $\rightarrow$ Cheat =No



规则的质量

- 用覆盖率和准确率度量
- 规则的**覆盖率** (Coverage) :
 - 满足规则前件的记录所占的比例
- 规则的**准确率** (Accuracy) :
 - 在满足规则前件的记录中, 满足规则后件的记录所占的比例
- 规则: (Status=Single) → No
- Coverage = 40%, Accuracy = 50%

Tid	Refund	Marital Status	Taxable Income	Class
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

规则分类的特征

- 互斥规则集

- 每个记录最多被一个规则覆盖
- 如果规则都是相互独立的，分类器包含互斥规则

- 如果规则集不是互斥的

- 一个记录可能被多个规则触发
- 如何处理?

- 有序规则集

- 基于规则的序 vs 基于类的序

- 无序规则集

- 在无序规则方案中，允许一条记录触发多条规则，规则被触发时视为**对其相应类的一次投票**，然后计算不同类的票数（可以使用加权方式）来决定记录的类所属。

r_1 : (胎生 = 否) $\wedge$ (飞行动物 = 是) $\rightarrow$ 鸟类
 r_2 : (胎生 = 否) $\wedge$ (水生动物 = 是) $\rightarrow$ 鱼类
 r_3 : (胎生 = 是) $\wedge$ (体温 = 恒温) $\rightarrow$ 哺乳类
 r_4 : (胎生 = 否) $\wedge$ (飞行动物 = 否) $\rightarrow$ 爬行类
 r_5 : (水生动物 = 半) $\rightarrow$ 两栖类

- 海龟触发规则 r_4 和 r_5 ——冲突

有序规则集

- 根据规则优先权将规则排序定秩 (rank)
 - 有序规则集又称决策表 (decision list)
- 对记录进行分类时
 - 由被触发的，具有最高秩的规则确定记录的类标号
 - 如果没有规则被触发，则指派到缺省类

r_1 : (胎生 = 否) $\wedge$ (飞行动物 = 是) $\rightarrow$ 鸟类

r_2 : (胎生 = 否) $\wedge$ (水生动物 = 是) $\rightarrow$ 鱼类

r_3 : (胎生 = 是) $\wedge$ (体温 = 恒温) $\rightarrow$ 哺乳类

r_4 : (胎生 = 否) $\wedge$ (飞行动物 = 否) $\rightarrow$ 爬行类

r_5 : (水生动物 = 半) $\rightarrow$ 两栖类



名称	体温	胎生	飞行动物	水生动物	类
海龟	冷血	否	否	半水生	?

规则定序方案

- 基于规则的序

- 根据规则的质量排序：覆盖率(coverage)和准确率(accuracy)

- 基于类的序

- 属于同一类的规则放在一起
- 基于类信息（如类的分布、重要性）对每类规则排序

基于规则的排序

(表皮覆盖=羽毛, 飞行动物=是) ⇒ 鸟类
(体温=恒温, 胎生=是) ⇒ 哺乳类
(体温=恒温, 胎生=否) ⇒ 鸟类
(水生动物=半) ⇒ 两栖类
(表皮覆盖=鳞片, 水生动物=否) ⇒ 爬行类
(表皮覆盖=鳞片, 水生动物=是) ⇒ 鱼类
(表皮覆盖=无) ⇒ 两栖类

基于类的排序


(表皮覆盖=羽毛, 飞行动物=是) ⇒ 鸟类
(体温=恒温, 胎生=否) ⇒ 鸟类
(体温=恒温, 胎生=是) ⇒ 哺乳类
(水生动物=半) ⇒ 两栖类
(表皮覆盖=无) ⇒ 两栖类
(表皮覆盖=鳞片, 水生动物=否) ⇒ 爬行类
(表皮覆盖=鳞片, 水生动物=是) ⇒ 鱼类

直接方法：顺序覆盖

- 基本思想
 - 依次对每个类建立一个或多个规则
 - 对第*i*类建立规则
 - 第*i*类记录为正例，其余为负例
 - 建立一个第*i*类的规则 r ，尽可能地覆盖正例，而不覆盖负例（即构建一个正例的规则）
 - 删除 r 覆盖的所有记录，在剩余数据集上学习下一个规则，直到所有第*i*类记录都被删除


Action

Ruleset



删除实例

- 为什么要删除实例?
 - 否则, 下一个规则将与前面的规则相同
(规则可能重复)
- 为什么删除正实例?
 - 防止高估后面规则的准确率
 - 确保下一个规则不同
- 为什么删除负实例?
 - 防止过拟合错误训练集
 - 防止低估后面规则的准确率
 - 比较图中的规则 R2 和 R3



规则增长

- 两种策略

- 一般到特殊 (通常采用的策略)

- 从初始规则 $r: \{\} \rightarrow y$ 开始
 - 反复加入合取项, 得到更特殊的规则, 直到不能再加入

$(\text{胎生} = \text{否}) \rightarrow \text{鸟类}$



$(\text{胎生} = \text{否}) \wedge (\text{飞行动物} = \text{是}) \rightarrow \text{鸟类}$

- 特殊到一般 (适用于小样本情况)

- 随机地选择一个正例作为初始规则
 - 反复删除合取项, 得到更一般的规则, 直到不能再删除

$(\text{胎生} = \text{否}) \wedge (\text{飞行动物} = \text{是}) \wedge (\text{体温} = \text{恒温}) \rightarrow \text{鸟类}$



$(\text{胎生} = \text{否}) \wedge (\text{飞行动物} = \text{是}) \rightarrow \text{鸟类}$

- 问题

- 加入/删除合取项有多种选择, 如何选择?
 - 何时停止加入/删除合取项?

→ 需要评估标准

规则评估

- 常用的度量
 - 准确率
 - 似然比
 - Laplace
 - FOIL信息增益

例如 考虑一个训练集，它包含60个正例和100个反例，现有两个候选规则：

r1:覆盖50个正例和5个反例

r2:覆盖2个正例和0个反例

规则评估

- 准确率

- $\text{Accuracy} = \frac{n_c}{n}$

- n : 被规则覆盖的实例数

- n_c : 被规则正确分类的实例数

$\text{Acc}(r_1)$: 90.9%

$\text{Acc}(r_2)$: 100%

- 问题：准确率高的规则可能覆盖率太低

例如 考虑一个训练集，它包含60个正例和100个反例，现有两个候选规则：

r1:覆盖50个正例和5个反例

r2:覆盖2个正例和0个反例

规则评估

- 准确率

- $\text{Accuracy} = \frac{n_c}{n}$

- n : 被规则覆盖的实例数

- n_c : 被规则正确分类的实例数

$\text{Acc}(r_1)$: 90.9%

$\text{Acc}(r_2)$: 100%

- 问题：准确率高的规则可能覆盖率太低

例如 考虑一个训练集，它包含60个正例和100个反例，现有两个候选规则：

r_1 :覆盖50个正例和5个反例

r_2 :覆盖2个正例和0个反例

规则评估

- 似然比（越高越好）
 - k 是类别数
 - f_i 是被规则覆盖的类 i 的样本的观测频度
 - e_i 是规则作随机猜测的期望频度

$$R = 2 \sum_{i=1}^k f_i \log(f_i/e_i)$$

简单理解就是当前规则分类效果比随机效果越高，说明规则越好

$$LRS(r_1) = 2 \times \left[50 \times \log_2 \frac{50}{55 \times 60 / 160} + 5 \times \log_2 \frac{5}{55 \times 100 / 160} \right] = 99.99$$

$$LRS(r_2) = 2 \times \left[2 \times \log_2 \frac{2}{2 \times 60 / 160} + 0 \times \log_2 \frac{0}{2 \times 100 / 160} \right] = 5.66$$

例如 考虑一个训练集，它包含60个正例和100个反例，现有两个候选规则：

r1:覆盖50个正例和5个反例

r2:覆盖2个正例和0个反例

停止条件与规则剪枝

- **停止条件**

- 计算增益
- 如果增益不显著, 则丢弃新规则

- **规则剪枝**

- 类似于决策树后剪枝
- 降低错误剪枝：
 - 删除规则中的合取项
 - 比较剪枝前后的错误率
 - 如果降低了错误率, 则剪掉该合取项

规则分类的特点

优点

- 表达能力与决策树一样高
- 容易解释
- 容易产生
- 能够快速对新实例分类
- 性能可与决策树相媲美

缺点

- 规则库难以维护
- 规则匹配计算量大
- 模型缺乏泛化能力

急切学习 vs 惰性学习

- **急切学习 (Eager Learner)**

- 两步过程: (1) 归纳 (2) 演绎

- **惰性学习 (Lazy Learner)**

- 把训练数据建模过程推迟到需要对样本分类时

- 例子

- Rote-learner (死记硬背)

- 记住所有的训练数据，仅当记录的属性值与一个训练记录完全匹配才对它分类

- **最近邻 (Nearest neighbor)**

- 使用“最近”的 k 个点 (最近邻) 进行分类

k-最近邻分类算法

- k-最近邻分类算法

- 1: 令k是最近邻数目, D是训练样例的集合
- 2: for 每个测试样例 $z = (x', y')$ do
- 3: 计算z和每个样例 $(x, y) \in D$ 之间的距离 $d(x', x)$
- 4: 选择离z最近的k个训练样例的集合 D_z D
- 5: $y' = \operatorname{argmax}_v \sum_{(x_i, y_i) \in D_z} I(v = y_i)$
- 6: end for

- 距离加权表决

$$y' = \operatorname{argmax}_v \sum_{(x_i, y_i) \in D_z} w_i \times I(v = y_i)$$

07 回归方法

回归问题

- 回归分析
 - 如果把其中的一些因素（房屋面积）作为**自变量**，而另一些随自变量的变化而变化的变量作为**因变量**（房价），研究他们之间的非确定映射关系，这种分析就称为**回归分析（regression）**。
 - 回归分析是研究一个或多个自变量与一个因变量之间是否存在某种**线性关系**或**非线性关系**的一种统计学方法。

线性回归

- 线性回归假设特征和响应满足**线性关系**
- 一元线性回归问题函数关系可表示

$$y = a + bx$$

- 根据上式，在确定a、b的情况下，给定一个x值，我们就能够得到一个确定的y值，然而根据上式得到的y值与实际的y值存在一个误差
- a、b为参数(parameters)、或称回归系数(regression coefficients)
- 采用什么样的线性关系误差刻画更好呢？

最小二乘法

- 基本思想

- 保证直线与所有点接近

- 详细做法

- 若有 n 个样本点: $(x_1, y_1), \dots, (x_n, y_n)$, 可以用下面的表达式来刻画这些点与直线 $y = a + bx$ 的接近程度:


$$[y_1 - (a + bx_1)]^2 + \dots + [y_n - (a + bx_n)]^2$$

- 使上式达到最小值的直线 $y = a + bx$ 就是所求的直线, 这种方法称为最小二乘法。

- 求 a 和 b 的偏导数, 可得

如果用 $\bar{x}$ 表示 $\frac{x_1 + x_2 + \dots + x_n}{n}$, 用 $\bar{y}$ 表示 $\frac{y_1 + y_2 + \dots + y_n}{n}$ 则可得到

$$b = \frac{x_1 y_1 + \dots + x_n y_n - n \bar{x} \bar{y}}{x_1^2 + \dots + x_n^2 - n \bar{x}^2}, a = \bar{y} - b \bar{x}$$



优化求解 —— 梯度下降法

- 基本思想
 - 向着梯度的反方向调整
 - 步长不能太大，也不能太小

The diagram illustrates the gradient descent formula: $\Theta^1 = \Theta^0 - \alpha \nabla J(\Theta)$ evaluated at Θ^0 . Annotations include:

- current position**: points to Θ^0 (blue bubble)
- opposite direction**: points to the minus sign (black bubble)
- small step**: points to α (green bubble)
- direction of fastest increase**: points to $\nabla J(\Theta)$ (purple bubble)
- next position**: points to Θ^1 (red bubble)

逻辑回归函数

1838年由比利时数学家Verhulst首次提出。1920年美国学者 Bearl & Reed 在研究果蝇的繁殖中发现和使用该函数，并在人口估计和预测中推广使用

logistic函数的值域为 $[0,1]$


$$f(x) = \frac{e^x}{1 + e^x}$$

用 $p_i = P(y_i = 1 | x_{i1}, x_{i2}, \dots, x_{ip})$

作为因变量，得到logistic回归模型

$$p_i = \frac{\exp(\alpha + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip})}{1 + \exp(\alpha + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip})}$$

$$\ln \frac{p_i}{1 - p_i} = \alpha + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}$$



逻辑回归参数估计

记得到一个实际观测值 $y_i (i = 1, 2, \dots, n)$ 的概率为

$$P(y_i) = p_i^{y_i} (1 - p_i)^{1-y_i} \quad \leftarrow \begin{aligned} p(y = 1|x; w) &= \phi(w^T x + b) = \phi(z) \\ p(y = 0|x; w) &= 1 - \phi(z) \\ P(y|x; \theta) &= (h_\theta(x))^y (1 - h_\theta(x))^{1-y} \end{aligned}$$

则似然函数为 $L = \prod_{i=1}^n P(y_i) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}$

两边取对数: $\ln L = \sum_{i=1}^n [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)] =$

$$\sum_{i=1}^n \left[y_i \ln \frac{p_i}{1 - p_i} + \ln(1 - p_i) \right]$$
$$\ln \left(\frac{P}{1 - P} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m = \text{logit} P$$

最后得到: $\ln L = \sum_{i=1}^n [y_i (\alpha + \beta x_i) - \ln(1 + \exp(\alpha + \beta x_i))]$

当使得 $\ln L$ 取得最大值时, $-\frac{1}{m} \ln L$ 最小时, 参数估计值即为所求。

逻辑回归参数估计

- 使用梯度下降方法，迭代求解参数

参数估计: $\alpha = -2.869$ ($p=0.0001$),

$\beta = 0.986$ ($p=0.0468$).

回归模型:

如何解释系数的实际意义?


$$p(y = 1 | x) = \frac{e^{-2.869 + 0.986 x}}{1 + e^{-2.869 + 0.986 x}}$$

逻辑回归正则化


$$\text{Logit}(p_i) = \alpha + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

$w_1 x_1 + w_2 x_2 + w_0 = 0$ 对应于平面的一根直线

下述两个公式描述同一条直线，哪个好？

$$0.5x_1 + 0.4x_2 + 0.3 = 0$$

$$5x_1 + 4x_2 + 3 = 0$$



W在数值上越小越好，这样越能抵抗数据的扰动

逻辑回归正则化


$$\text{Logit}(p_i) = \alpha + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

$w_1 x_1 + w_2 x_2 + w_0 = 0$ 对应于平面的一根直线

下述两个公式描述同一条直线，哪个好？

$$0.5x_1 + 0.4x_2 + 0.3 = 0$$

$$5x_1 + 4x_2 + 3 = 0$$



正则化表达式

$$L_1 = \sum_{i=0}^m |w_i|$$

$$L_2 = \sum_{i=0}^m w_i^2$$

W在数值上越小越好，这样越能抵抗数据的扰动

逻辑回归正则化

平衡训练误差与泛化能力

$$E = \sum_{i=1}^n \left(y_i - \frac{1}{1 + e^{-(w_1 x_{i1} + w_2 x_{i2} + w_0)}} \right)^2 + \lambda L_1$$
$$E = \sum_{i=1}^n \left(y_i - \frac{1}{1 + e^{-(w_1 x_{i1} + w_2 x_{i2} + w_0)}} \right)^2 + \lambda L_2$$

正则化表达式

$$L_1 = \sum_{i=0}^m |w_i|$$



$$L_2 = \sum_{i=0}^m w_i^2$$

惩罚项：若学习到大权值使得误差小，但是再加上正则化式子以后使得上面E值变大。

因此，最小化E值使得求解的权值尽可能相对较小。

决策树回归

- 决策树是将空间用超平面进行划分的一种方法，每次分割的时候，都将当前的空间一分为二，这样使得每一个叶子节点都是在空间中的一个不相交的区域，在进行决策的时候，会根据输入样本每一维feature的值，一步一步往下，最后使得样本落入N个区域中的一个（假设有N个叶子节点），如下图所示。



- 既然是决策树，那么必然会存在以下两个核心问题：如何选择划分点？如何决定叶节点的输出值？——
决策树分类选择划分点，使得信息增益最大，叶节点输出即类别
- 一个回归树对应着输入空间（即特征空间）的一个划分以及在划分单元上的输出值。分类树中**采用信息增益等方法**，通过计算选择最佳划分点。**而在回归树中，采用的是启发式的方法。**

小 结

- **线性回归**
 - **连续型因变量-数值预测**
- **逻辑回归**
 - **分类型因变量-类别预测**
- **决策树回归-数值预测**
 - **连续型因变量, 非线性预测**

08 支持向量机分类

了解SVM

- 根据统计学习理论，学习机器的实际风险由**经验风险值**和**置信范围值**两部分组成。而基于经验风险最小化准则的学习方法只强调了训练样本的经验风险最小误差，没有**最小化**置信范围值，因此其泛化能力较差。
- Vapnik于1995年提出的支持向量机（Support Vector Machine, SVM）以训练误差作为优化问题的约束条件，以置信范围值最小化作为优化目标，即SVM是一种基于**结构风险最小化**准则的学习方法，其泛化能力明显优于一些传统的学习方法。

了解SVM

- 由于SVM 的求解最后转化成二次规划问题的求解，因此SVM的解是全局唯一的最优解
- SVM在解决小样本、非线性及高维模式识别问题中表现出许多特有的优势，并能够推广应用到函数拟合等其他机器学习问题中。

最小间隔面推导

$$g(\mathbf{x}) = \langle \mathbf{w}, \mathbf{x} \rangle + b$$

$$= \langle \sum_{i=1}^n (\alpha_i y_i \mathbf{x}_i), \mathbf{x} \rangle + b$$

“primal formulation of linear SVMs”

$$\text{Minimize } \boxed{\frac{1}{2} \sum_{i=1}^n w_i^2} \quad \text{subject to} \quad \boxed{y_i (\vec{w} \cdot \vec{x}_i + b) - 1 \geq 0} \quad \text{for } i = 1, \dots, N$$

Objective function Constraints

$$\text{Gap(Margin): } D = 2 / \|\vec{w}\|$$

Problem Transformation:

$$\max D \rightarrow \min w \rightarrow \min w^2 \rightarrow \min \frac{1}{2}(w^2)$$

最小间隔面推导

$$\begin{array}{ll} \text{Minimize } \boxed{\frac{1}{2} \sum_{i=1}^n w_i^2} & \text{subject to } \boxed{y_i(\vec{w} \cdot \vec{x}_i + b) - 1 \geq 0} \text{ for } i = 1, \dots, N \end{array}$$

Objective function Constraints

$$g(x) = \langle w, x \rangle + b = \langle \sum_{i=1}^n (\alpha_i y_i x_i), x \rangle + b$$

- 用惩罚项来表达限制条件，从而能够转化带限制的优化问题为无限制的优化问题

$$\min_{w,b} \frac{1}{2} \|w\|^2 + \text{penalty term}$$

- 为训练数据中的每个数据样本，定义penalty term如下：

$$\max_{\alpha_i \geq 0} \alpha_i (1 - y_i (w^T x_i + b))$$

- 从而可以重写SVM的优化问题：


$$\begin{aligned} & \min \left\{ \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \max_{\alpha_i \geq 0} \alpha_i (1 - y_i (w^T x_i + b)) \right\} \\ & = \min_{w,b} \max_{\{\alpha_i \geq 0\}} \left\{ \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \alpha_i (1 - y_i (w^T x_i + b)) \right\} \end{aligned}$$

拉格朗日
乘子

SVM目标函数求解：对偶问题求解

- 发现
 - 所有非支持向量对应的系数 α 都等于0

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1)$$



支持向量机解的**稀疏性**：训练完成后，大部分的训练样本都不需保留，最终模型仅与支持向量有关。

SVM目标函数求解：稀疏性理论解释

- 最终模型：

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^\top \mathbf{x} + b$$

- KKT条件：

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\mathbf{x}_i) \geq 1, \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0. \end{cases}$$

$$y_i f(\mathbf{x}_i) > 1 \quad \Rightarrow \quad \alpha_i = 0$$

支持向量机解的**稀疏性**：训练完成后，大部分的训练样本都不需保留，最终模型仅与支持向量有关。

基于软间隔的C-SVM

- 形式化：
 - 具体的，这种所谓软间隔方法引入了松弛变量 $\xi_i (\geq 0)$ ，用以表征或者说度量分类器针对训练样本 x_i 的差错程度。则最优划分平面求解的优化问题转化为：


$$\min_{(w,b)} \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \right\}$$

$$\text{s.t. } (y_i (w x_i + b) \geq 1 - \xi_i) \text{ and } (\xi_i \geq 0), \quad \forall i = 1, \dots, n$$

其中 C 为预先选定的调和参数。

同样运用Lagrange数乘法，通过引入非负的Lagrange乘子矢量 α 和 β ，可得到此时优化问题的原始形式如下：

$$\min_{(w,b)} \max_{\alpha, \beta} \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i [y_i (w \cdot x_i + b) - 1 + \xi_i] - \sum_{i=1}^n \beta_i \xi_i \right\}$$



非线性SVM与核变换

- 概述:

- 在 R_q 空间中, 因为 D' 是线性可分的, 所以其判别函数和最优分类平面求解的对偶形式分别为:

$$f(z) = \text{sign}(wz + b - 1) = \text{sign}\left(\sum_{i=1}^n \alpha_i y_i z_i^T z + b - 1\right)$$

$$\max_{\alpha \geq 0, \sum_{i=1}^n \alpha_i y_i = 0} \left\{ \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j z_i^T z_j \right\}$$

观察以上两个式子可见: 无论判别函数还是对偶形式中的目标函数都只涉及到高维空间中两个矢量之间的内积, 而并不需要知道它们的具体坐标。

$$z_i^T z_j = K(x_i, x_j)$$

$$\sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i,j=1}^l \alpha_i \alpha_j y_i y_j (x_i \cdot x_j)$$

非线性SVM与核变换

- 常用核函数:

- 高斯RBF (Radial Basis Function)核:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2\right) = \exp\left(-\|\mathbf{x}_i - \mathbf{x}_j\|^2 / 2\sigma^2\right)$$

- 齐次多项式(homogeneous polynomial)核:

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i \cdot \mathbf{x}_j)^d$$

- 非齐次多项式(inhomogeneous polynomial)核:

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i \cdot \mathbf{x}_j + 1)^d$$

- Sigmoid核:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\kappa \mathbf{x}_i \cdot \mathbf{x}_j + \theta)^d$$

09 神经网络分类

人工神经网络

- 人工神经网络主要由大量的神经元以及它们之间的有向连接构成。包含三个方面：

- **神经元的激活规则**


- 主要是指神经元输入到输出之间的映射关系，一般为非线性函数

- **网络的拓扑结构**


- 不同神经元之间的连接关系。

- **学习算法**


- 通过训练数据来学习神经网络的参数。



(a) 前馈网络




(b) 记忆网络



(c) 图网络

多层人工神经网络






- 人工神经网络比感知机模型复杂
 - 输入层和输出层之间包含隐藏层



多层人工神经网络


- 人工神经网络比感知机模型复杂
 - 激活函数可以是多种函数

$$\theta_0 \leftarrow \theta_0 - \eta \frac{\partial f}{\partial \theta_0}$$



多层人工神经网络

- 人工神经网络比感知机模型复杂
 - 激活函数可以是多种函数



解决了部分梯度消失问题

激活函数	函数	导数
Logistic 函数	$f(x) = \frac{1}{1+\exp(-x)}$	$f'(x) = f(x)(1 - f(x))$
Tanh 函数	$f(x) = \frac{\exp(x) - \exp(-x)}{\exp(x) + \exp(-x)}$	$f'(x) = 1 - f(x)^2$
ReLU	$f(x) = \max(0, x)$	$f'(x) = I(x > 0)$
ELU	$f(x) = \max(0, x) + \min(0, \gamma(\exp(x) - 1))$	$f'(x) = I(x > 0) + I(x \leq 0) \cdot \gamma \exp(x)$
SoftPlus 函数	$f(x) = \log(1 + \exp(x))$	$f'(x) = \frac{1}{1+\exp(-x)}$

收敛速度比双面正切更快

导致神经元懒惰


设置较小的学习率

误差反向传播 (BP) 网络

- 激活函数

- 必须处处可导

- 一般都使用S型函数




- 使用S型激活函数时BP网络输入与输出关系

- 输入

$$net = x_1 w_1 + x_2 w_2 + \dots + x_n w_n$$

- 输出

$$y = f(net) = \frac{1}{1 + e^{-net}}$$



误差反向传播 (BP) 网络


- **学习的类型：** 监督式学习
- **核心思想：**
 - 将输出误差以**某种形式**通过隐层向输入层逐层反传

将误差分摊给各层的所有单元
—— 各层单元的误差信号



修正各单元权值

- **学习的过程：**
 - 信号的正向传播 → 误差的反向传播



误差反向传播 (BP) 网络

- **正向传播:**

- 输入样本 — 输入层 — 各隐层 — 输出层

- **判断是否转入反向传播阶段:**

- 若输出层的实际输出与期望的输出（教师信号）不符

- **误差反传**

- 误差以某种形式在各层表示 —— 修正各层单元的权值
- 



- **网络输出的误差减少到可接受的程度**

- **进行到预先设定的学习次数为止**

后向传播算法


1、初始化权重

- 循环以下两步，直到满足条件

2、向前传播输入

- 在每个节点加权求和，再代入激活函数

$$I_j = \sum_i x_i w_{ij} \quad y = \frac{1}{1 + e^{-I_j}}$$




3、向后传播误差

$$E_j = \frac{1}{2} (t_j - o_j)^2$$

$$E_j = \frac{1}{2} (t_j - o_j)^2$$


$$w_{ij} = w_{ij} + \Delta w_{ij}$$

$$t_j = t_j + \Delta t_j$$



后向传播BP网络注意事项

- 初始值选择
 - 权值向量以及阈值的初始值应设定在**一均匀分布的小范围内**
 - 初始值**不能为零**，否则性能曲面会趋向于**鞍点**
 - 初始值**不能太大**，否则远离优化点，导致性能曲面平坦，学习率很慢
- 训练样本输入次序
 - 不同，也会造成不一样的学习结果
 - 在每一次的学习循环中，输入向量输入网络的**次序应使其不同**
- BP算法的学习过程的终止条件
 - 权值向量的梯度 < **给定值**
 - 均方误差值 < **给定误差容限值**
 - 若其**推广能力达到目标**则予终止
 - 可以结合上述各种方式



10 关联规则挖掘

定义：关联分析 (association analysis)

- 关联分析用于发现隐藏在大型数据集中的令人感兴趣的联系，所发现的模式通常用**关联规则或频繁项集**的形式表示。
- 关联规则反映一个**事物与其它事物**之间的相互依存性和关联性。如果**两个或者多个事物之间**存在一定的关联关系，那么，其中一个事物发生就能够预测与它相关联的其它事物的发生。

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Rules Discovered:
{Diaper} --> {Beer}

定义： 频繁项集 (Frequent Itemset)

- **项集 (Itemset)**

- 包含0个或多个项的集合
 - 例子： {Milk, Bread, Diaper}
- k-项集
 - 如果一个项集包含k个项

- **支持度计数 (Support count) (σ)**

- 包含特定项集的事务个数
- 例如： $\sigma(\{\text{Milk, Bread, Diaper}\}) = 2$

- **支持度 (Support)**

- 包含项集的事务数与总事务数的比值
- 例如： $s(\{\text{Milk, Bread, Diaper}\}) = 2/5$


- **频繁项集 (Frequent Itemset)**

- 满足最小支持度阈值 (minsup) 的所有项集

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

最大频繁项集 (Maximal Frequent Itemset)

最大频繁项集是这样的频繁项集，它的直接超集都不是频繁的



定义：关联规则 (Association Rule)

- 关联规则

- 关联规则是形如 $X \rightarrow Y$ 的蕴含表达式, 其中 X 和 Y 是不相交的项集

- 例子:

$\{\text{Milk, Diaper}\} \rightarrow \{\text{Beer}\}$

- 关联规则的强度

- 支持度 Support (s)

- 确定项集的频繁程度

- 置信度 Confidence (c)

- 确定Y在包含X的事务中出现的频繁程度

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Example:

$\{\text{Milk, Diaper}\} \Rightarrow \text{Beer}$

$$s = \frac{\sigma(\text{Milk, Diaper, Beer})}{|T|} = \frac{2}{5} = 0.4$$

$$c = \frac{\sigma(\text{Milk, Diaper, Beer})}{\sigma(\text{Milk, Diaper})} = \frac{2}{3} = 0.67$$

关联规则挖掘问题

关联规则挖掘问题:

给定事务的集合 T , 关联规则发现是指找出**支持度大于等于 minsup** 并且**置信度大于等于 minconf** 的所有规则, minsup 和 minconf 是对应的支持度和置信度阈值

挖掘关联规则 (Mining Association Rules)

- 大多数关联规则挖掘算法通常采用的一种策略是，将关联规则挖掘任务分解为如下两个主要的子任务：
 - **频繁项集产生 (Frequent Itemset Generation)**
 - 其目标是发现满足最小支持度阈值的所有项集，这些项集称作频繁项集。
 - **规则的产生 (Rule Generation)**
 - 其目标是从上一步发现的频繁项集中提取所有高置信度的规则，这些规则称作强规则 (strong rule) 。

降低产生频繁项集计算复杂度的方法


- 减少候选项集的数量
 - 先验原理: (**Apriori**)
- 减少比较的次数
 - 替代将每个候选项集与每个事务相匹配, 可以使用更高级的数据结构, 或存储候选项集或压缩数据集, 来减少比较次数(**FPGrowth**)

Apriori

- **先验原理:**

- 如果一个项集是频繁的，则它的所有子集一定也是频繁的
- 相反，如果一个项集是非频繁的，则它的所有超集也一定是非频繁的

Apriori算法过程：最小支持度计数=2



Apriori算法特点

- 优点

- 使用先验性质，大大提高了频繁项集逐层产生的效率
- 简单易理解；数据集要求低

- 缺点

- 多次扫描数据库
- 候选项规模庞大
- 计算支持度开销大

Apriori算法需要反复的生成候选项，如果项的数目比较大，候选项的数目将达到**组合爆炸式的增长**

提高Apriori算法性能的方法

Hash-based
itemset counting

散列项集
计数

Transaction
reduction

事务压缩

Partitioning

划分

Sampling

采样

产生关联规则

- 任务描述：给定频繁项集 Y , 查找 Y 的所有非空真子集 $X \subset Y$, 使得 $X \rightarrow Y - X$ 的置信度超过最小置信度阈值 minconf
 - 例子：If $\{A,B,C\}$ is a frequent itemset, 候选规则如下：
$$AB \rightarrow C, \quad AC \rightarrow B, \quad BC \rightarrow A$$
$$A \rightarrow BC, \quad B \rightarrow AC, \quad C \rightarrow AB$$
- 如果 $|Y| = k$, 那么会有 $2^k - 2$ 个候选关联规则 (不包括 $Y \rightarrow \emptyset$ and $\emptyset \rightarrow Y$)

产生关联规则

- 如何高效地从频繁项集中产生关联规则？
 - 通常置信度不满足反单调性（anti-monotone property），例如：
 - $c(ABC \rightarrow D)$ 可能大于也可能小于 $c(AB \rightarrow D)$
 - 但是，针对同一个频繁项集的关联规则，如果规则的后件满足子集关系，那么这些规则的置信度间满足反单调性
 - e.g., $Y = \{A, B, C, D\}$:
$$c(ABC \rightarrow D) \geq c(AB \rightarrow CD) \geq c(A \rightarrow BCD)$$

11 聚类分析

聚类分析概述

- **什么是聚类？**
 - 是把数据对象集合按照相似性划分成多个子集的过程。
 - 每个子集是一个簇（cluster），使得簇中的对象彼此相似，但与其他簇中的对象不相似。：
- **聚类是无监督学习：** 给定的数据没有类标号信息

数据挖掘对聚类的要求

- **处理噪声数据的能力**

- 很多数据库都包含了孤立点，缺失或错误的数据
- 而一些聚类算法对于这样的数据敏感，可能导致低质量的聚类结果

- **对输入数据的顺序不敏感和增量聚类**

- 同一个数据集合，以不同的次序提交给同一个算法，应该产生相似的结果
- 能将新加入的数据合并到已有聚类中

- **高维度**

- 许多聚类算法擅长处理低维数据，可能只涉及两到三维
- 而数据库或者数据仓库可能包含若干维或属性

划分方法

- **划分方法：**将有 n 个对象的数据集 D 划分成 k 个簇，并且 $k \leq n$ ，满足如下的要求：
 - 每个簇至少包含一个对象
 - 每个对象属于且仅属于一个簇
- **基本思想**
 - 首先创建一个初始 k 划分(k 为要构造的划分数)
 - 然后不断迭代地计算各个簇的聚类中心并依新的聚类中心调整聚类情况，直至收敛
- **目标**
 - 同一个簇中的对象之间尽可能“接近” 或相关
 - 不同簇中的对象之间尽可能“远离” 或不同

划分方法

- **启发式方法** $E = \sum_{i=1}^k \sum_{p \in C_i} (d(p, c_i))^2$
 - **k-均值(k-means)**
 - 每个簇用该簇中对象的均值来表示
 - 基于质心的技术
 - **k-中心点(k-medoids)**
 - 每个簇用接近簇中心的一个对象来表示
 - 基于代表对象的技术
- **适用性**
 - 这些启发式算法适合发现中小规模数据库中的球状聚类
 - 对于大规模数据库和处理任意形状的聚类，这些算法需要进一步扩展

K-means

1. 从数据集中随机取K个样本作为初始的聚类中心 $C = \{c_1, c_2, \dots, c_k\}$
2. 针对数据集中每个样本 x_i , 计算它到K个聚类中心的距离并将其分到距离最小的聚类中心对应的类中
3. 针对每个类别 c_i , 重新计算其聚类中心 $c_i = \frac{1}{|c_i|} \sum_{x \in c_i} x$
4. 重复第2和第3步骤, 直到 $\sum_{i=0}^n \min_{c_j \in C} (\|x_j - c_i\|^2)$ 小于特定的阈值

k-means优缺点

- 优点

- 聚类时间快
- 当结果簇是密集的，而簇与簇之间区别明显时，效果较好
- 相对可扩展和有效，能对大数据集进行高效划分

- 缺点

- 用户必须事先指定聚类簇的个数
- 常常终止于局部最优
- 只适用于数值属性聚类(计算均值有意义)
- 对噪声和异常数据也很敏感
- 不同的初始值，结果可能不同
- 不适合发现非凸面形状的簇

K-modes算法 —— 解决数据敏感的问题

- K-means的改进算法主要区别在于：

- 初始k均值选择
- 相异度计算
- 计算均值方法

- 处理分类变量: K-modes

- 针对分类数据
- 用众数代替均值
- 使用新的相异性度量


	(A)	(B)	(C)	(D)	(A)	(B)	(C)	(D)	(A)	(B)	(C)	(D)	
Response 1	1	0	0	0	0	0	0	1	0	1	0	0	...
Response 2	0	1	0	0	0	0	0	1	0	0	0	1	...
Response 3	1	0	0	0	0	1	0	0	1	0	0	0	...
Response 4	0	0	1	0	0	0	1	0	1	0	0	0	...

Question 1 Question 2 Question 3

K-means++ 算法 —— 解决初始点选择问题

- 基本原理

- ① 从输入的数据点集合中随机选择一个点作为第一个聚类中心
- ② 对于数据集中的每一个点 X ，计算其与聚类中心的距离 $D(X)$
- ③ 选择一个 $D(X)$ 最大的点作为新的聚类中心
- ④ 重复2和3步直到 K 个聚类中心被选出
- ⑤ 利用 K 个初始聚类中心运行K-Means




尽可能选择距离远的点来作为初始种子节点

k-中心点

- k-中心点

- 选用簇中位置**最中心**的**实际对象**即中心点作为参照点
- 基于最小化所有对象与其参照点之间的相异度之和的原则来划分(使用绝对误差标准)

$$E = \sum_{i=1}^k \sum_{p \in C_i} |p - o_i|$$



层次方法

- 层次方法

- 对给定数据对象集进行层次的分解
- 使用距离矩阵作为聚类标准
- 不需要输入聚类数目 k ，但需要终止条件

- 两种层次方法

- 自底向上方法（凝聚）

- 初始将每个对象作为单独的一个簇，然后相继的合并相近的对象或簇，直到所有的簇合并为一个，或者达到一个终止条件
- 代表算法：AGNES算法

- 自顶向下方法（分裂）


- 初始将所有的对象置于一个簇中，在迭代的每一步，一个簇被分裂为多个更小的簇，直到最终每个对象在一个单独的簇中，或达到一个终止条件
- 代表算法：DIANA算法

AGNES算法 —— 最小距离

- 单链接

- 其每个簇可以用簇中所有对象代表，簇间的相似度用属于不同簇中**最近的**数据点对之间的**相似度来度量**
- 也称为**最短距离法**，定义簇的邻近度为取自不同簇的两个最近的点之间的邻近度
- 设 d_{ij} 表示样本 $X_{(i)}$ 和 $X_{(j)}$ 之间的距离， D_{ij} 表示类 G_i 和 G_j 之间距离

$$D_{ij} = \min_{X_{(i)} \in D_i, X_{(j)} \in D_j} d_{ij}$$




AGNES算法 —— 最大距离

- 全链接

- 取自不同簇中的两个最远的点之间邻近度作为簇的邻近度

$$D_{ij} = \max_{X_{(i)} \in G_i, X_{(j)} \in G_j} d_{ij}$$




AGNES算法 —— 平均距离

- 平均链接

- 类间所有样本点的平均距离
- 该法利用了所有样本的信息，被认为是较好的系统聚类法

$$d_{avg}(C_i, C_j) = \frac{1}{n_i n_j} \sum_{p \in C_i} \sum_{p' \in C_j} \|p - p'\|$$



聚类评估

- 估计在数据集上进行聚类的可行性和被聚类方法产生的结果的质量
- 聚类评估的任务
 - 估计聚类趋势：评估数据集是否存在非随机结构，如霍普金斯统计量
 - 确定数据集中的簇数：在聚类之前，估计簇数，如肘部 (Elbow) 方法
 - 测定聚类质量：聚类之后，评估结果簇的质量
 - 有监督：用某种聚类质量度量对聚类结果和基准进行比较
 - 无监督：通过考察簇的分离情况和簇的紧凑情况来评估聚类，如轮廓系数

12 集成学习

集成学习简介

- **定义**

- **集成学习 (Ensemble learning) 方法通过组合多种学习算法来获得比单独使用任何一种算法更好的预测性能。.**

- **动机**

- **提高单分类器的性能**

集成学习算法

1

Bagging

2


Boosting

3

Stacking

Bagging: 有放回的重采样

Bootstrap Aggregating



讨论：样本集合如何选取？

如果训练集规模足够大，平均分成 t 份即可

如果训练集规模不大，怎么办？


Bagging: 有放回的重采样



Sample 1



Sample 2



Sample 3



Bagging: 随机森林

- 基本思想

- 随机森林就是通过**集成学习的思想将多棵树集成的一种算法**，它的基本单元是**决策树（如CART）**。
- 随机森林的名称中有两个关键词，一个是“**随机**”，一个就是“**森林**”。“森林”很好理解，一棵叫做树，那么成百上千棵就可以叫做森林了，其实这也是随机森林的主要思想--**集成思想的体现**。“随机”的包括**随机选取训练样本集**和**随机选取分裂属性集**。



Bagging: 随机森林

- **优点:**

- 两个随机性的引入, 使得随机森林**不容易陷入过拟合**;
- 两个随机性的引入, 使得随机森林**具有很好的抗噪声能力**;
- 对数据集的适应能力强: **既能处理离散型数据, 也能处理连续型数据, 数据集无需规范化且能够有效地运行在大数据集上**;
- 能够处理具有高维特征的输入样本, 而且**不需要降维**;
- 对于缺省值问题也能够获得很好得结果。

集成学习算法

1

Bagging

2

Boosting

3

Stacking

Boosting Weight

- 核心思想
- 样本的权重
 - 没有先验知识的情况下，初始的分布应为等概分布，也就是训练集如果有 N 个样本，**每个样本的分布概率为 $1/N$**
 - 每次循环后提高错误样本的分布概率，**分错样本在训练集中所占权重增大，使得下一次循环的弱学习器能够集中力量对这些错误样本进行判断。**
- 弱学习器的权重
 - **准确率越高的弱学习机权重越高**
- 循环控制：损失函数达到最小
 - 在强学习器的组合中增加一个加权的弱学习器，使**准确率提高，损失函数值减小。**

AdaBoost: train

for $k = 1$ to *iterations*:

- classifier_k = learn a weak classifier based on weights
- calculate weighted error for this classifier (加权分类误差)

$$e_k = \sum_{i=1}^n w_i * 1[label_i \neq classifier_k(x_i)]$$

- calculate “score” for this classifier (分类器的系数)

$$a_k = \frac{1}{2} \log \frac{1 - e_k}{e_k}$$

- change the example weights (权值的更新)

$$w_i = \frac{1}{Z} w_i \exp(- a_k * label_i * classifier_k(x_i))$$

集成学习算法

1

Bagging


2

Boosting

3

Stacking

Stacking



数据

基分类器

元分类器

$\{(x_1, y_1) \dots (x_n, y_n)\}$

$\{(h_1(x_i), h_2(x_i), \dots, h_k(x_i), y_i)\}$

基分类器的结果再训练出一个元分类器

13 模型的评价

准确率评价

混淆矩阵

	PREDICTED CLASS	
	Class=Yes	Class=No
ACTUAL CLASS		
Class=Yes	a (TP)	b (FN)
Class=No	c (FP)	d (TN)

$$\text{准确率 (Accuracy)} = \frac{a + d}{a + b + c + d} = \frac{TP + TN}{TP + TN + FP + FN}$$

其它度量

ACTUAL CLASS	PREDICTED CLASS	
	Class=Yes	Class=No
	Class=Yes	Class=No
	a (TP)	b (FN)
	c (FP)	d (TN)

- **真阳率TP**，真阳性（True positive rate, TPR）或**灵敏度（sensitivity）**、**查全率（recall）**
 - $TPR = TP / (TP + FN)$
- **真阴率TN**，真阴性（True negative rate, TNR）或**特指度（specificity）**
 - $TNR = TN / (TN + FP)$
- **假阳率FP**，假阳性（False positive rate, FPR）或**误报率**
 - $FPR = FP / (TN + FP)$
- **假阴率FN**，假阴性（False negative rate, FNR）**漏报率（与查全率此消彼长）**
 - $FNR = FN / (TP + FN)$

查全率vs.查准率

下面是两个场景：

- **地震的预测：**对于地震的预测，我们希望的是recall非常高，也就是说每次地震我们都希望预测出来。这个时候我们可以牺牲precision。情愿发出1000次警报，把10次地震都预测正确了，也不要预测100次，对了8次，漏了2次。
- **嫌疑人定罪：**基于不错怪一个好人的原则（无罪推定原则，presumption of innocence），对于嫌疑人的定罪我们希望是非常准确的（precision高），及时有时候放过了一些罪犯（recall低），但也是值得的。

$$F_1 = \frac{2rp}{r + p} = \frac{2 \times TP}{2 \times TP + FP + FN}$$

ROC曲线

- 接收者操作特征曲线 (Receiver Operating Characteristic Curve, 或者叫ROC曲线) 是一种坐标图式的分析工具, 用于
 - 选择最佳的分类模型、舍弃次佳的模型。
 - 在同一模型中设定最佳阈值。
- 给定一个二元分类模型和它的阈值, 就能从所有样本的(阳性 / 阴性)真实值和预测值计算出一个 (X=FPR, Y=TPR) 坐标点。

A\P	C	¬C	
C	TP	FN	P
¬C	FP	TN	N
	P'	N'	All

$$TPR = TP / (TP + FN)$$

$$FPR = FP / (TN + FP)$$


$$TNR = TN / (TN + FP)$$

$$FNR = FN / (TP + FN)$$

ROC曲线属性


(FPR, TPR):

- (0,0): 任何分类都是**阴性**
- (1,1): 任何分类都是**阳性**
- (0,1): **理想分类**
- 对角线:
 - 随机猜测结果
 - 对角线以下: 预测结果与真实结果相反



ROC曲线下方面积：AUC

- ROC曲线下方的区域称为AUC，Area Under the ROC curve
- Ideal:
 - Area = **1**
- Random guess:
 - Area = **0.5**



$$TPR = TP / (TP + FN)$$

$$FPR = FP / (TN + FP)$$

如何构建ROC曲线

- 首先利用分类器计算每个数据记录的后验概率 $P(+|A)$
- 将这些数据记录对应的 $P(+|A)$ 从高到低排列（如右表）：
 - 由低到高，对于每个 $P(+|A)$ 值（threshold，阈值），把对应的记录以及那些值**高于或等于**阈值指派为阳性类positive，把那些值**低于**阈值指派为阴性类negative
 - 统计 TP, FP, TN, FN
 - 计算 $TPR = TP/(TP+FN)$ 和 $FPR = FP/(FP + TN)$
- 绘出诸点(FPR, TPR)并连接它们

Instance	$P(+ A)$	True Class
1	0.95	+
2	0.93	+
3	0.87	-
4	0.85	-
5	0.85	-
6	0.85	+
7	0.76	-
8	0.53	+
9	0.43	-
10	0.25	+

模型过分拟合和拟合不足

- 分类模型的误差大致分为两种：
 - **训练误差**：是在训练记录上误分类样本比例
 - **泛化误差**：是模型在未知记录上的期望误差
- 一个好的分类模型不仅要能够很好的拟合训练数据，而且对未知样本也要能准确分类。
- 换句话说，一个好的分类模型必须具有低训练误差和低泛化误差。
- 当训练数据拟合太好的模型（**较低训练误差**），其**泛化误差**可能比**具有较高训练误差**的模型高，这种情况成为模型**过分拟合**。

数据预处理→模型训练→模型调整→对新数据分类→模型评价

缺乏代表性样本导致的过分拟合

- 根据**少量训练记录**做出分类决策的模型也容易受过分拟合的影响。
- 由于训练数据缺乏具有代表性的样本，在没有多少训练记录的情况下，**学习算法仍然细化模型**就会产生过分拟合。

表 4-5 哺乳动物分类的训练集样本

名称	体温	胎生	4 条腿	冬眠	类标号
蝾螈	冷血	否	是	是	否
虹鳟	冷血	是	否	否	否
鹰	恒温	否	否	否	否
弱夜鹰	恒温	否	否	是	否
鸭嘴兽	恒温	否	是	是	是





图 4-26 根据表 4-5 中的数据集建立的决策树


减少泛化误差

- 过分拟合的主要原因一直是个争辩的话题，但数据挖掘研究界普遍认为**模型的复杂度**对模型的过分拟合有影响。
- 如何确定正确的模型复杂度？理想的复杂度是能产生最低泛化误差的模型的复杂度。
- **奥卡姆剃刀定律**




减少泛化误差

- 根据奥卡姆剃刀原则
 - 引入惩罚项，使较简单的模型比复杂的模型更可取
 - 引入正则项
 - 神经网络中，引入dropout机制



(a) Standard Neural Net



(b) After applying dropout.

减少泛化误差

● 使用验证集

- 该方法中，不是用训练集估计泛化误差，而是把原始的训练数据集分为两个较小的子集，一个子集用于训练，而另一个称为验证集，用于估计泛化误差。
- 该方法为评估模型在未知样本上的性能提供了较好办法。

