



南京大學
NANJING UNIVERSITY

自然语言处理

0. 引言

虞剑飞

南京大学智能科学与技术学院

2025.2.19

联系方式

- 主讲：虞剑飞
 - 邮箱： jfyu@nju.edu.cn
 - 主页： <https://sites.google.com/site/jfyu1990/>
- 助教：宋晓
 - 邮箱： x.song@samil.nju.edu.cn
 - 手机： 18810779353
- 课程QQ群：




扫一扫二维码，入群聊



引言


- 从人工智能开始
 - 让机器具有人类的智能
 - 机器感知（计算机视觉、语音信息处理）
 - 学习（模式识别、机器学习、强化学习）
 - 语言（自然语言处理）
 - 记忆（知识表示）
 - 决策（规划、数据挖掘）



Alan Turing

引言

- 从人工智能开始
 - 让机器具有人类的智能
 - 机器感知（计算机视觉、语音信息处理）
 - 学习（模式识别、机器学习、强化学习）
 - 语言（自然语言处理）
 - 记忆（知识表示）
 - 决策（规划、数据挖掘）



Alan Turing

引言

- 人工智能发展初期
 - 机器翻译



IBM-701计算机

1954年，世界上第一个机器翻译系统

随着机器翻译研究进展

各种自然语言处理技术应运而生



IBM Archives > Exhibits > IBM 701 > 701 Reference room >

701 Translator

IBM Press release, January 8, 1954

New York, January 7.... Russian was translated into English by an electronic "brain" today for the first time.

Brief statements about politics, law, mathematics, chemistry, metallurgy, communications and military affairs were submitted in Russian by linguists of the Georgetown University Institute of Languages and Linguistics to the famous 701 computer of the International Business Machines Corporation. And the giant computer, within a few seconds, turned the sentences into easily readable English.

A girl who didn't understand a word of the language of the Soviets punched out the Russian messages on IBM cards. The "brain" dashed off its English translations on an automatic printer at the breakneck speed of two and a half lines per second.

"Mi pyeryedayem mislyi posryedstvom ryechyi," the girl punched. And the 701 responded: "We transmit thoughts by means of speech."

"Vyelyichyina ugla opryedyelayetsya otnoshenyem dlyini dugi k radiyusu," the punch rattled. The "brain" came back: "Magnitude of angle is determined by the relation of length of arc to radius."

"Myezhdunarodnoye ponyimaniye yavlyayetsya vazhnim faktorom v ryeshenyiyi polyityicheskix voprosov," the girl tapped out. And the computer translated: "International understanding constitutes an important factor in decision of political questions."

More than sixty Russian sentences were given to the "brain" altogether. All were translated smoothly in a demonstration performed jointly by Georgetown and IBM as a phase of IBM's endowed research in computation.

A handful of men had been individually engaged in research at various institutions for almost a decade to make a machine convert the meaning of words clearly from one language to another. No practical results were achieved until Georgetown a year and a half ago enlisted the aid of the most versatile electronic "brain" extant, the IBM 701.

This amazing instrument was interrupted in its 16-hour-a-day schedule of solving problems in nuclear physics, rocket trajectories, weather forecasting and other mathematical wizardry. Its attention was turned at brief intervals from these lightninglike numerical calculations to the altogether different consideration of logic in an entirely new and strange realm for giant electronic data processing machines: the study of human behavior -- specifically, the human use of words. The result, as publicly proved today, was an unqualified success.

"The potential value of this experiment for the national interest in defense or in peace is readily seen," Prof. Leon Dostert, Georgetown language scholar who originated the practical approach to the idea of electronic translation, declared to a group of scientists and United States government officials who witnessed the demonstration at IBM World Headquarters, 57th Street and Madison Avenue.

引言

- 人工智能发展现阶段
 - 深度学习
 - 工业界



智能音箱



新闻写稿机器人



自动作文评分系统

引言

- 人工智能发展现阶段
 - 深度学习
 - 弱人工智能 → 强人工智能

KZ

最近有个tree tree new bee这个词比较火，你知道是什么意思吗



作为一个AI语言模型，我可以告诉你“Tree tree new bee”并不是一个标准的英文短语或习语，它可能是一些人自己发明的一个口头用语或者网络热词。我目前无法确定它的具体含义或来历。您可以提供更多上下文信息，让我更好地理解这个短语并为您提供更准确的答案。

KZ

是的。这是个网络词汇，是中文的谐音。



了解了这个补充信息后，我可以告诉您，“Tree tree new bee”（树树纽比）是一个近期在中国网络上流行的网络热词，它的中文谐音是“输输怒吧”。这个短语的出处可以追溯到一段视频中，一个小孩被其他孩子欺负，他大喊“输输怒吧”，并在一些网络平台上广泛传播。现在，“Tree tree new bee”已经成为一种网络语言和表达方式，用来表达输了比赛或失败的情况下的“不服输”的精神。

KZ

不是的，这个词和吹牛有关。



感谢您的纠正和补充信息。我了解到，“Tree tree new bee”（树树纽比）在中国网络上还有一种解释，即与吹牛或炫耀有关。它的中文谐音是“吹吹牛逼”，其中“牛逼”是一种俚语，指的是某人非常厉害或成功。因此，“Tree tree new bee”这个网络热词可以用来形容某人吹嘘或炫耀自己的成就或能力。

Regenerate response

先修十字街，在修月花台，身子不用动，口粮自动来(打一动物)。

嗯，这个谜语的题目是“先修十字街，在修月花台，身子不用动，口粮自动来”，打一动物。首先，我需要仔细分析每一句话，看看它们分别代表什么，然后综合起来找出对应的动物。

首先，第一句“先修十字街”。十字街通常指的是交叉路口，形状像一个十字，可能与某种动物的特征有关。比如蜘蛛网的结构有时候会被形容为十字形，或者是某种动物的身体结构有交叉的部分。

第二句“在修月花台”。月花台听起来像是一个装饰性的结构，可能与圆形或弧形有关，比如蜘蛛网的圆形结构，或者是某种动物的巢穴形状。另外，“月”可能代表圆形，“花”可能指美丽或复杂的花纹。

第三句“身子不用动”，说明这种动物不需要移动身体，可能是指它静止不动，等待猎物上门，比如蜘蛛结网后等待昆虫自投罗网。

第四句“口粮自动来”，进一步说明它不需要主动捕猎，食物会自己送上门，这也是蜘蛛的典型行为，因为它们结网后等待猎物被网粘住，然后过去捕获。

结合起来，这四句话可能是在描述蜘蛛。蜘蛛结网的时候，会先拉出放射状的丝线（十字街），然后围绕中心编织圆形的网（月花台），之后蜘蛛待在网中央或附近不动（身子不用动），等待昆虫撞到网上成为食物（口粮自动来）。

不过，我需要确认是否有其他动物符合这些特征。比如，有些捕食性昆虫如螳螂也会等待猎物，但通常需要主动出击，而不会建造类似的结构。另外，水母虽然也有触手，但生活环境不同，且“十字街”和“月花台”不太符合水母的特征。

再考虑蜘蛛结网的过程，确实会先拉出几条主要的辐射丝（类似十字），然后编织螺旋形的捕获丝，形成圆形网（月花台）。因此，答案应该是蜘蛛。

答案：蜘蛛

解析：

1. 先修十字街：蜘蛛结网时，首先会搭建放射状的丝线，形似“十字”结构，作为网的骨架。
2. 在修月花台：随后，蜘蛛围绕中心编织螺旋形的圆形网，状如“月花台”，用于捕捉猎物。
3. 身子不用动：蜘蛛结网后，常静伏于网中央或隐蔽处，无需频繁移动。
4. 口粮自动来：猎物触网后被粘住，蜘蛛无需主动捕猎，食物“自动”送上门。

Message DeepSeek

DeepThink (R1) Search

AI-generated, for reference only

引言

- 课程内容
 - 第一部分：NLP基础知识：概念、规则方法、文本分类与语言模型
 - 自然语言处理概述
 - 概要介绍自然语言处理的发展历史；
 - 典型应用简介；
 - 挑战问题；
 - 技术发展趋势。
 - 自然语言处理之规则方法
 - 规则方法的基本框架，以词形还原、分词等任务为例介绍规则方法的设计与实现过程。
 - 文本分类
 - 文本分类的应用；文本表示词袋模型；
 - 朴素贝叶斯文本分类模型；线性文本分类模型；
 - $tf*idf$ 表示模型；特征选择方法；
 - 文本分类评价方法。
 - 语言模型：概念、建模方法及应用
 - N-Gram语言模型；线性语言模型；模型参数估计；语言模型评价。

引言

- 课程内容
 - 第二部分：面向NLP的深度学习基础
 - 词向量
 - 词汇表征；潜在语义分析；词表示学习；
 - 词向量（word2vec）算法思想；
 - CBOW/Skip-Gram 模型学习和优化。
 - 文本卷积神经网络
 - 神经网络基础；
 - 卷积的种类与运算；
 - 面向文本的卷积神经网络；
 - 卷积神经网络的应用。
 - 循环神经网络
 - 循环神经网络语言模型；
 - GRU/LSTM等高级循环神经网络模型；递归神经网络；
 - 注意力机制；
 - 循环神经网络应用。
 - 高级神经网络与预训练模型
 - 自注意力机制；
 - Transformer网络结构；
 - 预训练模型框架简介。

引言

- 课程内容
 - 第三部分：自然语言理解与应用
 - 序列化标注任务及方法
 - 词性标注、命名实体识别等序列化标注典型任务介绍；
 - 隐马尔可夫模型框架、训练及解码算法；
 - 条件随机场模型框架、特征设计、训练及解码算法；
 - 神经网络序列化标注模型框架简介。
 - 信息抽取
 - 信息抽取子任务及主流技术；
 - 信息抽取应用。
 - 机器翻译
 - 机器翻译应用；
 - 机器翻译的发展历史；
 - 统计机器翻译基本流程和框架；
 - 神经机器翻译框架。
 - 实践课时

引言

- 考核方式
 - 课堂参与10%+课程实践40%+期末考试50%
 - 课程实践1：一个课后作业（从下面三个题目中任选且只选一个，总20分）
 - 基于卷积神经网络的文本分类
 - 基于循环神经网络的命名实体识别
 - 基于Transformer的机器翻译（英文->中文）
 - 提交内容：
 - 代码（可运行的源代码）和文档报告（方法、实验结果、分析）
 - 1-2 分钟程序演示视频
 - 评分标准：综合考量代码实现和文档报告的完整性、准确性、实验效果、演示视频等方面。

引言

- 考核方式


- 课堂参与10%+课程实践40%+期末考试50%
- 课程实践2：期末小组项目（老师、助教打分，总20分）
 - 3-4人一组
 - 项目内容
 - 针对某个自然语言处理任务复现最新论文中的算法，鼓励进一步提出改进算法
 - 或者结合最新的NLP技术提升所在研究方向的一个任务的性能
 - 提交内容
 - 项目报告（方法、实验、结果分析）和源代码
 - PPT文件以及10-15 分钟的PPT演讲视频（第 13 周周日晚 12 点前提交给助教）
 - 课堂答辩（第 15 周）：
 - 5 分钟答辩，老师和助教根据PPT演讲视频提前准备问题。
 - 抽查代码，如有 Demo，可现场演示。
 - 评分标准：综合考量代码实现和报告的完整性、准确性、实验效果、创新性、团队分工与贡献、答辩表现等方面

引言

- 参考资料


- 参考文献

[1] C. D. Manning, H. Schütze . 1999. *Foundations of Statistical Natural Language Processing*. The MIT Press



CHRISTOPHER D. MANNING AND
HINRICH SCHÜTZE

Copyrighted Material






苑春法等译，**统计自然语言处理基础**，电子工业出版社，2005

引言

- 参考资料
 - 参考文献

[2] 宗成庆：统计自然语言处理（第2版），清华大学出版社，2013年8月

[3] 宗成庆等：文本数据挖掘，清华大学出版社，2019年5月(Text Data Mining, Springer, April 2021)



引言

- 参考资料
 - 参考文献
 - 本门课大部分内容来自于上述三本书
 - 基于中科院自动化所宗成庆老师和张家俊老师的课件进行了部分修改

引言

- 参考资料
 - 网上课程

学校	主讲老师	课程网站
Columbia University	Michael Collins	http://www.cs.columbia.edu/~cs4705/
Stanford	Christopher Manning	b站链接
Stanford	Dan Jurafsky	b站链接



南京大學
NANJING UNIVERSITY

自然语言处理

1. 绪论

虞剑飞

南京大学智能科学与技术学院

2025.2.19

本章内容

- 问题的提出
- 基本概念
- 学科的产生与发展
- 研究内容
- 面临的问题与挑战
- 基本方法与技术现状

问题的提出

设为首页 手机新


sina 新浪网
sina.com.cn
新闻 军事
财经 股票
科技 手机


欧文被交易

新浪产品
每日一闻

荔枝新闻
荔枝 LIZHI NEWS

【首发】22-3-1
【#南京新
防控工作要
意,自202
风险等级相

JSTV
荔枝网
22-3-1

西风晚报
22-3-1

生菜多
22-3-1

有李
22-3-1

阿漫
22-3-1

共5条

漂水发
22-3-1

今天不
22-3-1

诗路八
22-3-1

樱花雨
22-3-1

匿名用户
★★★★★
2021年11月16日
上菜很慢很慢很慢,等很久很久很久,服务很差很差很差,要俩鸡蛋服务员转头就忘了,下次吃水林间绝对不会来金鹰,味道和服务都比南京其他水林间要差。

赞

红橡树860
★★★★★
2021年12月4日
菜品很棒,牛肉虾滑,小食品也非常好吃。

赞

夜空孤星Z
★★★★★
2021年12月5日
还行,吃了两三回了

赞

寂寞的钩子
★★★★★
2021年12月2日
很满意的一次就餐体验,整体评价的话我觉得:服务。

赞


问题的提出

- 语言是思维的载体，是人类交流思想、表达情感最自然、最直接、最方便的工具
- 人类历史上以语言文字形式记载和流传的知识占知识总量的**80%**以上
- 2008年1月中国互联网络信息中心 (CNNIC) 发布的《第21次中国互联网络发展状况统计报告》表明，中国互联网上有**87.8%**的网页内容是文本表示的
- 面对文本**大数据**，我们面临怎样的机遇和挑战？

问题的提出

- 网络信息检索市场前景广阔

- 全世界网页数量仍在不断上涨




- 中文网页检索的准确率不高 (40~50%?)

问题的提出

- 随着社会全球化时代的到来，机器翻译市场潜力巨大：

- 文化
- 商旅
- 旅游
- 体育
-



跨语言通讯和信息获取技术具有重要的用途

全世界正在使用的语言有几千种。

问题的提出

利用网络组织犯罪，已成为不法活动的新特点

信息安全问题已经成为
国际社会共同关注



恐怖爆炸

问题的提出



问题的提出

微信

电话

人们处在不同的国家，使用不同的语言，通过不同的手段和方式发表不同的言论（微博/微信/Twitter/Facebook、专著、论文、网页等），千丝万缕的关系将他们联系在一起，构成一个特定的社会网络，如何发现或挖掘这种网络？如何确定不同的实体，事件和知识之间的关联？


QQ

微博

社区论坛


问题的提出

- 人物、事件关系分析意义重大




问题的提出

- 人物、事件关系分析意义重大



问题的提出



人工难以应对的数据“灾难”！

问题的提出

- 如何让计算机能够自动或者半自动地理解自然语言文本，懂得人的意图和心声？
- 如何让计算机实现海量语言文本的自动处理、挖掘和有效利用，满足不同用户的各种需求，实现个性化信息服务？

自然语言处理

Natural Language Processing, NLP

本章内容

- 问题的提出
- 基本概念
- 学科的产生与发展
- 研究内容
- 面临的问题与挑战
- 基本方法与技术现状

基本概念

- 语言学 VS. 计算语言学
- 自然语言理解 VS. 自然语言处理
VS. 中文信息处理

基本概念

- 定义1: 语言学 (linguistics)

语言学是指对语言的科学研究。

— 戴维·克里斯特尔, 《现代语言学词典》, 1997

研究语言的本质、结构和发展规律的科学。

— 商务印书馆, 《现代汉语词典》第3版, 1996

研究语言的本质、结构和发展规律的学科。

— 商务印书馆, 《现代汉语词典》第7版, 2019

语音和文字是语言的两个基本属性。

基本概念

作为一门纯理论的学科，语言学在近期获得了快速发展，尤其从上个世纪60年代起，已经成为一门知晓度很高的广泛教授的学科。包括：历时语言学 (diachronic linguistics) 或称历史语言学 (historical linguistics)、共时语言学 (synchronic linguistics)、描述语言学 (descriptive linguistics)、对比语言学 (contrastive linguistics)、结构语言学 (structural linguistics) 等等。

基本概念

- **定义2：计算语言学 (Computational Linguistics)**

通过建立形式化的计算模型来分析、理解和生成自然语言的学科，是人工智能和语言学的分支学科。计算语言学是典型的交叉学科，其研究常常涉及计算机科学、语言学、数学等多个学科的知识。与内容接近的学科**自然语言处理**相比较，计算语言学更加侧重基础理论和方法的研究。

《计算机科学技术百科全书》第三版，2018.5, P476, 常宝宝

基本概念

- 1962年美国成立“机器翻译和计算语言学学会(Association for Machine Translation and Computational Linguistics)”并组织召开了第一届国际计算语言学学术年会 (ACL, The annual meeting of the Association for Computational Linguistics)
- 1965年成立国际计算语言学委员会 (The International Committee on Computational Linguistics, ICCL), 并组织召开了第一届国际计算语言学大会 (The International Conference on Computational Linguistics, COLING)
- 1966年术语 Computational Linguistics 正式出现在 ALPAC (Automatic Language Processing Advisory Committee)报告中

基本概念

- The 61st Annual Meeting of the Association for Computational Linguistics, Toronto, Canada, July 9-14, 2023(CCF A类会议)
- The 29th International Conference on Computational Linguistics (COLING'2022), Gyeongju, Republic of Korea, October 12-17, 2022 (CCF B类会议)
- The 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP'2022), Abu Dhabi, December 7–11, 2022 (CCF B类会议)
- 2022 Annual Conference of the North American Chapter of the Association for Computational Linguistics (NAACL'2022), Seattle, Washington, July 10–15, 2022 (CCF B类会议)

基本概念

- **定义3：自然语言理解 (Natural Language Understanding, NLU)**

自然语言理解是探索人类自身语言能力和语言思维活动的本质，研究模仿人类语言认知过程的自然语言处理方法和实现技术的一门学科。它是人工智能早期研究的领域之一，是一门在语言学、计算机科学、认知科学、信息论和数学等多学科基础上形成的交叉学科。

《计算机科学技术百科全书》第三版, P1223 (宗成庆、黄昌宁)

基本概念



达特茅斯学院 (Dartmouth College)
(成立于1769年)

人工智能夏季研讨会 (达特茅斯会议, 1956)

Summer Research Project on **Artificial Intelligence** (Dartmouth Conference)



左起：摩尔、麦卡锡、明斯基、赛弗里奇(Oliver Selfridge)、所罗门诺夫

基本概念

关于“理解”的标准

- 如何判断计算机系统的智能？

计算机系统的表现 (act) 如何？

反应 (react) 如何？

相互作用 (interact) 如何？




与有意识的个体（人）比较如何？

图灵设计的“模仿游戏” — 图灵测试 (Turing test)

基本概念

图灵 (Turing) 测试：



悄悄地提醒：关于图灵测试仍有争议。

基本概念

- **定义4：自然语言处理 (Natural Language Processing, NLP)**

自然语言处理是研究如何利用计算机技术对语言文本（句子、篇章或话语等）进行处理和加工的一门学科，研究内容包括对词法、句法、语义和语用等信息的识别、分类、提取、转换和生成等各种处理方法和实现技术。

《计算机科学技术百科全书》第三版, P1222, 宗成庆、黄昌宁

基本概念

- **自然语言理解** (Natural Language Understanding, NLU) 是人工智能最重要的研究方向之一，是当今“**人工智能皇冠上的明珠**”。
- **计算语言学** (Computational Linguistics, CL)
1960s, 形成相对独立的学科。1962年国际计算语言学学会 (ACL) 成立，1965年国际计算语言学委员会 (ICCL) 成立，1966年“机算语言学”首次出现在美国国家科学院 ALPAC 报告里。
- **自然语言处理** (Natural Language Processing, NLP)
1980s, 面向计算机网络和移动通信，从系统实现和语言工程的角度开展语言信息处理方法的研究。专门针对中文的语言信息技术研究称为中文信息处理。

基本概念


近年来，自然语言处理技术迅速发展成为一门相对独立的学科，倍受关注，而且该技术不断与语音技术相互渗透和结合形成新的研究分支，因此，很多人在谈到“计算语言学”、“自然语言处理”或“自然语言理解”这些术语时，往往默认为同一个概念。甚至有专著[刘颖，2002]干脆直接解释为：**计算语言学也称自然语言处理或自然语言理解**。

人类语言技术
(Human Language Technology, HLT)


基本概念




基本概念




基本概念



基本概念



HLT是当前人工智能领域最具有挑战性的研究方向之一。



基本概念

- 三种不同的语系

- 屈折语 (fusional language / inflectional language): 用词的形态变化表示语法关系，如英语、法语等。
- 黏着语 (agglutinative language): 词内有专门表示语法意义的附加成分，词根或词干与附加成分的结合不紧密，如日语、韩语、土耳其语等。
- 孤立语 (isolating language): 又称分析语 (analytic language)，几乎没有形态变化，语法关系靠词序和虚词表示，如汉语、苗语、越南语等。


基本概念

汉语：汉族的语言，是我国的主要语言。

中文：中国的语言文字，特指汉族的语言文字
— 《现代汉语词典》

- **定义5：中文信息处理 (Chinese Information Processing)**
针对中文的自然语言处理技术

基本概念



基本概念

(Million)

Chinese

汉语已经不再只是中国人自己使用和关注的语言，不管外国人喜欢她还是讨厌她，但没有人敢藐视她！针对汉语的处理技术早已成为国际学术界和企业界共同关注的问题，汉英两大强势语言的自动翻译则是人类语言技术中最具有挑战性的研究课题。

0

French

1950

1970

1990

2010

2030


2050

(Year)

本章内容

- 问题的提出
- 基本概念
- 学科的产生与发展
- 研究内容
- 面临的问题与挑战
- 基本方法与技术现状

学科的产生与发展



1946年，世界上第一台计算机ENIAC诞生



Warren Weaver (July 17, 1894 – Nov. 24, 1978)

- 信息论先驱
- 1920至1932年Wisconsin大学数学教授
- 1932至1955年担任Rockefeller Institute自然科学部主任



- ◆ A. D. Booth 数学物理学家，二战中参与计算机研制，在程序化计算机研究中成绩卓著；
- ◆ 1947年3月至9月，曾在普林斯顿大学参与John Von Neumann研究组，后来曾在伦敦大学工作。

学科的产生与发展



[Reproduced by permission of the Rockefeller Foundation Archives]

March 4, 1947

Dear Norbert:

I was terribly sorry, when in Cambridge recently, that I got unavoidably held up by several unexpected jobs, and did not get a chance to see you.

One thing I wanted to ask you about is this. A most serious problem, for UNESCO and for the constructive and peaceful future of the planet, is the problem of translation, as it unavoidably affects the communication between peoples. Huxley has recently told me that they are appalled by the magnitude and the importance of the translation job.

I wondered if it were unthinkable to design a computer which would translate

Remaining fully aware though necessarily somewhat hesitating, I have nevertheless thought of the problem because of automatic machines, etc. I have wondered if it were unthinkable to design a computer which would translate. Even if it would translate only scientific material (where the semantic difficulties are very notably less), and even if it did produce an inelegant but intelligible result, it would have to be worth while.

Also knowing nothing official about, but having guessed and inferred considerable about, powerful new mechanized methods in cryptography - methods which I believe succeed even when one does not know what language has been coded - one naturally wonders if the problem of translation could conceivably be treated as a problem in cryptography. When I look at an article in Russian, I say "This is really written in English, but it has been coded in some strange symbols. I will now proceed to decode."

Have you ever thought about this? As P. linguist and expert on computers, do you think it is worth thinking about?

Cordially,

Warren Weaver.

Professor Norbert Wiener
Massachusetts Institute of Technology
Cambridge 39, Massachusetts

WW:AEB




诺伯特·维纳 (Norbert Wiener)
(1894年11月26日~1964年3月18日)

学科的产生与发展

- 美国和英国的学术界对机器翻译产生了浓厚的兴趣，并得到了工业界的支持。
- 1954年Georgetown大学在IBM协助下，用IBM-701计算机实现了世界上第一个MT系统，实现俄译英翻译，1954年1月该系统在纽约公开演示。
- 在随后10多年里，MT研究在国际上出现热潮，一批自然语言人机接口系统和对话系统相继出现。

随着机器翻译研究的进展，各种自然语言处理技术应运而生，并逐渐发展壮大，形成了这一语言学与计算机技术相结合的新兴学科。

学科的产生与发展




- ~1950s: 基于模板的NLP方法
- 1960s ~1980s: 基于规则的方法

- 1990~2013: 统计NLP方法
- 2013~: 深度学习方法

学科的产生与发展

- 1947: 机器翻译 (machine translation, MT) 概念提出
- 1954: 世界上第一个 MT 演示系统出现
- 1957: N. Chomsky 发表句法结构理论
- 1966: 美国国家科学院发布语言咨询委员会的评估报告 (ALPAC)
- 1976: 蒙特利尔大学开发完成天气预报翻译系统 TAUM-METEO
- 1982: 日本五代机项目启动
- 1984: 日本学者长尾真教授提出 Example-based MT 方法
- 1989: 统计模型得到应用, 统计机器翻译 (SMT) 系统实现
- 1993: SMT 方法的数学基础发表
- 1999~2007: GIZA/ GIZA++/ Pharaoh/ Moses 等一批工具开放
- 2006: Google Translator 上线
- 2011: 百度翻译系统 上线
- 2013: 神经机器翻译模型提出
- 2014: 端到端的神经机器翻译模型实现


学科的产生与发展



- ~1950s: 基于模板的NLP方法
- 1960s ~1980s: 基于规则的方法

- 1990~2013: 统计NLP方法
- 2013~: 深度学习方法


学科的产生与发展



- ~1950s: 基于模板的NLP方法
- 1960s ~1980s: 基于规则的方法

- 1990~2013: 统计NLP方法
- 2013~: 深度学习方法


学科的产生与发展



- ~1950s: 基于模板的NLP方法
- 1960s ~1980s: 基于规则的方法

- 1990~2013: 统计NLP方法
- 2013~: 深度学习方法

学科的产生与发展



- ~1950s: 基于模板的NLP方法
- 1960s ~1980s: 基于规则的方法


- 1990~2013: 统计NLP方法
- 2013~: 深度学习方法

本章内容

- 问题的提出
- 基本概念
- 学科的产生与发展
- 研究内容
- 面临的问题与挑战
- 基本方法与技术现状


研究内容

- 根据研究目标的不同大致可分为以下三类



研究内容

- 自然语言处理旨在让机器理解人类语言的语义信息
 - 本质是从无结构的文本中抽取出结构化的语义信息



应用

信息抽取
机器翻译
自动问答
情感分析
.....

{ 这, 是, 语法树 }

研究内容

- 根据建模方式的不同大致可分为以下四类

分类

文本分类

情感分类

文本匹配

文本蕴涵

序列标注

中文分词

词性标注

信息抽取

槽位填充

生成

机器翻译

文本摘要

风格迁移

自动问答

对话系统

结构预测

序列分割



句子分割

段落分割

句法分析


研究内容

- 分类
 - 文本分类





研究内容

- 分类
 - 情感分类



研究内容

- 序列标注
 - 信息抽取



知识图谱

研究内容

- 生成
 - 机器翻译

英文输入

Two field measurements for atmospheric fine particles were conducted in Baoan district of Shenzhen during the summer and winter in 2004.

中文翻译

2004年夏季和冬季在深圳市宝安区对大气细颗粒物进行了两次实地测量。

谷歌翻译

大气细颗粒两个现场测量在深圳市宝安区2004夏季和冬季期间进行。

百度翻译

2004宝安区深圳夏季和冬季大气细颗粒物的两场测量。

有道翻译

两个大气细粒子进行了实地测量在深圳宝安区2004年夏季和冬季。

研究内容

- 生成
 - 文本摘要

人民网内容科技应用层根据业务可以划分为四个部分。第一是内容原创。尽管媒体行业现在已经可以实现机器人写稿、虚拟主播等技术，但我认为短期内机器人不太可能完全取代人类从事深度报道、政策解读、新闻评论等内容的创作。第二是内容风控。我们和一些互联网公司合作，凭借人民网过硬的内容把关能力和风控体系，帮助他们有效地把控风险。第三是内容聚合与分发。目前绝大多数内容聚合分发平台采用“家乐福模式”、“沃尔玛模式”，所有品牌厂商把商品聚集在大型超市，由大型超市统一售卖和收银，如微信公众号和今日头条，就是这样的模式。最后是内容运营。即把我们在内容方面的策划、创意、制作、分发、运营能力，输送给政府机关、企事业单位和合作伙伴，帮其运营网站、客户端及各类账号平台，做好与群众、用户之间的互动



人民网内容科技应用层根据业务可以划分为四个部分。第一是内容原创。第二是内容风控。第三是内容聚合与分发。最后是内容运营。

研究内容


- 生成
 - 自动问答



阿里小蜜




闲聊小蜜



店小蜜

研究内容

- 结构预测
 - 依存句法分析



Root（核心词）和买（修饰词）之间存在依存关系HED（核心关系）

小王（修饰词）和买（核心词）之间存在依存关系SBV（主谓关系）

买（核心词）和电脑（修饰词）之间存在依存关系VOB（动宾关系）

研究内容

❖ 语音识别 (Automatic Speech Recognition, ASR)

将输入语音信号自动转换成书面文字。

— 应用：文字录入、人机通讯、语音翻译等。

❖ 文语转换 / 语音合成 (text-to-speech synthesis)

将书面文本自动转换成对应的语音表征。

— 应用：朗读系统、人机交互等。

❖ 说话人识别 (speaker recognition / identification / verification)

根据部分言语样品确定或验证说话人身份。

— 应用：信息安全、防伪等。

研究内容

- 说明

由于不同的研究方向所关注的侧重点不同，因此，一般将语音识别、语音合成和说话人识别等以语音信号为主要研究对象的语音技术独立出来，而其他以文本(词汇/句子/篇章等)为主要处理对象的研究内容作为自然语言处理的主体。

文字识别更多地涉及图像识别与理解的问题。信息检索与自然语言处理之间既有密切关联，又各自相对独立，我们暂且回避它们之间关系的争论。

本章内容

- 问题的提出
- 基本概念
- 学科的产生与发展
- 研究内容
- 面临的问题与挑战
- 基本方法与技术现状

面临的问题与挑战

- 基本问题之一：形态学 (Morphology) 问题

研究词 (word) 是如何由有意义的基本单位——词素 (morphemes) 构成的。

屈折语的形态变化和单词的识别 / 汉语等分词问题。

词素：词根、前缀、后缀、词尾

例如：老虎 ← 老 + 虎

图书馆 ← 图 + 书 + 馆

re + ex + port → reexport

面临的问题与挑战

- 基本问题之二：句法 (Syntax) 问题

研究句子结构成分之间的相互关系和组成句子的序列的规则。

为什么一句话可以这么说也可以那么说？

如何建立快速有效的句子结构分析方法？

苹果，我吃了。

我吃了苹果。

≠ 苹果吃了我。

面临的问题与挑战

- 基本问题之三：语义学 (Semantics) 问题

研究如何从一个语句中词的意义，以及这些词在该语句中句法结构中的作用来推导出该语句的意义。

这句话说了什么？

(1) 这个人真牛

(2) 火烧圆明园

(3) 火烧驴肉

面临的问题与挑战

- 基本问题之四：语用学 (Pragmatics) 问题

研究在不同上下文中语句的应用以及上下文对语句理解所产生的影响。从狭隘语言学观点看，语义学处理的是语言结构中有形式体现的那些语境。相反，语用学最宽泛的定义是研究语义学未能涵盖的那些意义。

为什么要说这句话？

灵魂八问

(1) 火，火！

(2) 看看鱼怎么样了？

配钥匙师傅：你配吗？

食堂阿姨：你要饭吗？

算命先生：你算什么东西？

快递小哥：你是什么东西？

上海垃圾分拣阿姨：你是什么垃圾？


滴滴司机：你搞清楚你自己的定位了么？

理发师傅：你自己照照镜子看看你自己，觉得还行么？

小区保安：你是谁？你从哪里来？要到哪里去？

面临的问题与挑战

- 基本问题之五：语音学 (Phonetics) 问题
研究语音特性、语音描述、分类及转写方法等。



面临的问题与挑战

- 困难之一：大量歧义 (ambiguity) 现象

- ❖ 词法歧义

例如：(1) I'll see Prof. Zhang home.

(2) 南京市长江大桥

南京市 / 长江 / 大桥 /

南京市 / 长江大桥 /

南京市长/江大桥 /

(3) 门把手弄坏了

门 / 把 / 手 / 弄 / 坏 / 了

门把手 / 弄 / 坏 / 了

面临的问题与挑战

- 文章标题中的歧义比比皆是：
 - 上大学子烛光追思钱伟长 (<http://www.sina.com.cn/>, 2010.8.8)
 - 教育部长跑活动负责人与商家总经理被曝系师生
(科学网: <http://news.sciencenet.cn/>, 2010-11-14)



面临的问题与挑战

❖ 词性歧义

①介词：像，好似； ②动词：喜欢



(1) Time flies like an arrow.



①动词：飞，飞翔，飞驰

②名词：苍蝇，飞虫

✧ 时间像箭一样飞驰（光阴似箭）。

✧ 时间苍蝇喜欢箭（有一种苍蝇叫“时间”）。

(2) 美国环境保护警察

——《现代世界警察》2022年01期

面临的问题与挑战

❖ 结构歧义

1. 喜欢乡下的孩子
2. 关于鲁迅的文章
3. 今天中午吃馒头
4. 今天中午吃食堂
5. 今天中午吃大碗
6. 今天中午吃了闭门羹
7. 写文章 / 写黑板

面临的问题与挑战

8. I saw a man with a telescope.

→ I saw [a man with a telescope].
I [saw a man] with a telescope.

→ I saw a man with a telescope in the park. ?

英语句子歧义组合的开塔兰数(Catalan Numbers) C_n :

$$C_n = \binom{2n}{n} \frac{1}{n+1} \quad \text{其中: } \binom{2n}{n} = \frac{(2n)!}{n! \times n!}$$

n 为句子中介词短语的个数。

面临的问题与挑战

❖ 语义歧义

小明说:“小红这个人真有意思(funny)”。小红说:“小明这个人怪有意思的(funny)”。于是人们以为他们有了意思(wish), 并让小明向小红意思意思(express)。小明火了:“我根本没有那个意思(thought)”! 小红也生气了:“你们这么说是什么意思(intention)”? 事后有人说:“真有意思(funny)”。也有人说:“真没意思(nonsense)”。

— 《生活报》1994. 11. 13. 第6版

人们的语言表达中大量地使用缩略语和隐喻的表达方式, 例如: 要把权力装进制度的笼子; 老虎苍蝇一起打; 消灭一切牛鬼蛇神。

面临的问题与挑战

❖ 语音歧义：同音词

施氏食狮史

石室诗士施氏，嗜狮，誓食十狮。施氏时时适市视狮。十时，适十狮适市。是时，适施氏适市。施氏视是十狮，恃矢势，使是十狮逝世，氏拾是十狮尸，适石室。石室湿，氏使侍拭石室，石室拭，氏始试食是十狮尸，食时，始识是十狮尸，实十石狮尸。试释是事。

(百度百科)



赵元任(1892-1982)

1892年11月3日生于天津。1914年获康奈尔大学数学学士学位。1918年获哈佛大学哲学博士学位。1919年任康奈尔大学物理学讲师。1920年回国任清华学校心理学及物理学教授。1921年再入哈佛大学研习语音学，任哈佛大学哲学系讲师、中文系教授。与梁启超、王国维、陈寅恪并称为清华“四大导师”。1938~41年先后执教于夏威夷大学、耶鲁大学，之后任教于哈佛大学。1947~62，任教于伯克利加州大学，讲授中国语文和语言学。1982年2月24日逝世，享年90岁。

面临的问题与挑战

❖ 多音字及韵律等歧义

— 一字多音

例如：尾巴、亲家、削铅笔、一行

— 韵律、声调、语气、重音

例如：药材好药才好

他的钱包被偷了

今日说法 / 《幸福里的故事》 / 聊吧 / 说吧

面临的问题与挑战

- 困难之二：大量未知语言现象

- 新词、人名、地名、术语等

如：奥特、给力、内卷；非典、新冠肺炎；夏天、高山、温馨、温泉、时光、平安、田野、边疆、程序、吉林、桂林；

- 新含义

如：苹果、奔腾、小姐、老虎、苍蝇

- 新用法和新句型等，尤其在口语中或部分网络语言中，不断出现的一些“非规范的”新的语句结构。

如：被长工资，很中国，百度一下
组内计算资源很充足，来就对了捏

面临的问题与挑战

• 困难之二：大量未知语言现象

Be Appropriate and Funny: Automatic Entity Morph Encoding

Boliang Zhang¹, Hongzhao Huang¹, Xiaoman Pan¹, Heng Ji¹, Kevin Knight²
Zhen Wen³, Yizhou Sun⁴, Jiawei Han⁵, Bulent Yener¹

¹Computer Science Department, Rensselaer Polytechnic Institute

²Information Sciences Institute, University of Southern California

³IBM T. J. Watson Research Center

⁴College of Computer and Information Science, Northeastern University

⁵Computer Science Department, University of Illinois at Urbana-Champaign

¹{zhangb8, huangh9, panx2, jih, yener}@rpi.edu, ²knight@isi.edu

³zhenwen@us.ibm.com, ⁴yzsun@ccs.neu.edu, ⁵hanj@illinois.edu

Abstract

Internet users are keen on creating different kinds of *morphs* to avoid censorship, express strong sentiment or humor. For example, in Chinese social media, users often use the entity morph “方便面 (*Instant Noodles*)” to refer to “周永康 (*Zhou Yongkang*)” because it shares one character “康 (*Kang*)” with the well-known brand of instant noodles “康师傅 (*Master Kang*)”. We developed a wide variety of novel approaches to automatically encode proper and interesting morphs, which can effectively pass decoding tests¹.

1 Introduction

One of the most innovative linguistic forms in so-

- “天线 (*Antenna*)” refers to “温家宝 (*Wen Jiabao*)” because it shares one character “宝 (*baby*)” with the famous children’s television series “天线宝宝 (*Teletubbies*)”;

In contrast with covert or subliminal channels studied extensively in cryptography and security, *Morphing* provides confidentiality against a weaker adversary which has to make a real time or near real time decision whether or not to block a morph within a time interval t . It will take longer than the duration t for a morph decoder to decide which encoding method is used and exactly how it is used; otherwise adversary can create a codebook and decode the morphs with a simple look up. We note that there are other distinct characteristics of morphs that make them different from cryptographic constructs: (1) Morphing can be consid-

1 Introduction

One of the most innovative linguistic forms in social media is *Information Morph* (Huang et al., 2013). Morph is a special case of alias to hide the original objects (e.g., sensitive entities and events) for different purposes, including avoiding censorship (Bamman et al., 2012; Chen et al., 2013), expressing strong sentiment, emotion or sarcasm, and making descriptions more vivid. Morphs are widely used in Chinese social media. Here is an example morphs: “由于瓜爹的事情，方便面与天线摊牌. (Because of *Gua Dad*’s issue, *Instant Noodles* faces down with *Antenna*).”, where

- “瓜爹 (*Gua Dad*)” refers to “薄熙来 (*Bo Xilai*)” because it shares one character “瓜 (*Gua*)” with “薄瓜瓜 (*Bo Guagua*)” who is the son of “薄熙来 (*Bo Xilai*)”;
- “方便面 (*Instant Noodles*)” refers to “周永康 (*Zhou Yongkang*)” because it shares one character “康 (*kang*)” with the well-known instant noodles brand “康师傅 (*Master Kang*)”;

¹The morphing data set is available for research purposes: <http://nlp.cs.rpi.edu/data/morphencoding.tar.gz>

of morphs that make them different from cryptographic constructs: (1) Morphing can be considered as a way of using natural language to communicate confidential information without encryption. Most morphs are encoded based on semantic meaning and background knowledge instead of lexical changes, so they are closer to Jargon. (2) There can be multiple morphs for an entity. (3) The Shannon’s Maxim “the enemy knows the system” does not always hold. There is no common code-book or secret key between the sender and the receiver of a morph. (4) Social networks play an important role in creating morphs. One main purpose of encoding morphs is to disseminate them widely so they can become part of the new Internet language. Therefore morphs should be interesting, fun, intuitive and easy to remember. (5) Morphs rapidly evolve over time, as some morphs are discovered and blocked by censorship and newly created morphs emerge.



We propose a brand new and challenging research problem - can we automatically encode morphs for any given entity to help users communicate in an appropriate and fun way?

706

Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Short Papers), pages 706–711, Baltimore, Maryland, USA, June 23–25 2014. ©2014 Association for Computational Linguistics

面临的问题与挑战

- 困难之三：语义组合与新概念的产生

$$\begin{cases} \text{蓝} + \text{天} \neq \text{蓝天} \\ \text{白} + \text{云} \neq \text{白云} \end{cases}$$
$$\begin{cases} \text{疾} + \text{病} \approx \text{疾病} \\ \text{图} + \text{书} \approx \text{图书} \end{cases}$$


面临的问题与挑战

$$\begin{array}{ccc} \text{火} & & \text{药} & & \text{火药} \\ \begin{bmatrix} 0.15 \\ \cdot \\ \cdot \\ \cdot \\ 0.21 \end{bmatrix} & \text{?} & \begin{bmatrix} 0.23 \\ \cdot \\ \cdot \\ \cdot \\ 0.19 \end{bmatrix} & = & \begin{bmatrix} 0.18 \\ \cdot \\ \cdot \\ \cdot \\ 0.06 \end{bmatrix} \\ \text{山} & \oplus & \text{药} & = & \text{山药 ?} \end{array}$$

语义计算不是简单的数字运算，也不是逻辑运算，更不是“赌徒式”的概率推算，而应该是可以追踪、可以解释、可以举一反三和产生新概念的新的运算系统。


面临的问题与挑战

归纳起来，HLT所面临的挑战：

- 普遍存在的不确定性：词法、句法、语义、语用和语音各个层面。
- 未知语言现象的不可预测性：新的词汇、新的术语、新的语义和非规范语法等现象无处不在。
- 始终面临着数据不充分性：有限的语言集合无法涵盖开放的语言现象。
- 知识表示的复杂性：语义知识的模糊性和错综复杂的关联性难以用常规方法有效地描述，为语义计算带来了极大的困难。

面临的问题与挑战


- 机器翻译中映射单元的不对等性：词法表达不相同、句法结构不一致、语义概念不对等。



从大量复杂多样的不确定性中寻找确定性结论

面临的问题与挑战

- 人脑理解语言是一个复杂的思维过程
 - 语言学、心理学
 - 逻辑学、认知科学
 - 计算机科学
 - 统计学、系统论
 - 背景知识、常识等
 -




本章内容

- 问题的提出
- 基本概念
- 学科的产生与发展
- 研究内容
- 面临的问题与挑战
- 基本方法与技术现状

基本方法与技术现状

1. 基本方法



基本方法与技术现状

- 理性主义：通过对一些代表性词语或语言现象的研究得到对人的语言能力的认识，归纳语言使用的规律，以此分析，推断测试样本的预期结果。
 - 问题求解的基本思路：基于规则的分析方法建立符号处理系统。
 - 规则库的开发： $N + N \rightarrow NP$
 - 词典标注：#工作，N(uc)；V；
 - 推到算法设计：归纳、推导、歧义消解方法…

知识库 + 推理系统 → NLP 系统
理论基础：Chomsky 的文法理论

基本方法与技术现状

- 经验主义：利用大规模真实语言数据，借助人的帮助（标注数据和筛选特征等），统计发现语言使用的规律及其可能性（概率）大小，以此为依据计算预测测试样本的可能结果。统计单元是离散事件（词、短语、词性等）。
 - 问题求解的思路：基于大规模真实数据建立计算模型。
 - 大规模真实数据的收集、标注：真实性、代表性、标注信息…
 - 模型构建：模型的复杂性、有效性、参数训练方法…

标注语料库 + 统计模型 → NLP 系统
理论基础：统计学、信息论、机器学习

基本方法与技术现状

- 连结主义：利用大规模真实语言数据构建模型，统计发现语言使用的规律及其可能性（概率）大小，以此为依据计算预测测试样本的可能结果。统计单元采用连续的实数空间表示（向量）。

语料库 + 神经网络 + 统计模型 → NLP 系统
理论基础：统计学、深度学习

基本方法与技术现状

以机器翻译为例

给定英语句子：

There is a book on the desk.

将其翻译成汉语。


基本方法与技术现状

➤ 基于规则的方法

(1) 对英语句子进行词法分析


There/Ad is/V_{be} a/Det book/N on/P the/Det desk/N./Puc

(2) 对英语句子进行句法结构分析




基本方法与技术现状

(3) 利用转换规则将英语句子结构转换成汉语句子结构




基本方法与技术现状

(3) 利用转换规则将英语句子结构转换成汉语句子结构




基本方法与技术现状

(3) 利用转换规则将英语句子结构 转换成汉语句子结构



基本方法与技术现状

(4) 根据转换后的句子结构，
利用词典和生成规则生成译文



#a, Det, 一

#book, N, 书; V, 预定

#desk, N, 桌子

#on, P, 在 X 上

#There be, V, 有

输出译文:

在桌子上有一本书。



桌子上有一本书。


基本方法与技术现状

- 方法评价:

- **优点**: 可以较好地保持原文的结构, 产生的译文结构与原文的结构关系密切, 尤其对于语言现象已知的或句法结构规范的源语言语句具有较强的处理能力和较好的翻译效果。
- **弱点**: 规则一般由人工编写, 工作量大, 主观性强, 一致性难以保障, 不利于系统扩充, 对非规范语言现象缺乏相应的处理能力。

基本方法与技术现状

➤ 数据驱动的翻译方法（SMT和NMT）



基本方法与技术现状

≡ training.txt X

E: > dataset > cmn-eng-simple > cmn-eng-simple > ≡ training.txt

```
1  it 's none of your concern .    这不关 你 的 事 。
2  she has a habit of bi@@ ting her na@@ ils .    她有 咬 指甲 的 习惯 。
3  he is a teacher .    他 是 老师 。
4  japan re@@ lies on ar@@ a@@ b countries for oil .    日本 靠 阿拉伯 国家 提供 石油 。
5  i 'll dream about you .    我会 梦到 你 的 。
6  i borrowed tom 's phone this morning .    我 今天 早上 跟 Tom 借手机 。
7  she does n't know how to play golf .    她 不 知道 怎么 打 高尔夫球 。
8  tears ro@@ lled down my chee@@ ks .    泪水 沿着 我 的 面颊 流 了 下来 。
9  that 's soft .    这 很 软 。
10 do n't open this door , please .    请 不要 打开 此门 。
11 what exactly does tom do ?    汤姆 究竟 在 做 什么 ?
12 there 's a book here .    这里 有 一 本 书 。
13 tom was the first to rea@@ ct .    汤姆 是 最先 作出 反应 的 。
14 i 'm going to check out at eight .    我 会 在 八点钟 的 时候 登出 。
15 is this your notebook ?    这 是 你 的 书 吗 ?
16 how could things get worse ?    事情 怎么 变糟 的 ?
17 i hope this is the right one .    我 希望 这 是 对 的 。
18 i play tennis an hour a day .    我 每天 打 一 小时 网球 。
19 we still have more time .    我们 仍然 有 更 多 的 时间 。
20 all my friends will be there .    我 所有 的 朋友 都 会 到 那 儿 。
```

基本方法与技术现状

(a) 统计机器翻译方法

给定源语言句子: $E = e_1^m \equiv e_1 e_2 \wedge e_m$

将其翻译成目标语言句子: $C = c_1^l \equiv c_1 c_2 \wedge c_l$

根据贝叶斯公式: $P(C|E) = \frac{P(C)P(E|C)}{P(E)}$

求解使 P
值最大的 C

$$\hat{C} = \arg \max_C P(C)P(E|C)$$

语言模型
(Language Model, LM)

翻译模型
(Translation Model, TM)

基本方法与技术现状

构建解码器 (decoder), 快速搜索最优译文候选:



三个关键问题:

- 估计语言模型概率 $P(C)$
- 估计翻译模型概率 $P(E|C)$
- 快速有效地搜索候选译文 C , 使 $P(C) \times P(E|C)$ 最大。

主要任务:

- (1) 收集大规模双语句子对、目标语言句子
- (2) 参数训练与模型优化

基本方法与技术现状

(b) 神经机器翻译方法

给定源语言句子: $E = e^m = e_1 e_2 \wedge e_m$

将其翻译成目标语言句子: $C = c_1^l \equiv c_1 c_2 \wedge c_l$


词汇向量化表示: Word2Vec

$$P(c_i) \approx P(c_i | c_1 \dots c_{i-1}, \mathbf{E})$$

$$\text{目标函数: } L = \sum_i \log(P(c_i | c_1 \dots c_{i-1}, \mathbf{E}))$$

基本方法与技术现状

$$h_t = \tanh(W \cdot x + U \cdot h_{t-1} + b)$$




Transformer的核心是注意力机制，包括自注意力 (self-attention) 和跨语言注意力 (cross-language-attention)

基本方法与技术现状

- 方法评价:

- **优点**: 一般不需要对源语言句子进行深层次分析, 甚至对源语言没有任何基本知识, 只要有足够多的双语言句对就可以建立一个机器翻译系统。
- **弱点**: 对于某些语言对来说, 收集高质量大规模的双语句对并不是一件容易的事情; 机器翻译过程和译文结果缺乏解释性; 对于结构复杂的句子、生僻词汇、指代、译文一致性等问题缺乏有力的处理手段。

基本方法与技术现状



基本方法与技术现状

已取得较好性能

Spam email detection

Let's go to Agra!



Buy V1AGRA ...



Part-of-speech (POS) tagging

ADJ ADJ NOUN VERB ADV

Colorless green ideas sleep furiously.

Named entity recognition (NER)

PERSON ORG LOC

Einstein met with UN officials in Princeton

已取得较大进展

Sentiment analysis

Best roast chicken in San Francisco!



The waiter ignored us for 20 minutes.



Coreference resolution

Carter told Mubarak he shouldn't run again.

Word sense disambiguation

I need new batteries for my *mouse*.



Parsing

I can see Alcatraz from the window!

Machine translation (MT)

第13届上海国际电影节开幕...



The 13th Shanghai International Film Festival...

Information extraction (IE)

You're invited to our dinner party, Friday May 27 at 8:30



Party
May 27
add

仍存在很大挑战

Question answering (QA)

Q. How effective is ibuprofen in reducing fever in patients with acute febrile illness?

Paraphrase

XYZ acquired ABC yesterday

ABC has been taken over by XYZ

Summarization

The Dow Jones is up

The S&P500 jumped

Housing prices rose



Economy is good

Dialog

Where is Citizen Kane playing in SF?



Castro Theatre at 7:30. Do you want a ticket?



基本方法与技术现状

- 现状归纳：

- 部分问题得到了解决，可以为人们提供辅助性帮助，如：机器翻译、电子词典、搜索引擎、文字录入、语音识别等；
- 基础问题研究仍任重而道远，如：语义表示和计算、高质量的自动翻译等；
- 社会需求日益迫切：个性化信息服务、网络内容管理、国家安全等；
- 许多技术离真正实用的目标还有相当的距离，尚未建立起有效、完善的理论体系。

本章小节

- 基本概念： NLU、CL、NLP、HLT
- 学科的产生与发展： 1947, 1966, 1980s, 1990s, 2013/4...
- 研究内容： 机器翻译、信息检索...
- 问题与挑战： 从词法、句法、语义到语用，普遍存在的歧义、未知语言现象、知识表示 ...
- 研究方法： 理性主义、经验主义和连结主义方法
- 技术现状： 硕果累累，仍任重道远
- 参考文献： 三本书

课后思考

1-1. 请说明如下句子有多少种不同的含义？

- He drew one card.
- 咬死猎人的狗。
- 这座碑是为纪念反对共产主义者叛乱中牺牲的英雄而建立的。
(摘自马来西亚旅游介绍资料)

1-2. 试比较汉英句子中地点状语位置的差异。

1-3. 下列语言中哪些为自然语言？ 世界语、C语言、鸟语、甲骨文



欢迎提问！