



自然语言处理

9. 信息抽取

虞剑飞

南京大学智能科学与技术学院

2025.5.14

本章内容


- 概述
- 命名实体识别
- 实体消歧
- 关系抽取
- 事件抽取

本章内容

- 概述
- 命名实体识别
- 实体消歧
- 关系抽取
- 事件抽取


概述

- 为什么要信息抽取？
 - 互联网的普及和迅速发展
 - 信息资源极大丰富
 - 但“信息过载”问题日趋严重
 - 迫切需要快速、准确获取信息的技术手段
 - 信息抽取技术应运而生
 - 文本信息抽取
 - 自然语言（非结构化）文本信息抽取




概述

• 信息抽取与信息检索的区别 (1/2)



互联网文档集合

信息检索



迈克尔·乔丹- 维基百科，自由的百科全书

<https://zh.wikipedia.org/zh/迈克尔·乔丹> ▼ Translate this page

麥可·傑佛瑞·喬丹（英語：Michael Jeffrey Jordan，1963年2月17日－）是美國退役NBA職業籃球運動員，也是一名商人，現任夏洛特黃蜂董事長及主要股東。職業生涯 ...
夏洛特黃蜂 以賽亞·湯瑪斯 馬庫斯·喬丹 芝加哥公牛

迈克尔·乔丹_百度百科

<https://baike.baidu.com/item/乔丹> ▼ Translate this page

2003年4月16日，迈克尔·乔丹在职业生涯最后一场奇才主场对阵76人比赛的赛后正式宣布退役。他被认为历史上最伟大的篮球运动员，他的23号球衣分别被公牛队 ...

所属运动队：已退役

出生地：美国纽约市布鲁克林区

出生日期：1963年2月17日 专业特点：得分、防守、领导能力超强

迈克尔·乔丹到底有多伟大？ - 知乎

<https://www.zhihu.com/question/50457536> ▼ Translate this page

Sep 9, 2016 - 得出的结论是没法比比不过不是一个量级的球员乔丹自己是一档其他球员爱怎么比怎么比跟乔丹比只能比一些细微的数据那种单场的细枝末节的。

篮球之神乔丹的实力是否真的无法触及？ 35 answers Feb 28, 2018

乔丹为什么难防？ 35 answers Sep 28, 2015

为什么乔丹是篮球之神？ 10 answers Jun 19, 2015

说说迈克尔·乔丹的缺点？ 14 answers Jan 19, 2015

More results from www.zhihu.com

NBA50大巨星之乔丹：当之无愧的篮球之神_NBA中国官方网站 - 腾讯

nbachina.qq.com/a/20150924/070975.htm ▼ Translate this page

Sep 24, 2015 - 论得到的欢呼与赞誉而言，迈克尔·乔丹是篮球史上最伟大的球员。我们对某人生涯和影响力的评价永远难以符合所谓客观，我们只知道，乔丹是一名 ...

飞人乔丹：就这样不小心赚了10亿刀_腾讯财经_腾讯网

finance.qq.com/original/MissMoney/mm008.html ▼ Translate this page

Oct 15, 2015 - 如果你仅仅把乔丹定位成一名篮球运动员，那你就大错特错了。事实上，NBA的收入在乔丹的“资产帝国”中，不值一提。

图9.1 信息检索示例

概述

- 信息抽取与信息检索的区别 (2/2)




图9.2 信息抽取示例

概述

- 信息抽取定义(Grishman, 1997)
 - 从自然语言文本中抽取指定类型的实体、关系、事件等事实信息，并形成结构化数据输出的文本处理技术
 - 目标：从非结构化的文本内容中提取特定的信息。




- 应用
 - 在阅读理解、机器翻译、知识图谱等任务中都发挥着非常基础和重要的作用

概述

- 信息抽取的主要任务
 - 命名实体识别（Named Entity Recognition, NER）
 - 实体链接（Entity Linking, EL）
 - 关系抽取（Relation Extraction, RE）
 - 事件抽取（Event Extraction）
 - 时间表达式识别（Temporal Expression）
 - 模板填充（Template Filling）
 - 话题检测与跟踪（Topic Detection and Tracking, TDT）

概述

- 信息抽取的主要任务



事件类型	发布会
时间	北京时间9月13日
公司	苹果公司
地点	史蒂夫·乔布斯剧院
人员	蒂姆·库克
产品	Iphone13、Apple TV
实体关系	苹果公司，蒂姆·库克，CEO

图9.3 非结构化文本信息抽取样例

概述

• 信息抽取的发展简史




图9.4 信息抽取发展历程

概述

- 信息抽取的发展简史
 - MUC (Message Understanding Conference)
 - 由美国国防高级研究计划局DARPA资助
 - 命名实体识别、共指消解和基于模板的关系抽取等任务
 - 1987年-1997年，以英文为主，后两期扩展到中文
 - ACE (Automatic Content Extraction)
 - 由美国国家标准与技术研究所NIST举办
 - 命名实体识别、关系抽取和事件抽取等任务
 - 1999年-2008年，关注英文、中文和阿拉伯文等
 - TAC-KBP (Knowledge Base Population)
 - NIST主办，2009年至今，关注实体链接、属性抽取等

本章内容

- 概述
- 命名实体识别
 - 定义
 - 典型方法
 - 自动评价
- 实体消岐
- 关系抽取
- 事件抽取

命名实体识别定义


- 命名实体识别

- 信息抽取的一项基础任务
- 自动识别出文本中指定类别的实体，包括人名、地名、机构名、日期、时间和货币等七类
- 人名（例如“乔布斯”）、地名（例如“北京”）、组织机构名（例如“中国科学院”）、时间（例如“10点30分”）、日期（例如“2017年6月1日”）、货币（例如“1000美元”）、百分比（例如“百分之五十”）
- 由于时间、日期、货币和百分比规则性强，利用模板或正则表达式基本可处理
- 人名、地名和组织机构名是关注重点

命名实体识别定义

- 命名实体识别

- 包含两个任务：实体检测和实体分类
- 实体检测：检测出文本中哪些词串属于实体，也即发现实体的左边界和右边界
- 实体分类：判别检测出的实体具体属于哪个类别



命名实体识别定义

- 命名实体识别

- 基准数据集：CoNLL 2003

Dataset	Category	Train	Dev	Test
CoNLL 2003	PER	6600	1842	1617
	LOC	7140	1837	1668
	ORG	6321	1341	1661
	MISC	3438	922	702

- 其他数据集：ACE03/04/05

Type	Subtypes
FAC (Facility)	Airport, Building-Grounds, Path, Plant, Subarea-Facility
GPE (Geo-Political Entity ³)	Continent, County-or-District, GPE-Cluster, Nation, Population-Center, Special, State-or-Province
LOC (Location)	Address, Boundary, Celestial, Land-Region-Natural, Region-General, Region-International, Water-Body
ORG (Organization)	Commercial, Educational, Entertainment, Government, Media, Medical-Science, Non-Governmental, Religious, Sports
PER (Person)	Group, Indeterminate, Individual
VEH (Vehicle)	Air, Land, Subarea-Vehicle, Underspecified, Water
WEA (Weapon)	Biological, Blunt, Chemical, Exploding, Nuclear, Projectile, Sharp, Shooting, Underspecified

表9.1 ACE05数据集中的命名实体类别

本章内容

- 概述
- 命名实体识别
 - 定义
 - 典型方法
 - 基于规则的方法
 - 基于有监督的机器学习方法
 - 自动评价
- 实体消歧
- 关系抽取
- 事件抽取

基于规则的命名实体识别

- 人名

- 以汉语为例，可借助姓氏和名字用字词典，结合称谓等线索词识别大部分的人名
- 常见的姓氏用字300个左右，并且据统计前十位频率最高的姓氏用字（“李、王、张、刘、陈、杨、赵、黄、周、吴”）占据约40%
- 常用名字用字为1000个左右
- 称谓：“先生”、“女士”、“局长”和“教授”等
- 特殊线索词：“说”、“指出”和“表示”等

基于规则的命名实体识别

- 地名和组织机构名
 - 多组织机构名以“大学”、“公司”、“集团”和“中心”等词语结尾
 - 很多地名以“市”、“县”、“镇”、“乡”和“街道”等词语结尾
 - 右边界明显，但左边界模糊
 - 往往收集一个机构名库和地名库成为一个比较务实的解决方案


规则方法的不足

- 一个实体属于多个类别
 - “沈阳”、“中山”等
- 既是普通词也是实体
 - “高山”、“高峰”等
- 实体缩写变化多、嵌套情形复杂
 - “中国科学院”、“中科院”、“中国人民大学”、“人大”、“全国人民代表大会”等
 - “中国人民大学附属中学”、“人大附小”
- 新的命名实体层出不穷

本章内容

- 概述
- 命名实体识别
 - 定义
 - 典型方法
 - 基于规则的方法
 - 基于有监督的机器学习方法
 - 自动评价
- 实体消岐
- 关系抽取
- 事件抽取

基于有监督的机器学习方法



基于有监督的机器学习方法

事件发生在武汉市/LOC 的界限路/LOC。
陈明亮/PER 是一所小学的校长。
北京市发改委/ORG 出台了政策。
国科大/ORG 是最近新成立的一所大学。
... ..

↓ 机器学习

命名实体
识别模型



谷 歌 C E O 拉 里 佩 奇 领 导 了 交 易




谷 歌 C E O 拉 里 佩 奇 领 导 了 交 易

机构名

人名

训练数据格式化

事件发生在武汉市/LOC 的界限路/LOC。
陈明亮/PER 是一所小学的校长。
北京市发改委/ORG 出台了政策。
国科大/ORG 是最近新成立的一所大学。
... ..




转换为基于字的序列标注问题

事/O 件/O 发/O 生/O 在/O 武/LOC-B 汉/LOC-I 市/LOC-I 的/O 界/LOC-B 限/LOC-I 路/LOC-I。
陈/PER-B 明/PER-I 亮/PER-I 是/O 一/O 所/O 小/O 学/O 的/O 校/O 长/O。
北/ORG-B 京/ORG-I 市/ORG-I 发/ORG-I 改/ORG-I 委/ORG-I 出/O 台/O 了/O 政/O 策/O。
国/ORG-B 科/ORG-I 大/ORG-I 是/O 最/O 近/O 新/O 成/O 立/O 的/O 一/O 所/O 大/O 学/O。
... ..

命名实体识别-测试

谷 歌 C E O 拉 里 佩 奇 领 导 了 交 易



命名实体识别模型

ORG-B	ORG-I	O	O	O	PER-B	PER-I	PER-I	PER-I	O	O	O	O	O
谷	歌	C	E	O	拉	里	佩	奇	领	导	了	交	易

本章内容

- 概述
- 命名实体识别
 - 定义
 - 典型方法
 - 基于规则的方法
 - 基于有监督的机器学习方法
 - 基于隐马尔科夫模型的命名实体识别
 - 基于条件随机场的命名实体识别
 - 基于深度神经网络的命名实体识别
 - 自动评价
- 实体消岐
- 关系抽取
- 事件抽取

基于CNN的命名实体识别

A Unified Architecture for Natural Language Processing: Deep Neural Networks with Multitask Learning

Ronan Collobert
Jason Weston

NEC Labs America, 4 Independence Way, Princeton, NJ 08540 USA

COLLOBER@NEC-LABS.COM
JASONW@NEC-LABS.COM

Journal of Machine Learning Research 12 (2011) 2493-2537

Submitted 1/10; Revised 11/10; Published 8/11

Abstract

We describe a single convolutional neural network architecture that, given a sentence, outputs a host of language processing predictions: part-of-speech tags, chunks, named entity tags, semantic roles, semantically similar words and the likelihood that the sentence makes sense (grammatically and semantically) using a language model. The entire network is trained *jointly* on all these tasks using weight-sharing, an instance of *multitask learning*. All the tasks use labeled data except the language model which is learnt from unlabeled text and represents a novel form of *semi-supervised learning* for the shared tasks. We show how both *multitask learning* and *semi-supervised learning* improve the generalization of the shared tasks, resulting in state-of-the-art performance.

1. Introduction

The field of Natural Language Processing (NLP) aims to convert human language into a formal representation that is easy for computers to manipulate. Current end applications include information extraction, machine translation, summarization, search and human-computer interfaces.

While complete semantic understanding is still a far-distant goal, researchers have taken a divide and conquer approach and identified several sub-tasks useful for application development and analysis. These range from the syntactic, such as part-of-speech tagging, chunking and parsing, to the semantic, such as word-sense disambiguation, semantic-role labeling, named entity extraction and anaphora resolution.

Appearing in *Proceedings of the 25th International Conference on Machine Learning*, Helsinki, Finland, 2008. Copyright 2008 by the author(s)/owner(s).

Currently, most research analyzes those tasks *separately*. Many systems possess few characteristics that would help develop a unified architecture which would presumably be necessary for deeper semantic tasks. In particular, many systems possess three failings in this regard: (i) they are *shallow* in the sense that the classifier is often linear, (ii) for good performance with a linear classifier they must incorporate many hand-engineered features specific for the task; and (iii) they cascade features learnt separately from other tasks, thus propagating errors.

In this work we attempt to define a unified architecture for Natural Language Processing that *learns features* that are relevant to the tasks at hand given very limited prior knowledge. This is achieved by training a *deep neural network*, building upon work by (Bengio & Ducharme, 2001) and (Collobert & Weston, 2007). We define a rather general convolutional network architecture and describe its application to many well known NLP tasks including part-of-speech tagging, chunking, named-entity recognition, learning a language model and the task of semantic role-labeling.

All of these tasks are integrated into a single system which is trained *jointly*. All the tasks except the language model are supervised tasks with labeled training data. The language model is trained in an unsupervised fashion on the entire Wikipedia website. Training this task jointly with the other tasks comprises a novel form of *semi-supervised learning*.

We focus on, in our opinion, the most difficult of these tasks: the semantic role-labeling problem. We show that both (i) multitask learning and (ii) semi-supervised learning significantly improve performance on this task *in the absence of hand-engineered features*.

We also show how the combined tasks, and in particular the unsupervised task, learn powerful features with clear semantic information given no human supervision other than the (labeled) data from the tasks (see Table 1).

Natural Language Processing (Almost) from Scratch

Ronan Collobert*
Jason Weston†
Léon Bottou‡
Michael Karlen
Koray Kavukcuoglu§
Pavel Kuksa¶

NEC Laboratories America
4 Independence Way
Princeton, NJ 08540

Editor: Michael Collins

RONAN@COLLOBERT.COM
JWESTON@GOOGLE.COM
LEON@BOTTOU.ORG
MICHAEL.KARLEN@GMAIL.COM
KORAY@CS.NYU.EDU
PKUKSA@CS.RUTGERS.EDU

Abstract

We propose a unified neural network architecture and learning algorithm that can be applied to various natural language processing tasks including part-of-speech tagging, chunking, named entity recognition, and semantic role labeling. This versatility is achieved by trying to avoid task-specific engineering and therefore disregarding a lot of prior knowledge. Instead of exploiting man-made input features carefully optimized for each task, our system learns internal representations on the basis of vast amounts of mostly unlabeled training data. This work is then used as a basis for building a freely available tagging system with good performance and minimal computational requirements.

Keywords: natural language processing, neural networks

基于CNN的命名实体识别




图9.5 基于CNN的命名实体识别框架

基于BiLSTM的命名实体识别




图9.6 基于LSTM的命名实体识别框架

Jason PC Chiu and Eric Nichols. 2016. Named entity recognition with bidirectional lstm-cnns. Transactions of the Association for Computational Linguistics, 4:357–370.

基于BERT的命名实体识别




图9.7 基于BERT的命名实体识别框架

Kenton, Jacob Devlin Ming-Wei Chang, and Lee Kristina Toutanova. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding." Proceedings of NAACL-HLT. 2019.

基于BART的命名实体识别

Input: <s> have muscle pain and fatigue </s>
Output: 2 3 7 2 5 6





图9.8 基于BART的命名实体识别框架

Hang Yan, Tao Gui, Junqi Dai, Qipeng Guo, Zheng Zhang, and Xipeng Qiu. "A Unified Generative Framework for Various NER Subtasks." In ACL, pp. 5808-5822. 2021.

基于BART的命名实体识别



Three entity representations:

Span: [0,2,5,5,PER] [0,7,LOC] [6,7, ORG]

BPE: [0,1,2,5,PER] [0,1,2,3,4,5,6,7,LOC] [6,7, ORG]

Word: [0,5,PER] [0,3,5,6,LOC] [6, ORG]

图9.9 实体索引生成格式化

Hang Yan, Tao Gui, Junqi Dai, Qipeng Guo, Zheng Zhang, and Xipeng Qiu. "A Unified Generative Framework for Various NER Subtasks." In ACL, pp. 5808-5822. 2021.

基于LLM的命名实体识别

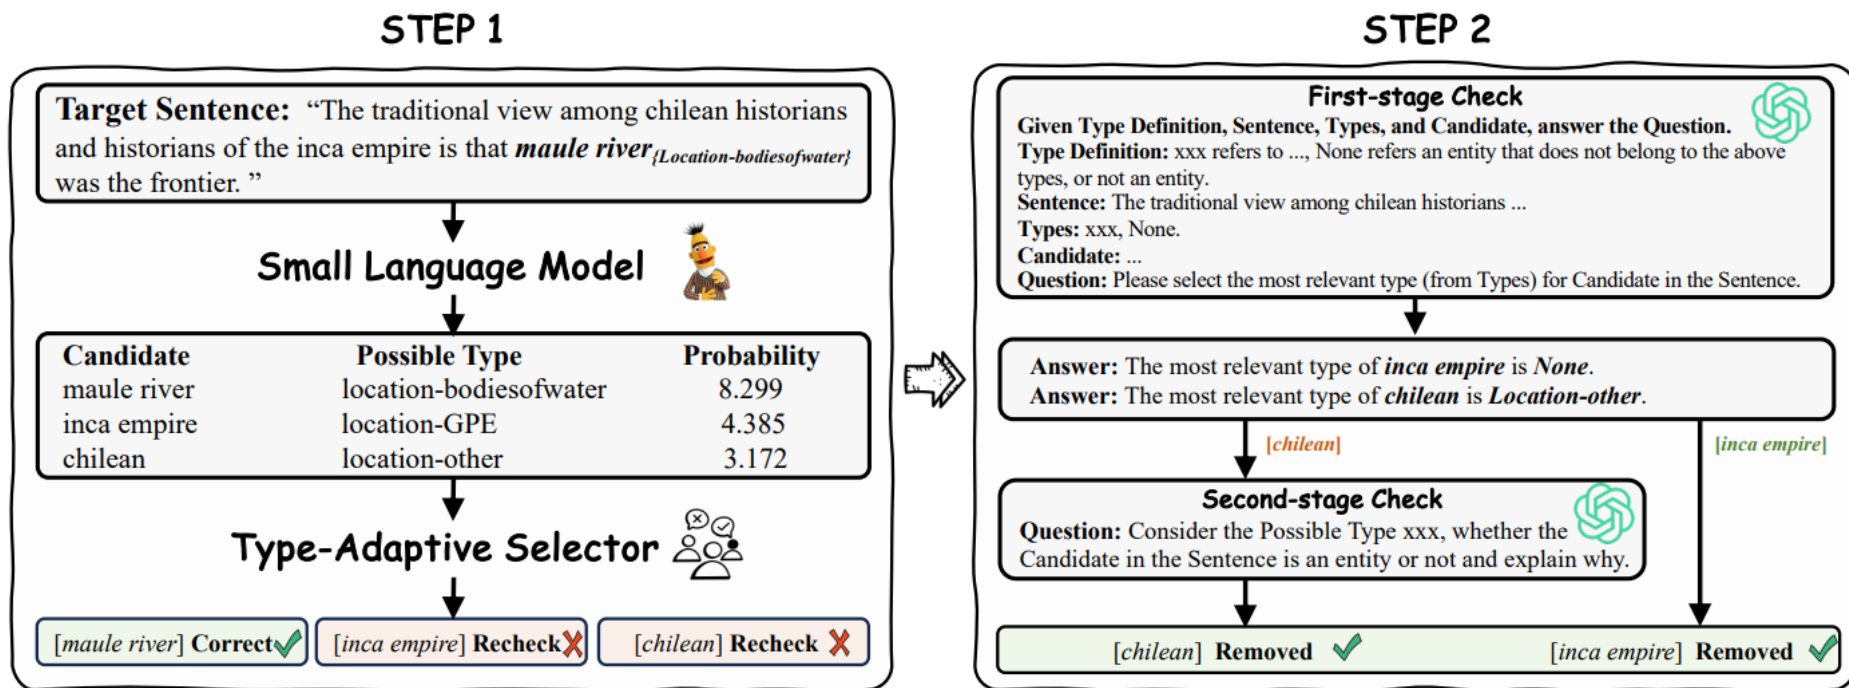


图9.10 基于LLM双重验证的命名实体识别框架

Chen W, Zhao L, Zheng Z, Xu T, Wang Y, Chen E. Double-Checker: Large Language Model as a Checker for Few-shot Named Entity Recognition. In Findings of the Association for Computational Linguistics: EMNLP 2024, Nov (pp. 3172-3181).

本章内容

- 概述
- 命名实体识别
 - 定义
 - 典型方法
 - 自动评价
- 实体消岐
- 关系抽取
- 事件抽取

实体消岐

- 概述
- 命名实体识别
- 实体消岐
 - 定义
 - 典型方法
 - 自动评价
- 关系抽取
- 事件抽取

实体消岐定义

- 实体消岐
 - 一篇文档中同一实体可能有多种不同的指称（Mention），不同文档中相同名称的实体也可能表示不同的含义。前者需要**共指消解**（Coreference Resolution）技术，后者需要**实体链接**（Entity Linking）技术
 - **共指消解**就是为文本中的指称确定其具体实体的过程
 - **实体链接**就是确定实体指称所对应的真实世界实体的过程

实体消岐定义

- 共指消解

- 例子：[李克强]接见[美国总统][特朗普]，[他]首先对[美国总统]的到来表示热烈欢迎。
- 指称主要分为3类：**普通名词短语**、**专有名词**和**代词**
- []列出了句中所有指称，其中“李克强”和“特朗普”是命名实体，属于专有名词，“美国总统”是普通名词短语，“他”是代词。
- 共指消解的目标就是将文档中所有指称进行**聚类**，将指向同一实体的所有指称归为一类
- “美国总统”和“特朗普”表示同一实体，“他”实际指代的是“李克强”，即例子中的所有指称聚为两类

实体消岐定义

- 实体链接

- ① “张杰多次参加春节联欢晚会。” ② “原上海交通大学校长张杰院士出任中国科学院副院长。”
- 在第一句话中，“张杰”指的是“歌手张杰”，而第二句话中的“张杰”指的是“中科院院士张杰”。
- 无论对于关系抽取还是事件抽取，都需要对多个文档中相同指称进行消岐
- 实体链接就是确定实体指称所对应的真实世界实体的过程

实体消岐

- 概述
- 命名实体识别
- 实体消岐
 - 定义
 - 典型方法
 - 自动评价
- 关系抽取
- 事件抽取

实体链接

- 实体链接的目标是学习一个映射函数 $f: M \times K \rightarrow E$ ，将文档中每一个实体指称 $M = \{m_1, m_2, \dots, m_N\}$ 准确链接到实体概念集合 $E = \{e_1, e_2, \dots, e_T\}$ 中的某个对应实体。通常，维基百科作为背景知识 K 。
- EL1: *Michael Jordan* is a leading *researcher* in *machine learning* and *artificial intelligence*, and he also plays *basketball* in free time.
- $M = \{\text{Michael Jordan, researcher, machine learning, artificial intelligence, basketball}\}$ 是实体指称，其中“Michael Jordan”的歧义性最大，候选实体概念包括 $E = \{\text{Michael Jordan (basketball player), Michael Jordan (football player), Michael Jordan (mycologist), Michael I. Jordan (professor),}\}$ 。在这个例子中，我们希望将文本中的 **Michael Jordan** 链接至 **Michael Jordan (professor)**

实体链接

- 实体链接任务可分为两个步骤：
 - 1. 候选实体概念的确定
 - 候选概念的确定就是对于给定的实体指称 m ，从 E 中找出可能的候选集合 E_m
 - 2. 候选实体概念的排序
 - 候选实体概念的排序就是对候选集合 E_m 中的所有实体进行打分排序，排在最前面的实体概念就是答案

确定候选实体概念

- 候选实体概念的确定直接影响实体链接的候选空间，若正确的实体概念未进入候选空间，无论后续的实体排序算法多么准确，都无法获得正确的答案。构造“**指称、实体概念**”词典是一种广泛采用的方法
- “**指称、实体概念**”词典的构造以维基百科为知识源，最终生成键值对形式的词典 $Dic = \{ \langle key, value \rangle \}$ ，其中 **key** 表示实体指称（例如 Michael Jordan），**value** 表示指称对应的候选概念集合（例如 { Michael Jordan (basketball player), Michael Jordan (football player), Michael Jordan (mycologist), Michael I. Jordan (professor), }）

确定候选实体概念

- 词典 Dic 的构造主要利用维基百科页面的各种特性，例如实体页面、重定向页面、消歧页面、首段黑体短语以及页面中的超链接等等
 - 例1：关于实体描述的维基百科页面中，题目通常是实体概念对应的最常见的指称，例如标题是“Microsoft”的维基百科页面描述的是“Microsoft Corporation”的实体概念。因此，“标题、实体概念”可作为 $\langle key, value \rangle$ 加入到词典中
 - 例2：每个维基百科页面中包含若干个超链接，例如“Michael Jordan”页面中包含超链接“ACC”，指向页面“Atlantic Coast Conference”。可见，这些超链接提供了实体概念的别名或者缩写等信息。因此，可将超链接部分作为 key ，所链接的实体作为 $value$ 加入到词典中

候选实体概念排序

- 给定指称 m 的候选实体概念集合 E_m ，下一步就是对 E_m 中的实体进行排序，以获得正确的实体链接关系
- 按照是否独立预测，实体排序方法主要可分为**基于局部的实体排序**和**基于全局的实体排序**
 - **基于局部的实体排序**假设文档中的多个指称之间是相互独立的，对某个指称的候选实体排序仅仅关注该指称的上下文以及候选实体概念的语义信息
 - **基于全局的实体排序**假设文档中的指称是相关的，一定程度上属于同一个主题，因此在实体链接过程中应该是相互影响的

基于局部的实体排序




图9.11 基于局部的实体排序模型架构

基于全局的实体排序

- 该模型包含两个步骤：
 - 1. 为文档中的指称及其对应的候选实体概念集合构建语义相关图 (Referent Graph, RG)
 - 2. 在相关图RG上进行实体链接的全局推断
- 文档中的指称与候选实体概念之间的相关图RG是一个加权无向图 $G = (V, E)$ ，其中 V 包含文档中所有指称与对应的候选实体概念， E 中包括两类边，一类是“指称-实体”边，刻画指称与实体之间的相关性；另一类是“实体-实体”边，刻画实体之间的语义相关性

基于全局的实体排序




图9.12 基于全局的实体排序模型架构

实体链接

- 概述
- 命名实体识别
- 实体消岐
 - 定义
 - 典型方法
 - 自动评价
- 关系抽取
- 事件抽取

实体链接评价

- 基于链接的实体消歧任务类似于分类任务，可直接利用准确率和召回率度量实体链接方法的性能
- 对于文档 D ，假设如下：
 - 人工标注的指称列表为 $M = \{m_i, m_j, \dots, m_M\}$ ，正确的实体链接结果为 $E = \{e_i, e_j, \dots, e_M\}$ ，
 - 系统识别的指称列表为 $M' = \{m'_i, m'_j, \dots, m'_N\}$ ，系统产生的实体链接结果为 $E' = \{e'_i, e'_j, \dots, e'_N\}$ ，其中 i 、 j 、 i' 、 j' 分别表示指称在文档中的位置
- 定义系统结果与人工标注结果的交集 M^* 和 E^*

$$M^* = \{m_k \mid \forall k, m'_k = m_k\}$$
$$E^* = \{e_k \mid \forall k, m_k \in M^*, e'_k = e_k\}$$

实体链接评价

- 定义系统结果与人工标注结果的交集 M^* 和 E^*

$$M^* = \{ m_k \mid \forall k, m'_k = m_k \}$$

$$E^* = \{ e_k \mid \forall k, m_k \in M^*, e'_k = e_k \}$$

$$Precision = \frac{|E^*|}{|E'|}$$

$$Recall = \frac{|E^*|}{|E|}$$

$$F1 = \frac{2 \times precision \times recall}{precision + recall}$$

关系抽取

- 概述
- 命名实体识别
- 实体消歧
- 关系抽取
 - 定义
 - 典型方法
 - 自动评价
- 事件抽取

关系抽取定义

- 关系抽取
 - 识别文本中的实体并判别实体间关系的技术称为关系抽取，该技术在知识图谱构建和自动问答等任务中扮演着关键角色
 - 例子：姚明是上海人。姚明2007年与叶莉正式领取了结婚证书。
 - 实体识别：[姚明]是[上海]人。[姚明]2007年与[叶莉]正式领取了结婚证书。
 - 关系抽取：citizen_of(姚明, 上海)、spouse(姚明, 叶莉)

关系抽取定义

- 形式化地，实体关系可以表示为一个元组 $t = (e_1, e_2, \dots, e_n, r)$ ，其中 $e_1, e_2, \dots, e_n$ 表示自然语言文本中的 n 个实体，而 r 表示 n 个实体之间的关系，称为 **n -元关系**
- **2-元关系**（两个实体间的关系）是主流，而且两个实体大多数限定在同一个句子中。所以，关系抽取任务聚焦于自动识别一句话中的一对实体概念和联系这对概念的关系所构成的三元组，即识别句子中的三元组 $t = (e_1, e_2, r)$
- 前面的例子中每个句子包含一个三元组，分别为 $t1 = (\text{姚明}, \text{上海}, \text{citizen_of})$ 和 $t2 = (\text{姚明}, \text{叶莉}, \text{spouse})$

关系抽取

- 概述
- 命名实体识别
- 实体消歧
- 关系抽取
 - 定义
 - 典型方法
 - 关系抽取形式化
 - 基于深度神经网络的关系分类方法
 - 自动评价
- 事件抽取

关系抽取形式化

- 假设句子中的实体已经给定，目标在于识别实体之间的关系。关系的类别在开放域环境中成千上万种并且未知关系类别繁多，我们将探讨**限定领域给定关系类别集合**下的关系识别任务
- 实体关系训练数据 $D_{train} = \{s_i, (e_{i1}, e_{i2})\}_{i=1}^N$ ， N 个句子， K 种关系，关系类别集合 $R = \{r_k\}_{k=1}^K$
- 测试数据 $D_{test} = \{s_j, (e_{j1}, e_{j2})\}_{j=1}^M$
- 关系识别系统需要判别测试数据中的每对实体概念 (e_{j1}, e_{j2}) 属于关系集合 R 中的哪一类

[姚明]2007年与[叶莉]正式领取了结婚证书。



spouse(姚明, 叶莉)

关系抽取形式化

ACE 2003			ACE 2004		
Type	Subtype	Count	Type	Subtype	Count
AT	based-in	496	PHYS	LOCATED	745
	located	2879		NEAR	87
	residence	395		PART-WHOLE	384
NEAR	relative-location	288	PER-SOC	BUSINESS	179
PART	other	6		FAMILY	130
	part-of	1178		OTHER	56
	subsidiary	366	EMP-ORG	EMPLOY-EXEC	503
ROLE	affiliate-partner	219		EMPLOY-STAFF	554
	citizen-of	450		EMPLOY-undetermined	79
	client	159		MEMBER-OF-GROUP	192
	founder	37		SUBSIDIARY	209
	general-staff	1507		PARTNER	12
	management	1559		OTHER	82
	member	1404	ART	USER/OWNER	200
	other	174		INVENTOR/MANUFACTURER	9
	owner	274		OTHER	3
SOCIAL	associate	119	OTHER-AFF	ETHNIC	39
	grandparent	10		IDEOLOGY	49
	other-personal	108		OTHER	54
	other-professional	415	GPE-AFF	CITIZEN/RESIDENT	273
	other-relative	86		BASED-IN	216
	parent	149		OTHER	40
	sibling	23	DISC	DISC	279
	spouse	89			

表9.2 ACE03和ACE04数据集中定义的关系类型

关系抽取形式化

Type	Subtype
ART (artifact)	User-Owner-Inventor-Manufacturer
GEN-AFF (Gen-affiliation)	Citizen-Resident-Religion-Ethnicity, Org-Location
METONYMY*	<i>none</i>
ORG-AFF (Org-affiliation)	Employment, Founder, Ownership, Student-Alum, Sports-Affiliation, Investor-Shareholder, Membership
PART-WHOLE (part-whole)	Artifact, Geographical, Subsidiary
PER-SOC* (person-social)	Business, Family, Lasting-Personal
PHYS* (physical)	Located, Near

表9.3 ACE05数据集中定义的关系类型

关系抽取

- 概述
- 命名实体识别
- 实体消歧
- 关系抽取
 - 定义
 - 典型方法
 - 关系抽取形式化
 - 基于深度神经网络的关系分类方法
 - 自动评价
- 事件抽取

基于分布式表示的关系分类

- 关系识别系统需要判别测试数据中的每对实体概念(e_{j1}, e_{j2})属于关系集合 R 中的哪一类

[姚明]2007年与[叶莉]正式领取了结婚证书。



spouse(姚明, 叶莉)

- 关系分类方法的关键**在于**如何根据实体所在的上下文**准确判别一对实体之间的关系。早期分布式方法的核心思想体现在三个方面：
 - 1. 所有特征采用分布式表示，以克服数据稀疏与语义鸿沟问题
 - 2. 采用局部表示捕捉实体对周围的上下文词汇化特征；
 - 3. 采用卷积神经网络捕捉实体对所在句子的全局信息。

基于CNN的关系分类





图9.13 基于CNN的关系分类模型

Zeng, D., Liu, K., Lai, S., Zhou, G., & Zhao, J. (2014, August). Relation classification via convolutional deep neural network. In *Proceedings of COLING 2014*, (pp. 2335-2344).

基于CNN的关系分类

- 词汇化分布式表示考虑三类特征：
 - 1. 实体对(e_1, e_2)自身；
 - 2. 两个实体的上下文词汇；
 - 3. 实体对在语义知识库（例如英文的WordNet、中文的HowNet等）中的上位词。



基于CNN的关系分类




图9.14 基于实体相对位置的位置编码表示

Zeng, D., Liu, K., Lai, S., Zhou, G., & Zhao, J. (2014, August). Relation classification via convolutional deep neural network. In *Proceedings of COLING 2014*, (pp. 2335-2344).

基于递归神经网络的关系分类

- Recursive Neural Network Model for RE





图9.15 基于递归神经网络的关系分类模型

Richard Socher, Brody Huval, Christopher D Manning, and Andrew Y Ng. EMNLP 2012. Semantic compositionality through recursive matrix-vector spaces.


基于实体间最短依存路径的关系分类

- Dependency Trees

[People₁] have₂ been₃ moving₄ back₅ into₆ [downtown₇].



- Path between two entities



基于分布式表示的关系分类

- Incorporating Shortest Dependency Path into CNNs
- Considering inverse relations

Relation	
Cause-Effect	Effect-Cause
Component-Whole	Whole-Component
Content-Container	Container-Content
Entity-Destination	Destination-Entity
Entity-Origin	Origin-Entity
Instrument-Agency	Agency-Instrument
Member-Collection	Collection-Member
Message-Topic	Topic-Message
Product-Producer	Producer-Product
Other	

Table 1: Relations in SemEval-2010 Task 8.

Relation	
PART-WHOLE	WHOLE-PART
ORG-AFF	AFF-ORG
ART	ART ⁻¹
PHYS	PHYS ⁻¹
GEN-AFF	AFF-GEN
PER-SOC	
None	

Table 2: Relations in ACE-2005.

Yu, Jianfei, and Jing Jiang. "Pairwise Relation Classification with Mirror Instances and a Combined Convolutional Neural Network." Proceedings of COLING 2016.

基于分布式表示的关系分类

- Incorporating Shortest Dependency Path into CNNs




图9.16 融合原始序列和实体间最短依存路径的关系分类模型

Yu, Jianfei, and Jing Jiang. "Pairwise Relation Classification with Mirror Instances and a Combined Convolutional Neural Network." Proceedings of COLING 2016.

基于BiLSTM的关系分类

- BiLSTM




图9.17 基于BiLSTM和Bi-TreeLSTM的关系分类模型

Miwa, M., & Bansal, M. (2016, August). End-to-End Relation Extraction using LSTMs on Sequences and Tree Structures. In Proceedings of ACL (pp. 1105-1116).

基于BERT的关系分类

- BERT




图9.18 基于BERT的关系分类模型

Wu, Shanchan, and Yifan He. "Enriching pre-trained language model with entity information for relation classification." Proceedings of CIKM. 2019.

基于LLM的关系分类

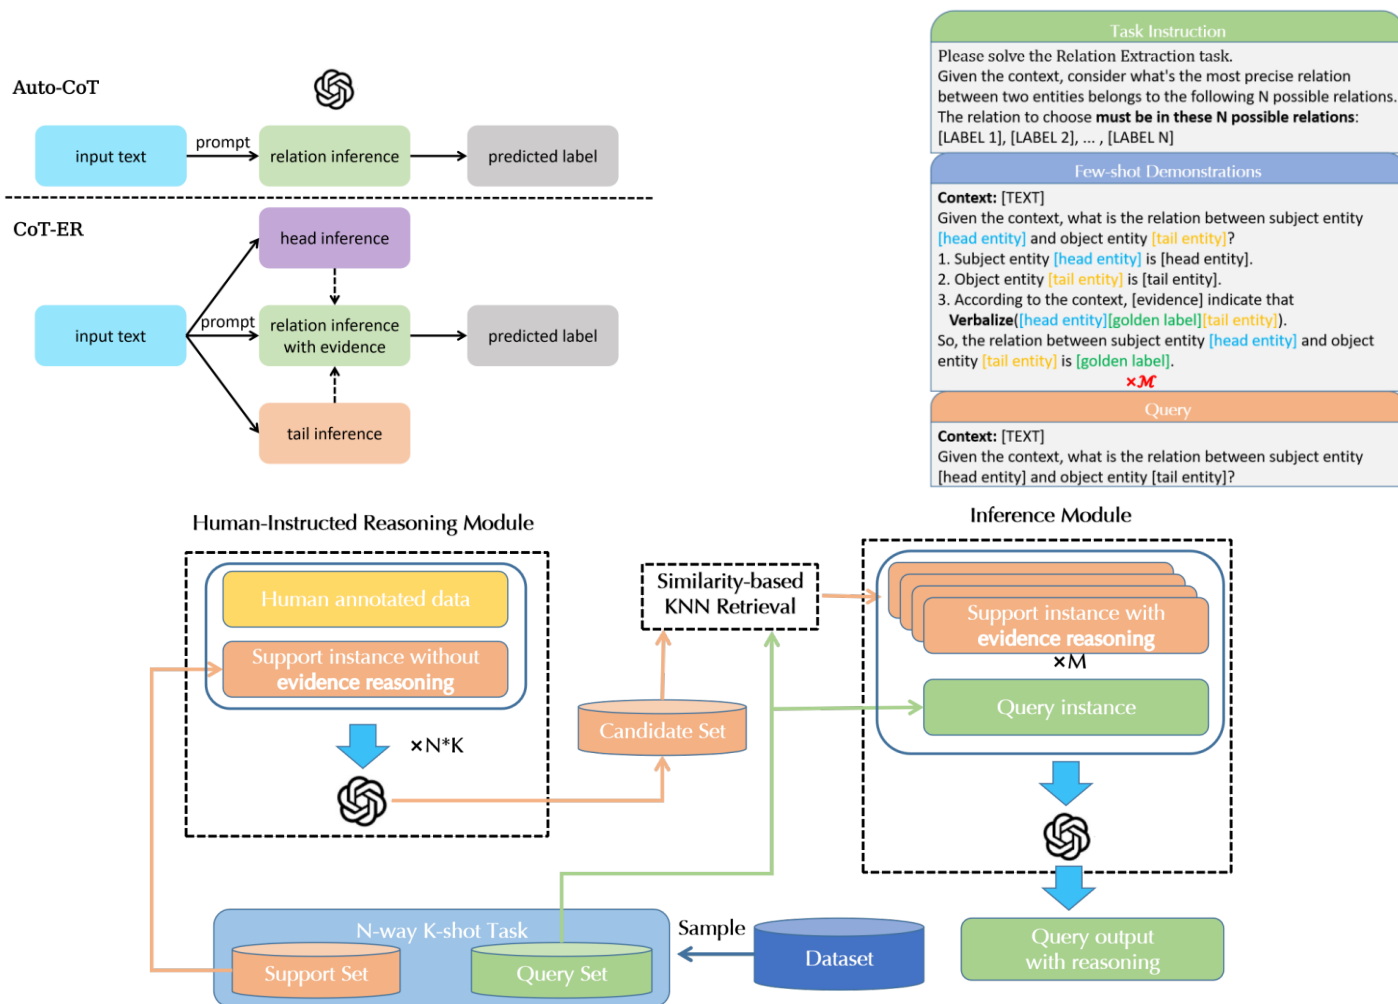


图9.19 基于思维链和上下文学习的关系分类模型

Ma X, Li J, Zhang M. Chain of Thought with Explicit Evidence Reasoning for Few-shot Relation Extraction. In Findings of the Association for Computational Linguistics: EMNLP 2023 2023 Dec (pp. 2334-2352).

关系抽取

- 概述
- 命名实体识别
- 实体消歧
- 关系抽取
 - 定义
 - 典型方法
 - 自动评价
- 事件抽取

基于分布式表示的关系分类

- 针对一个测试集，假设人工标注的实体关系集合为 R ，分类器自动识别和标注的实体关系集合为 O

$$F1 = \frac{2 \times \text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

$$\text{recall} = \frac{|O \cap R|}{|R|}$$

$$\text{precision} = \frac{|O \cap R|}{|O|}$$

事件抽取

- 概述
- 命名实体识别
- 实体消歧
- 关系抽取
- 事件抽取
 - 定义
 - 典型方法
 - 自动评价

事件抽取定义

- 事件抽取

- 事件抽取就是针对特定领域的事件进行事件元素的抽取
- 一个事件包括事件类型、参与者、时间、地点、原因以及诸多其他元素，不同类型的事件对应不同的组织结构
- 例如，公司收购事件包含“收购者”、“被收购者”和“金额”等，而离职事件包含“离职者”、“公司机构”、“职位”以及“离职时间”等等

事件抽取定义

- 事件抽取

- 例：[9月3日]，[国家主席习近平]在[厦门]会见[俄罗斯总统普京]。
- “会见事件”由词语“会见”触发，该事件的元素包括：会见对象（国家主席习近平、俄罗斯总统普京）、地点（厦门）、时间（9月3日）以及会见时长（未提及）
- 事件抽取旨在抽取表明事件类型的**触发词**及其对应的**事件元素**

事件抽取定义

事件类型 (大类)	事件类型 (子类)
Life (生活)	Be-Born (出生), Marry (结婚), Divorce (离婚), Injure (受伤), Die (去世)
Movement (转移)	Transport (运输)
Transaction (交易)	Transfer-Ownership (所有权转移), Transfer-Money (资金转移)
Business (商业)	Start-Org (创办), Merge-Org (合并), Declare-Bankruptcy (破产), End-Org (倒闭)
Conflict (冲突)	Attack (袭击), Demonstrate (示威)
Contact (联系)	Meet (会见), Phone-Write (电话书信)
Personnel (人员变动)	Start-Position (履职), End-Position (离职), Nominate (提名), Elect (选举)
Justice (司法)	Arrest-Jail (拘捕), Release-Parole (释放), Trial-Hearing (审判), Charge-Indict (指控), Sue (起诉), Convict (定罪), Sentence (量刑), Fine (罚款), Execute (处决), Extradite (引渡), Acquit (宣告无罪), Appeal (上诉), Pardon (赦免)

ACE中8大类33子类的事件类型

事件抽取实例

- 例1：[李敖][1953年]出生于[黑龙江哈尔滨市]。
- 例2：[3月22日]，[百度首席科学家吴恩达]在Twitter发文宣布离职[百度]。
- 事件通常由一句话描述，其中一定存在一个词语，比如例1中的“出生”、例2中的“离职”等，能够**清晰表明某类事件的发生**，这类词语称为**触发词**。
- **触发词**是决定**事件类型**的**核心要素**，已知事件类型的前提下，抽取事件的各个元素并判别事件元素的角色是主要任务。事件角色由两大类组成：**事件参与者**和**事件属性**。

事件抽取实例

- **事件参与者**通常是命名实体中的**人名**和**机构名**。事件属性包括两类：通用事件属性和事件相关属性。
- **通用事件属性**：事件发生的地点、时间和时长等。
- **事件相关属性**：由具体的事件类型决定，例如“定罪”事件中的“罪名”属性，“履职”事件中的“职位”属性，都是事件相关属性。
- 若每个事件属性视为一种角色，在ACE的标注体系中一共有**35个角色**。
- 每种类型的事件可以通过一个模板表示，该模板可以是**通用模板**，也可以是事件类型相关的**特定模板**。
- **通用模板**包含36个槽位，其中一个槽位需要填充触发词，其余槽位对应35个角色。
- 由于不同类型事件之间差异较大，因此在**已知事件类型**的前提下可以采用**特定模板**。

事件抽取实例

Person	Place	Buyer	Seller
Beneficiary	Price	Artifact	Origin
Destination	Giver	Recipient	Money
Org	Agent	Victim	Instrument
Entity	Attacker	Target	Defendant
Adjudicator	Prosecutor	Plaintiff	Crime
Position	Sentence	Vehicle	Time-After
Time-Before	Time-At-Beginning	Time-At-End	Time-Starting
Time-Ending	Time-Holds	Time-Within	

事件抽取实例

- 例1：[李敖][1953年]出生于[黑龙江哈尔滨市]。

Trigger (触发词)	出生
Person-Arg (人名)	李敖
Time-Arg (时间)	1935年
Place-Arg (地点)	黑龙江哈尔滨市

例1描述的事件对应的模板

事件抽取实例

- 例2：[3月22日]，[百度首席科学家吴恩达]在Twitter发文宣布离职[百度]。

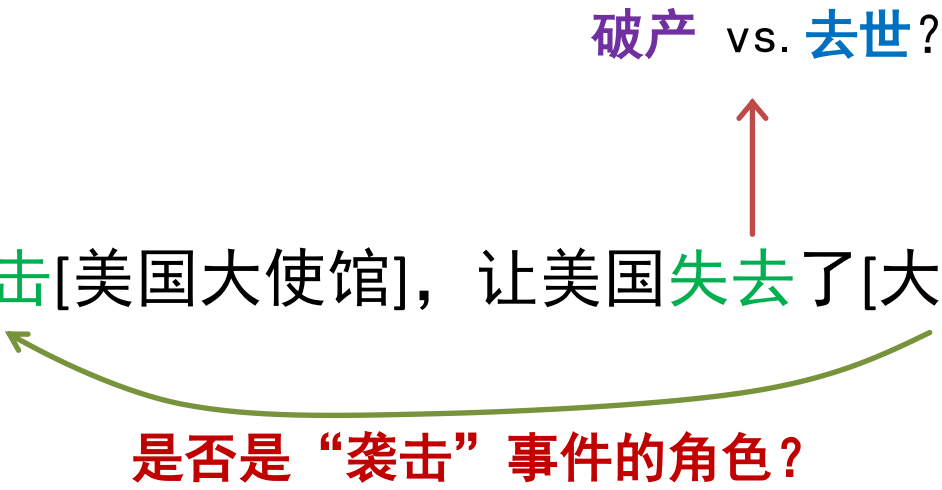
Trigger (触发词)	离职
Person-Arg (人名)	吴恩达
Entity-Arg (公司机构)	百度
Position-Arg (职位)	首席科学家
Time-Arg (时间)	3月22日

例2描述的事件对应的模板


事件抽取

- 概述
- 命名实体识别
- 实体消歧
- 关系抽取
- 事件抽取
 - 定义
 - 典型方法
 - 自动评价

基于联合模型的事件抽取


- 例3: [恐怖分子]炸弹**袭击**[美国大使馆], 让美国**失去了**[大兵瑞恩]。


破产 vs. 去世?

是否是“袭击”事件的角色?
- 例4: 两年前的生意失败, 让[陈兵]**失去了**原本价值数亿美元的[天鸿公司]。


破产 vs. 去世?

基于联合模型的事件抽取



事件抽取方法

- 基于联合模型的事件抽取方法
- 基于分布式模型的事件抽取方法

事件抽取方法

- 基于联合模型的事件抽取方法
- 基于分布式模型的事件抽取方法

基于CNN的事件抽取

- Step 1: 触发词定位与事件类型分类




图9.20 基于CNN的触发词定位与事件类型分类模型

Chen, Y., Xu, L., Liu, K., Zeng, D., & Zhao, J. (2015, July). Event extraction via dynamic multi-pooling convolutional neural networks. In Proceedings of ACL (pp. 167-176).

基于CNN的事件抽取

- Step 2: 事件元素(论元)识别与角色分类





图9.21 基于CNN的事件元素(论元)识别与角色分类


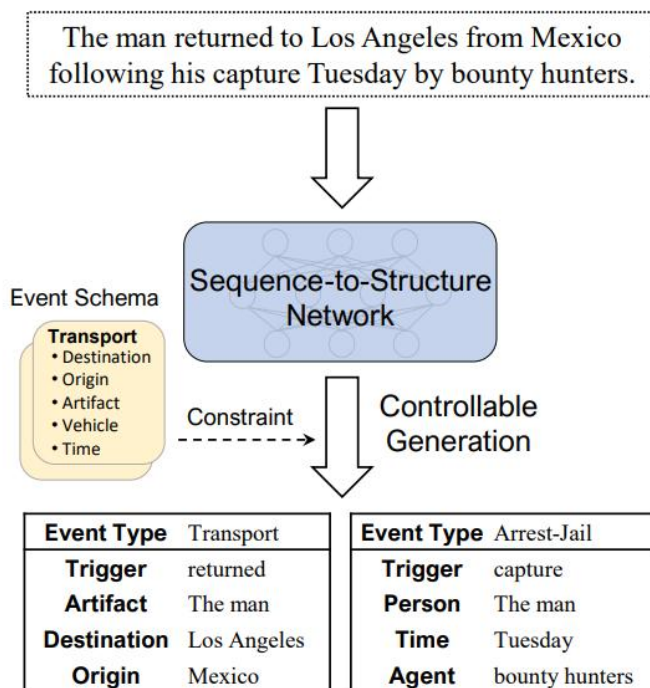
Chen, Y., Xu, L., Liu, K., Zeng, D., & Zhao, J. (2015, July). Event extraction via dynamic multi-pooling convolutional neural networks. In Proceedings of ACL (pp. 167-176).

基于BiGRU的事件抽取



Nguyen, T.H., Cho, K. and Grishman, R., 2016, June. Joint event extraction via recurrent neural networks. In Proceedings of NAACL (pp. 300-309).

基于Seq2Seq的事件抽取



Lu, Y., Lin, H., Xu, J., Han, X., Tang, J., Li, A., Sun, L., Liao, M. and Chen, S., 2021, August. Text2Event: Controllable Sequence-to-Structure Generation for End-to-end Event Extraction. In Proceedings of ACL (pp. 2795-2806).

基于LLM的事件抽取

Prompt for Zero-shot ED

Please analyze the following sentence to determine if it contains any of the listed events: [...]. If an event is detected, kindly provide its event type and trigger word/phrase, formatting your response as:

Event_Type: event type

Trigger: trigger word/phrase

If no event is identified, simply return 'None'.

Sentence: But, well, the business is complicated and the business is tough.

Response:

Prompt for Zero-shot EAE

The sentence is understood to describe an event **Personnel.End-Position**, triggered by 'leaving'. Analyze the sentence to identify any of the following arguments related to this event: 'person', 'entity', 'place'. If you find any arguments, format your response as: {role_type: arguments}. If multiple arguments are related to this event, include them all. If no arguments are found, simply respond with 'None'.

Sentence: Davies is leaving to become chairman of the London School of Economics, one of the best - known parts of the University of London.

Response:

Prompt

Could you create a succinct sentence that includes the **Justice.Acquit** event and then annotate it as per the provided examples?

sentence: Wouter Basson was acquitted in April 2002 on 46 charges, ranging from murder and drug trafficking to fraud and theft.

event_type: Justice.Acquit

trigger: acquitted

defendant: Wouter Basson

adjudicator: None

place: None

Response from GPT-4

Certainly! Here's a new sentence along with its annotation:

sentence: Jane Doe was acquitted of embezzlement charges by Judge Smith in New York City in June 2019.

event_type: Justice.Acquit

trigger: acquitted

defendant: Jane Doe

adjudicator: Judge Smith

place: New York City

Response from PaLM

sentence: Wouter Basson was acquitted in April 2002 on 46 charges, ranging from murder and drug trafficking to fraud and theft.

event_type: Justice.Acquit

trigger: acquitted

defendant: Wouter Basson

adjudicator: None

place: None

Response from GPT-3.5-Turbo

Wouter Basson was acquitted [Justice.Acquit] in April 2002 on 46 charges, ranging from murder and drug trafficking to fraud and theft.

[event_type: Justice.Acquit] [trigger: acquitted] [defendant: Wouter Basson] [adjudicator: None] [place: None]

Chen R, Qin C, Jiang W, Choi D. Is a large language model a good annotator for event extraction?. In Proceedings of the AAAI Conference on Artificial Intelligence 2024 Mar 24 (Vol. 38, No. 16, pp. 17772-17780).

事件抽取

- 概述
- 命名实体识别
- 实体消歧
- 关系抽取
- 事件抽取
 - 定义
 - 典型方法
 - 自动评价

事件抽取评价

- 给定一个测试集 $Test_{event}$ ，并且 $Test_{event}$ 由专家进行了正确的事件标注 Ref_{event} 。事件抽取模型 M 在测试集 $Test_{event}$ 上进行事件标注，得到预测结果 $Model_{event}$ 。客观评价方法就是对比预测结果 $Model_{event}$ 和正确结果 Ref_{event}
- 几乎所有模型都将事件抽取任务分解为触发词识别和事件角色分类两个步骤
 - 其中触发词识别又可分解为触发词定位与事件类型分类两个子任务，
 - 事件角色分类又可分解为事件元素识别与角色分类两个子任务；
 - 因此，客观评测一般对四个子任务分别进行测试

事件抽取评价

- 若模型找到了触发词的在事件描述中的具体位置，那么触发词定位正确；在定位正确的基础上，如果事件的类型也预测正确，那么事件类型分类任务得到正确结果。
- 若某候选事件元素被正确识别为触发词的关联属性，那么事件元素识别是正确的，如果正确识别的事件元素进一步被预测为正确的事件角色，那么最终的事件角色分类也是正确的。
- 根据匹配结果，利用准确率（Precision）、召回率（Recall）和F1值分别度量各个子任务的性能

本章小结

- 信息抽取概述：概念，定义，发展历史等
- 命名实体识别：
 - 规则方法、统计学习方法、深度学习方法
- 实体消岐：共指消解、实体链接
- 关系抽取：方法与评价
- 事件抽取：方法与评价



欢迎提问！

本章内容

- 概述
- 命名实体识别
 - 定义
 - 典型方法
 - 基于规则的方法
 - 基于有监督的机器学习方法
 - 基于隐马尔科夫模型的命名实体识别
 - 基于条件随机场的命名实体识别
 - 基于深度神经网络的命名实体识别
 - 自动评价
- 实体消岐
- 关系抽取
- 事件抽取

基于隐马尔科夫模型的命名实体识别

- 问题形式化

- 给定一个待标注的句子 $X = x_0 x_1 \cdots x_T$ （称为观测值），序列标注模型都希望搜索一个标签序列 $Y = y_0 y_1 \cdots y_T$ （称作状态值），使得后验概率 $P(Y|X)$ 最大。

$$P(Y|X) = \frac{P(X, Y)}{P(X)} = \frac{P(Y) \times P(X|Y)}{P(X)}$$

$$P(X, Y) = P(Y) \times P(X|Y) = \prod_{t=0}^T P(y_t|y_{t-1}) \times P(x_t|y_t)$$

$$P(y_t|y_{t-1}) = \frac{\text{count}(y_{t-1}, y_t)}{\text{count}(y_{t-1})}$$

$$P(x_t|y_t) = \frac{\text{count}(x_t, y_t)}{\text{count}(y_t)}$$

基于隐马尔科夫模型的命名实体识别


- 测试

- 给定一个待标注的句子 $X = x_0 x_1 \cdots x_T$ （汉字序列），利用维特比算法搜索标签序列 $Y = y_0 y_1 \cdots y_T$
- $\delta_t(y)$ 记录以 t 时刻标签 y 结束的路径对应的最大概率， $\varphi_t(y)$ 记录 t 时刻标签 y 的最大概率路径中前一时刻的标签

$$\delta_t(y) = \max_{y'} \{ \delta_{t-1}(y') P(y | y') P(x_t | y) \}$$


$$\varphi_t(y) = \operatorname{argmax}_{y'} \{ \delta_{t-1}(y') P(y | y') P(x_t | y) \}$$

基于隐马尔科夫模型的命名实体识别



基于隐马尔科夫模型的命名实体识别

$$P(Y|X) = \frac{P(X, Y)}{P(X)} = \frac{P(Y) \times P(X|Y)}{P(X)}$$



$$P(Y|X) = \frac{1}{Z_X} \exp \left\{ \sum_{t=1}^T \sum_k \lambda_k f_k(y_{t-1}, y_t, X, t) \right\}$$

$$f_k(y_{t-1}, y_t, X, t) = \begin{cases} 1; & \text{if } y_{t-1} = ORG - B, y_t = ORG - B, x_t = \text{歌} \\ 0; & \text{otherwise} \end{cases}$$

本章内容

- 概述
- 命名实体识别
 - 定义
 - 典型方法
 - 基于规则的方法
 - 基于有监督的机器学习方法
 - 基于隐马尔科夫模型的命名实体识别
 - 基于条件随机场的命名实体识别
 - 基于深度神经网络的命名实体识别
 - 自动评价
- 实体消岐
- 关系抽取
- 事件抽取

基于条件随机场的命名实体识别

词汇化特征	当前字符 x_t , 前驱字符 x_{t-1} , 后续字符 x_{t+1} , 字符组合 $x_{t-1}x_t$, x_tx_{t+1} , $x_{t-1}x_tx_{t+1}$ 等等
标签特征	当前标签 y_t , 前驱标签 y_{t-1} , 标签组合 $y_{t-1}y_t$ 等等
标签词汇组合特征	x_ty_t , $y_{t-1}x_t$, $y_{t-1}x_ty_t$ 等等
词典特征	字符串 $x_{t-1}x_t$, x_tx_{t+1} , $x_{t-1}x_tx_{t+1}$是否在给定的词典中

基于条件随机场的命名实体识别

