

田永铭 221900180 第二次作业

Problem 8.1

解：最大似然函数为 $L(\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n \exp(-\lambda \sum_{i=1}^n x_i)$ 。取对数得对数似然函数： $\ell(\lambda) = \log L(\lambda) = n \log \lambda - \lambda \sum_{i=1}^n x_i$ 。对 λ 求导并令其为零： $\frac{d\ell}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \Rightarrow \lambda^* = \frac{n}{\sum_{i=1}^n x_i}$ ，因此最大似然估计为 $\lambda^* = \frac{n}{\sum_{i=1}^n x_i}$ 。

Problem 8.6

解：已知 $p(x|y=i) = \mathcal{N}(\mu_i, \Sigma)$, $i \in \{1, 2\}$, 且 $p(y=1) = p(y=2) = 0.5$ 。根据贝叶斯定理, 有: $p(y=i|x) = \frac{p(x|y=i)p(y=i)}{p(x)}$ 。由于先验概率相等, 因此比较 $p(y=1|x)$ 与 $p(y=2|x)$ 等价于比较 $p(x|y=1)$ 与 $p(x|y=2)$ 的大小: $\hat{y} = \arg \max_{i \in \{1, 2\}} p(x|y=i)$ 。高斯密度函数为: $p(x|y=i) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp(-\frac{1}{2}(x - \mu_i)^T \Sigma^{-1}(x - \mu_i))$ 。对上式取对数并忽略常数项, 最大化 $\log p(x|y=i)$ 等价于最小化: $(x - \mu_i)^T \Sigma^{-1}(x - \mu_i)$ 。定义判别函数 $g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma^{-1}(x - \mu_i)$, 比较 $g_1(x)$ 和 $g_2(x)$, 令: $g_1(x) > g_2(x) \iff (x - \mu_1)^T \Sigma^{-1}(x - \mu_1) < (x - \mu_2)^T \Sigma^{-1}(x - \mu_2)$ 。化简得: $x^T \Sigma^{-1}(\mu_1 - \mu_2) > \frac{1}{2}(\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2)$ (注意这里每一项都是标量)。令 $w = \Sigma^{-1}(\mu_1 - \mu_2)$, $b = -\frac{1}{2}(\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2)$, 则分类器可写为:

$$y^* = \begin{cases} 1 & \text{if } w^T x + b > 0 \\ 2 & \text{if } w^T x + b \leq 0 \end{cases}$$

最终得到 w 与 b 的表达式为: $w = \Sigma^{-1}(\mu_1 - \mu_2)$, $b = -\frac{1}{2}(\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2)$ 。

Problem 9.1

解：由题意得: $y_1 - y_2 = E_d^T(x_1 - \bar{x}) - E_d^T(x_2 - \bar{x}) = E_d^T(x_1 - x_2)$ 。因此, 二范数平方等于欧氏距离平方, 其值为: $d_A^2(x_1, x_2) = \|y_1 - y_2\|_2^2 = \|E_d^T(x_1 - x_2)\|_2^2 = (x_1 - x_2)^T E_d E_d^T (x_1 - x_2)$ 。令 $A = E_d E_d^T$, 得 $d_A^2(x_1, x_2) = (x_1 - x_2)^T A (x_1 - x_2)$, 符合度量家族中的成员, 即“马氏距离”。因此, 合法的矩阵 A 是 $E_d E_d^T$ 。

Problem 9.3 证明:

- 由于 $|x_i| \geq 0$, 且 $x_i \geq 0$ 时 $|x_i| = x_i$, 因此公式 (9.56) 在 $x_i \geq 0$ 的条件下可直接表示为: $(x_1^p + x_2^p + \cdots + x_d^p)^{1/p} \geq (x_1^q + x_2^q + \cdots + x_d^q)^{1/q}$, 即公式 (9.57) 成立。
- 设 $r = \frac{q}{p} > 1$, 且 $y_i = x_i^p \geq 0$ 。注意到 $x_i^q = x_i^{p \cdot q/p} = y_i^r$, 并且将公式 (9.57) 两边同时取 q 次幂, 即得 $(y_1 + y_2 + \cdots + y_d)^r \geq (y_1^r + y_2^r + \cdots + y_d^r)$, 即公式 (9.58)。
- 当 $d = 2$ 时, 设 $f(t) = (1+t)^r - (1+t^r)$, 其中 $t = y_2/y_1 \geq 0$ 。通过泰勒展开可证 $f(t) \geq 0$ 对所有 $t \geq 0$ 成立。对于 $d > 2$, 假设不等式对 $d-1$ 成立, 利用归纳法, 将前 k 项合并, 得 $(y_1 + \cdots + y_{k+1})^r \stackrel{\text{基例}}{\geq} (y_1 + \cdots + y_k)^r + y_{k+1}^r \stackrel{\text{假设}}{\geq} y_1^r + \cdots + y_{k+1}^r$ 。证毕。

Problem 9.4

证明：需验证 $\|Gx\|$ 满足向量范数的三个性质。(1) **非负性：**由于范数本身是非负的，即 $\|Gx\| = \sqrt{(Gx)^\top(Gx)} \geq 0$ ，所以我们只需要验证 $Gx = 0 \Rightarrow x = 0$ 。通过反证法来证明，假设存在 $x_0 \neq 0$ 使得 $Gx_0 = 0$ ，则 $x_0^\top Gx_0 = 0$ ，这与 G 是正定矩阵矛盾，因此不存在这样的 x_0 ，因此满足向量范数需要的非负性。(2) **齐次性：**对任意标量 $\alpha \in \mathbb{R}$ ，有 $\|G(\alpha x)\| = \|\alpha Gx\| = |\alpha| \|Gx\|$ 。(3) **三角不等式：**对任意 $x, y \in \mathbb{R}^d$ ，由欧几里得范数的三角不等式得， $\|G(x+y)\| = \|Gx + Gy\| \leq \|Gx\| + \|Gy\|$ 。综上， $\|Gx\|$ 是一个有效的向量范数。

Problem 11.2

解：(a) 对于 $f(\alpha) = \|x - D\alpha\|^2$ ，其梯度为 $\nabla f(\alpha) = -2D^\top(x - D\alpha)$ 。考虑任意 α_1, α_2 ，有 $\|\nabla f(\alpha_1) - \nabla f(\alpha_2)\| = 2\|D^\top D(\alpha_1 - \alpha_2)\|$ 。由于 $\|D^\top D(\alpha_1 - \alpha_2)\| \leq \|D^\top D\| \cdot \|(\alpha_1 - \alpha_2)\|$ (相容性) $= \lambda_{\max}(D^\top D) \|\alpha_1 - \alpha_2\|$ (二范数定义)，其中 $\lambda_{\max}$ 表示最大特征值，因此 $\|\nabla f(\alpha_1) - \nabla f(\alpha_2)\| \leq 2\lambda_{\max}(D^\top D) \|\alpha_1 - \alpha_2\|$ ，即 $L(f) = 2\lambda_{\max}(D^\top D)$ 。

(b) 对于 $f(\alpha) = \|x - D\alpha\|^2$ 和 $g(\alpha) = \lambda \|\alpha\|_1$ ，优化问题 $p_L(\beta) = \argmin_{\alpha} \lambda \|\alpha\|_1 + \frac{L}{2} \|\alpha - (\beta - \frac{1}{L} \nabla f(\beta))\|^2$ 可分解为分量形式 (这是由于各个 β_i 分量之间没有耦合)：

$$p_L(\beta)_i = \mathcal{S}_{\lambda/L} \left(\beta_i + \frac{2}{L} D_i^\top (x - D\beta) \right)$$

其中软阈值函数 $\mathcal{S}_\kappa(z) = \text{sign}(z) \max(|z| - \kappa, 0)$ 。(这个问题是标准优化问题，解的形式就是这样，具体的可以通过讨论 α_i 的正负以及为 0 三种情况来推导。) 由于 $\mathcal{S}_\kappa$ 会将绝对值小于 κ 的分量置零，故每次迭代 $\alpha_{t+1} = p_L(\alpha_t)$ 都可能会产生新的零分量，但不可能增加非零分量，因此导致了解的稀疏性。

Problem 12.1

证明：一个拥有 N 个可能状态的离散时间马尔可夫链 (DTMC) 需要两部分信息来完全描述：(1) 转移概率矩阵： $N \times N$ 的矩阵 P ，其中每一行表示从当前状态转移到其他状态的概率，总和为 1，故每行有 $N-1$ 个自由参数，共需 $N(N-1)$ 个数。(2) 初始状态分布：长度为 N 的概率向量 π ，其元素之和为 1，因此有 $N-1$ 个自由参数。总计需要的独立数值为： $(N-1) + N(N-1) = N^2 - 1$ 。

Problem 12.2

证明：采用归纳法，对 k 进行归纳。右随机矩阵的定义是，满足所有元素非负并且行和为 1 的方阵。记 A 的维度为 $D \times D$ 。(1) 当 $k=1$ 的时候，结论成立，因为 A 本身条件就是右随机矩阵。(2) 归纳假设当 $k=n$ 的时候，结论成立，即 A^n 是右随机矩阵。(3) 当 $k=n+1$ 的时候，由归纳基础和归纳假设得到 $\sum_{d=1}^D A_{id} = 1$ ($i=1, 2, \dots, D$)，并且 $\sum_{d=1}^D A_{id}^n = 1$ ($i=1, 2, \dots, D$)，且这里所有的数都非负。由于 $A^{n+1} = A^n \cdot A$ ，而 A^{n+1} 的每一个位置的元素都是 A^n 和 A 元素的乘积和求和，所以显然非负。下面验证 A^{n+1} 行和为 1。记 $A_{i\cdot}$ 表示 A 的第 i 行， $A_{\cdot i}$ 表示 A 的第 i 列。以第 i 行为例，其中 $i=1, 2, \dots, D$ ，有 $\sum_{d=1}^D A_{id}^{n+1} = \sum_{d=1}^D A_{i\cdot}^n A_{\cdot d} = \sum_{d=1}^D \sum_{m=1}^D A_{im}^n A_{md} = \sum_{m=1}^D \sum_{d=1}^D A_{im}^n A_{md}$ (求和换序) $= \sum_{m=1}^D A_{im}^n \cdot 1 = 1$ 。证毕。