



南京大學
NANJING UNIVERSITY

人工智能导论

不确定性

郭兰哲

南京大学 智能科学与技术学院

Homepage: www.lamda.nju.edu.cn/guolz

Email: guolz@nju.edu.cn

大纲

- 不确定环境
- 概率论基础
- 贝叶斯网：表示
- 贝叶斯网：语法语义
- 贝叶斯网：精确推理
- 贝叶斯网：近似推理

大纲

- 不确定环境

- 概率论基础

- 贝叶斯网：表示

- 贝叶斯网：语法语义

- 贝叶斯网：精确推理

- 贝叶斯网：近似推理

不确定环境

□ 现实世界充满不确定性

- 以自动驾驶出租车agent为例，agent的目标是按时将乘客送到机场，令 A_t 表示在飞机起飞前 t 分钟出发，是否能按时到达？

□ 现实世界问题：

- 部分可观察（道路状况、其它司机的规划等）
- 噪声感知（地图导航）
- 建模复杂性（交通难预测）
- 缺少对动态世界的知识（爆胎、陨石）

不确定环境

□ 现实世界充满不确定性

- 以自动驾驶出租车agent为例，agent的目标是按时将乘客送到机场，令 A_t 表示在飞机起飞前 t 分钟出发，是否能按时到达？

□ 逻辑推理要么得出错误结论：

- A_{90} 能让我按时到达机场

□ 要么只能得到弱一些的结论：

- A_{90} 能让我按时到达机场，如果不抛锚、不堵车、不遇到交通事故、不爆胎、飞机不会提前起飞、没有陨石砸到我的车，...

不确定环境下的决策

- 概率(probability)提供了一种方法概括由惰性(laziness)和无知(ignorance)产生的不确定性
 - laziness: 为了确保得到一个没有任何意外的规则, 需要列出前提和结论的完整集合, 工作量太大
 - ignorance: 对于该领域, 缺少完整的认识 and 理论

- 堵车的概率是0.9
- 发生堵车的情况下, A_{90} 能让我按时到达机场的概率为0.6, A_{120} 能让我按时到达机场的概率为0.8
- ...

不确定环境下的决策

假如：

$$P(A_{25} \text{ gets me there on time} \mid \dots) = 0.04$$

$$P(A_{90} \text{ gets me there on time} \mid \dots) = 0.70$$

$$P(A_{120} \text{ gets me there on time} \mid \dots) = 0.95$$

$$P(A_{1440} \text{ gets me there on time} \mid \dots) = 0.9999$$

如何做决策？

必须在各种决策的不同结果之间有所偏好：效用理论(utility theory)

决策理论=概率理论+效用理论

大纲

- 不确定环境

- 概率论基础

- 贝叶斯网：表示



- 贝叶斯网：语法语义

- 贝叶斯网：精确推理

- 贝叶斯网：近似推理


基本概率符号

- 所有可能的情况构成的集合 Ω 称为**样本空间 (sample space)**
 - 例如，掷骰子的六种可能情况： $\{1,2,3,4,5,6\}$
- **概率模型(probability model)**为每一个可能的情况 ω 赋一个数值概率 $P(\omega)$
 - 例如， $P(1) = P(2) = P(3) = P(4) = P(5) = P(6) = 1/6$.
- 根据概率论基本公理，有：
 - $0 \leq P(\omega) \leq 1$
 - $\sum_{\omega \in \Omega} P(\omega) = 1$



事件(event)


- Ω 的任何一个子集可以称为一个事件(event)
 - 例如, “点数小于4” 的事件对应集合{1,2,3}
 - 例如, “点数是奇数” 的事件对应集合{1,3,5}



- 一个事件 A 发生的概率等于集合中所有样本发生的概率之和:
 - $P(A) = \sum_{\omega \in A} P(\omega)$
 - 例如: (点数小于4) = $P(1) + P(2) + P(3) = 1/2$

随机变量(random variables)

- 一个随机变量是可以用来表示随机结果的变量，取值自某个区间
 - Odd 表示骰子点数是否为奇数？ $\rightarrow \{true, false\}$
 - $Odd(1) = true, Odd(6)=false$
 - T = Is it hot or cold ? $\rightarrow \{hot, cold\}$
 - D = How long will take to get to the airport ? $\rightarrow [0, \infty]$
- 随机变量 X 的概率分布给出了其取值范围内每个值 x 的概率（事件 $X = x$ 的概率）
 - $P(X = x) = \sum_{\{\omega: X(\omega)=x\}} P(\omega)$
 - 例如： $P(Odd = true) = P(1) + P(3) + P(5) = 1/2$




概率分布(probability distribution)

- 把所有取值及其概率关联起来；求和为1

- 温度：

$P(T)$


T	P
hot	0.5
cold	0.5



- 天气：

$P(W)$

W	P
sun	0.6
rain	0.1
fog	0.3
meteor	0.0



- 联合分布

$P(T,W)$

		温度	
		hot	cold
天气	sun	0.45	0.15
	rain	0.02	0.08
	fog	0.03	0.27
	meteor	0.00	0.00

概率分布(probability distribution)

- $P(+x, +y)?$ 0.2
- $P(+x)?$ $0.2+0.3=0.5$
- $P(+x \text{ OR } -y)$ $0.2+0.3+0.1=0.6$


$P(X, Y)$

X	Y	P
+x	+y	0.2
+x	-y	0.3
-x	+y	0.4
-x	-y	0.1

边缘分布(marginal distribution)

- 除了某个变量的其他变量取每个可能值的概率相加

$$P(X=x) = \sum_y P(X=x, Y=y)$$



		Temperature		
		hot	cold	
Weather	sun	0.45	0.15	0.60
	rain	0.02	0.08	0.10
	fog	0.03	0.27	0.30
	meteor	0.00	0.00	0.00
		0.50	0.50	

$P(W)$

$P(T)$

边缘分布(marginal distribution)

$P(X, Y)$

X	Y	P
+x	+y	0.2
+x	-y	0.3
-x	+y	0.4
-x	-y	0.1

$$P(x) = \sum_y P(x, y)$$



$P(X)$


X	P
+x	
-x	

$$P(y) = \sum_x P(x, y)$$



$P(Y)$

Y	P
+y	
-y	



边缘分布(marginal distribution)

$P(X, Y)$

X	Y	P
+x	+y	0.2
+x	-y	0.3
-x	+y	0.4
-x	-y	0.1

$$P(x) = \sum_y P(x, y)$$



$P(X)$


X	P
+x	0.5
-x	0.5

$$P(y) = \sum_x P(x, y)$$




$P(Y)$

Y	P
+y	0.6
-y	0.4



条件概率

- 无条件概率(unconditional probabilities)或先验概率(prior probabilities)
 - 例如: $P(\text{Weather} = \text{sunny}) = 0.5$
- 条件概率(conditional probabilities)或后验概率(posterior probabilities)
 - 例如: $P(\text{Weather} = \text{sunny} | \text{Temperature} = \text{cold}) = 0.3$



$$P(a | b) = \frac{P(a, b)}{P(b)}$$

$P(T, W)$

		Temperature	
		hot	cold
Weather	sun	0.45	0.15
	rain	0.02	0.08
	fog	0.03	0.27
	meteor	0.00	0.00

$$P(W=s | T=c) = \frac{P(W=s, T=c)}{P(T=c)} = 0.15/0.50 = 0.3$$

$$\begin{aligned} &= P(W=s, T=c) + P(W=r, T=c) + P(W=f, T=c) + P(W=m, T=c) \\ &= 0.15 + 0.08 + 0.27 + 0.00 = 0.50 \end{aligned}$$

条件概率

$P(X, Y)$

X	Y	P
+x	+y	0.2
+x	-y	0.3
-x	+y	0.4
-x	-y	0.1

$$P(a|b) = \frac{P(a, b)}{P(b)}$$

■ $P(+x \mid +y)$?

■ $P(-x \mid +y)$?

■ $P(-y \mid +x)$?

条件概率

$P(X, Y)$

X	Y	P
+x	+y	0.2
+x	-y	0.3
-x	+y	0.4
-x	-y	0.1

$$P(a|b) = \frac{P(a, b)}{P(b)}$$

■ $P(+x \mid +y) ?$ $0.2 / 0.6 = 1/3$

■ $P(-x \mid +y) ?$ $0.4 / 0.6 = 2/3$

■ $P(-y \mid +x) ?$ $0.3 / 0.5 = 3/5$

条件概率分布

- 给定一个变量集合，另一个变量集合的概率分布

		Temperature	
		hot	cold
Weather	sun	0.45	0.15
	rain	0.02	0.08
	fog	0.03	0.27
	meteor	0.00	0.00

$P(W \mid T=h)$

hot
0.90
0.04
0.06
0.00

$P(W \mid T=c)$

cold
0.30
0.16
0.54
0.00

$P(W \mid T)$

hot	cold
0.90	0.30
0.04	0.16
0.06	0.54
0.00	0.00

归一化(Normalization)

- 概率之和为1
- 每一项乘 $\alpha = 1/(\text{所有项之和})$

$P(W, T)$

		Temperature	
		hot	cold
Weather	sun	0.45	0.15
	rain	0.02	0.08
	fog	0.03	0.27
	meteor	0.00	0.00

$P(W, T=c)$

0.15
0.08
0.27
0.00

$$P(W | T=c) = P(W, T=c) / P(T=c) \\ = \alpha P(W, T=c)$$

Normalize




$$\alpha = 1/0.50 = 2$$

0.30
0.16
0.54
0.00

乘法规则

$$P(a \mid b)P(b) = P(a, b) \quad \longleftrightarrow \quad P(a \mid b) = \frac{P(a, b)}{P(b)}$$

为了使 a 和 b 都成立，就需要 b 成立，并且在给定 b 成立的前提下 a 也成立



乘法规则


$$P(W | T) P(T) = P(W, T)$$

$P(W | T)$

	hot	cold
0.90	0.90	0.30
0.04	0.04	0.16
0.06	0.06	0.54
0.00	0.00	0.00

$P(T)$

T	P
hot	0.5
cold	0.5



$P(W, T)$

		Temperature	
		hot	cold
Weather	sun	0.45	0.15
	rain	0.02	0.08
	fog	0.03	0.27
	meteor	0.00	0.00

链式法则

重复应用乘法规则，可以得到：

$$P(x_1, x_2, x_3) = P(x_3 \mid x_1, x_2) P(x_1, x_2) = P(x_3 \mid x_1, x_2) P(x_2 \mid x_1) P(x_1)$$

$$\begin{aligned} \mathbf{P}(X_1, \dots, X_n) &= \mathbf{P}(X_1, \dots, X_{n-1}) \mathbf{P}(X_n \mid X_1, \dots, X_{n-1}) \\ &= \mathbf{P}(X_1, \dots, X_{n-2}) \mathbf{P}(X_{n-1} \mid X_1, \dots, X_{n-2}) \mathbf{P}(X_n \mid X_1, \dots, X_{n-1}) \\ &= \dots \\ &= \prod_{i=1}^n \mathbf{P}(X_i \mid X_1, \dots, X_{i-1}) \end{aligned}$$

概率推理

- 概率推理 (probability inference): 给定一个概率模型, 计算某个期望的概率
 - 给定某些证据(evidence)计算某个变量的概率
 - $P(\text{airport on time} \mid \text{no accidents}) = 0.90$
- 随着新的证据出现, 概率也会发生变化
 - $P(\text{airport on time} \mid \text{no accidents}) = 0.90$
 - $P(\text{airport on time} \mid \text{no accidents, raining}) = 0.80$



使用完全联合分布推理

一个有三个布尔变量toothache（牙痛）、cavity（牙齿有洞）、catch（牙医探针污染造成的牙龈感染）组成的问题域，其完全联合分布为：

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

使用完全联合分布推理

一个有三个布尔变量toothache（牙痛）、cavity（牙齿有洞）、catch（牙医探针污染造成的牙龈感染）组成的问题域，其完全联合分布为：

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

$$P(\text{toothache}) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$$

使用完全联合分布推理

一个有三个布尔变量toothache（牙痛）、cavity（牙齿有洞）、catch（牙医探针污染造成的牙龈感染）组成的问题域，其完全联合分布为：

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

$$P(\text{cavity or toothache})$$

$$= 0.108 + 0.012 + 0.016 + 0.064 + 0.072 + 0.008 = 0.28$$

使用完全联合分布推理

一个有三个布尔变量toothache（牙痛）、cavity（牙齿有洞）、catch（牙医探针污染造成的牙龈感染）组成的问题域，其完全联合分布为：

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

$$\begin{aligned} P(cavity|toothache) &= \frac{P(cavity \wedge toothache)}{P(toothache)} \\ &= \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064} = 0.6 \end{aligned}$$

使用完全联合分布推理

一个有三个布尔变量toothache（牙痛）、cavity（牙齿有洞）、catch（牙医探针污染造成的牙龈感染）组成的问题域，其完全联合分布为：

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

$$\begin{aligned} P(\neg cavity | toothache) &= \frac{P(\neg cavity \wedge toothache)}{P(toothache)} \\ &= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = 0.4 \end{aligned}$$

使用完全联合分布推理

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

$$\begin{aligned}\mathbf{P}(\textit{Cavity}|\textit{toothache}) &= \alpha \mathbf{P}(\textit{Cavity}, \textit{toothache}) \\ &= \alpha [\mathbf{P}(\textit{Cavity}, \textit{toothache}, \textit{catch}) + \mathbf{P}(\textit{Cavity}, \textit{toothache}, \neg \textit{catch})] \\ &= \alpha [\langle 0.108, 0.016 \rangle + \langle 0.012, 0.064 \rangle] \\ &= \alpha \langle 0.12, 0.08 \rangle = \langle 0.6, 0.4 \rangle\end{aligned}$$

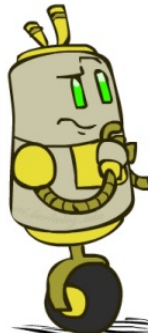
使用完全联合分布推理

- 通用推理过程：

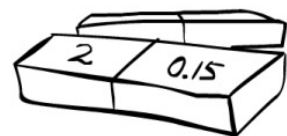
- 考虑只查询一个变量的情况，假设这个变量为 X (这个例子中是 $Cavity$)，假设 E 是证据变量集合（这个例子中只有 $Toothache$ ）， e 表示其观察值；并假设 H 为其余未观测变量（这个例子中是 $Catch$ ），计算过程为：

$$P(X|e) = \alpha P(X, e) = \alpha \sum_h (X, e, h)$$


Step1: 选择(select)与证据变量一致的部分



x	$P(x)$
-3	0.05
-1	0.25
0	0.07
1	0.2
5	0.01



Step2: 对未观测变量求和消元(summing out)



Step3: 归一化(Normalize)

$\times \alpha$

使用完全联合分布推理


- 假设共 n 个变量，每个变量有 d 个取值：
 - 空间复杂度： $O(d^n)$
 - 时间复杂度： $O(d^n)$

可扩展性差！

独立性 (independence)

- A 和 B 是独立的:

$$P(A|B) = P(A) \quad \text{or} \quad P(B|A) = P(B) \quad \text{or} \quad P(A, B) = P(A)P(B)$$



$$32 \rightarrow 2^3 + 4 = 12$$

$$\begin{aligned} &P(\textit{Toothache}, \textit{Catch}, \textit{Cavity}, \textit{Weather}) \\ &= P(\textit{Toothache}, \textit{Catch}, \textit{Cavity})P(\textit{Weather}) \end{aligned}$$

有助于减少问题域表示的规模并降低推理问题的复杂度,

然而现实世界中独立性非常难以满足

条件独立性 (independence)

如果已知病人是否有牙洞， *Toothache* 和 *Catch* 是相互独立的，可以写作：

$$P(\textit{toothache}, \textit{catch} | \textit{cavity}) = P(\textit{toothache} | \textit{cavity}) P(\textit{catch} | \textit{cavity})$$

那么：

$$\begin{aligned} &P(\textit{Toothache}, \textit{Catch}, \textit{Cavity}) \\ &= P(\textit{Toothache}, \textit{Catch} | \textit{Cavity}) P(\textit{Cavity}) \\ &= P(\textit{Toothache} | \textit{Cavity}) P(\textit{Catch} | \textit{Cavity}) P(\textit{Cavity}) \end{aligned}$$

通过条件独立性将一个大的概率问题分解成一些联系非常弱的子集，
是人工智能历史上最重大的进展之一


条件独立性 (independence)

- 考虑如下情况：
 - 堵车 (traffic)
 - 打伞 (umbrella)
 - 下雨 (raining)



条件独立性 (independence)

- 考虑如下情况:
 - 着火 (fire)
 - 冒烟 (smoke)
 - 警报 (alarm)



贝叶斯规则

乘法规则: $P(a|b)P(b) = P(a, b) = P(b|a)P(a)$

⇒ 贝叶斯规则: $P(a|b) = \frac{P(b|a)P(a)}{P(b)}$

为什么贝叶斯规则很有用？

$$P(\text{cause}|\text{effect}) = \frac{P(\text{effect}|\text{cause})P(\text{cause})}{P(\text{effect})}$$



贝叶斯规则是大多数进行概率推理的现代人工智能系统的基础

贝叶斯规则

- 医生知道脑膜炎会引起病人脖子僵硬，比如有70%的可能性；医生还了解一些无条件先验知识：例如，病人脑膜炎的概率为1/50000
- 令 M 表示病人患有脑膜炎， S 表示病人脖子僵硬

$$P(s|m) = 0.7$$

$$P(m) = 1/50000$$

$$P(s) = 0.01$$

- 脖子僵硬的人中，患脑膜炎的概率

$$P(m|s) = \frac{P(s|m)P(m)}{P(s)} = \frac{0.7 * 1/50000}{0.01} = 0.0014$$

贝叶斯规则

$P(W)$

R	P
sun	0.8
rain	0.2

$P(D|W)$

D	W	P
wet	sun	0.1
dry	sun	0.9
wet	rain	0.7
dry	rain	0.3

- $P(W|dry)?$
- $P(sun|dry) = P(dry|sun) * P(sun) = 0.9 * 0.8 = 0.72$
- $P(rain|dry) = P(dry|rain) * P(rain) = 0.3 * 0.2 = 0.14$
- $P(sun|dry) = \frac{0.72}{0.72+0.14} = 12/13$
- $P(rain|dry) = \frac{0.14}{0.72+0.14} = 1/13$

大纲

- 不确定环境

- 概率论基础

- 贝叶斯网：表示


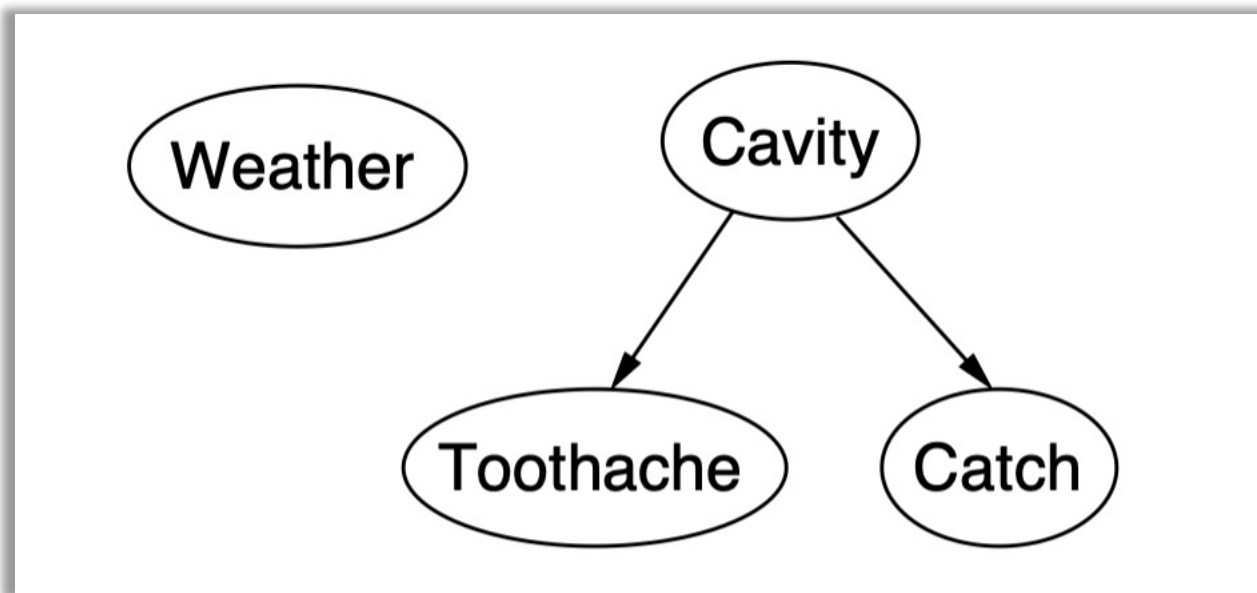
- 贝叶斯网：语法语义

- 贝叶斯网：精确推理

- 贝叶斯网：近似推理

贝叶斯网


- 贝叶斯网(Bayesian network)是一个图模型，用简单的条件分布描述复杂的联合分布
- 图中的边可以用于表示变量之间的依赖关系



- **Weather**独立于其他变量
- 给定**Cavity**后**Toothache**和**Catch**是条件独立的

Example: Coin flip

- n 次独立地掷硬币




- 绝对独立：任意两个变量之间都不具有关联

Example: 堵车

□ 变量:



- T: 堵车
- U: 打伞
- R: 下雨



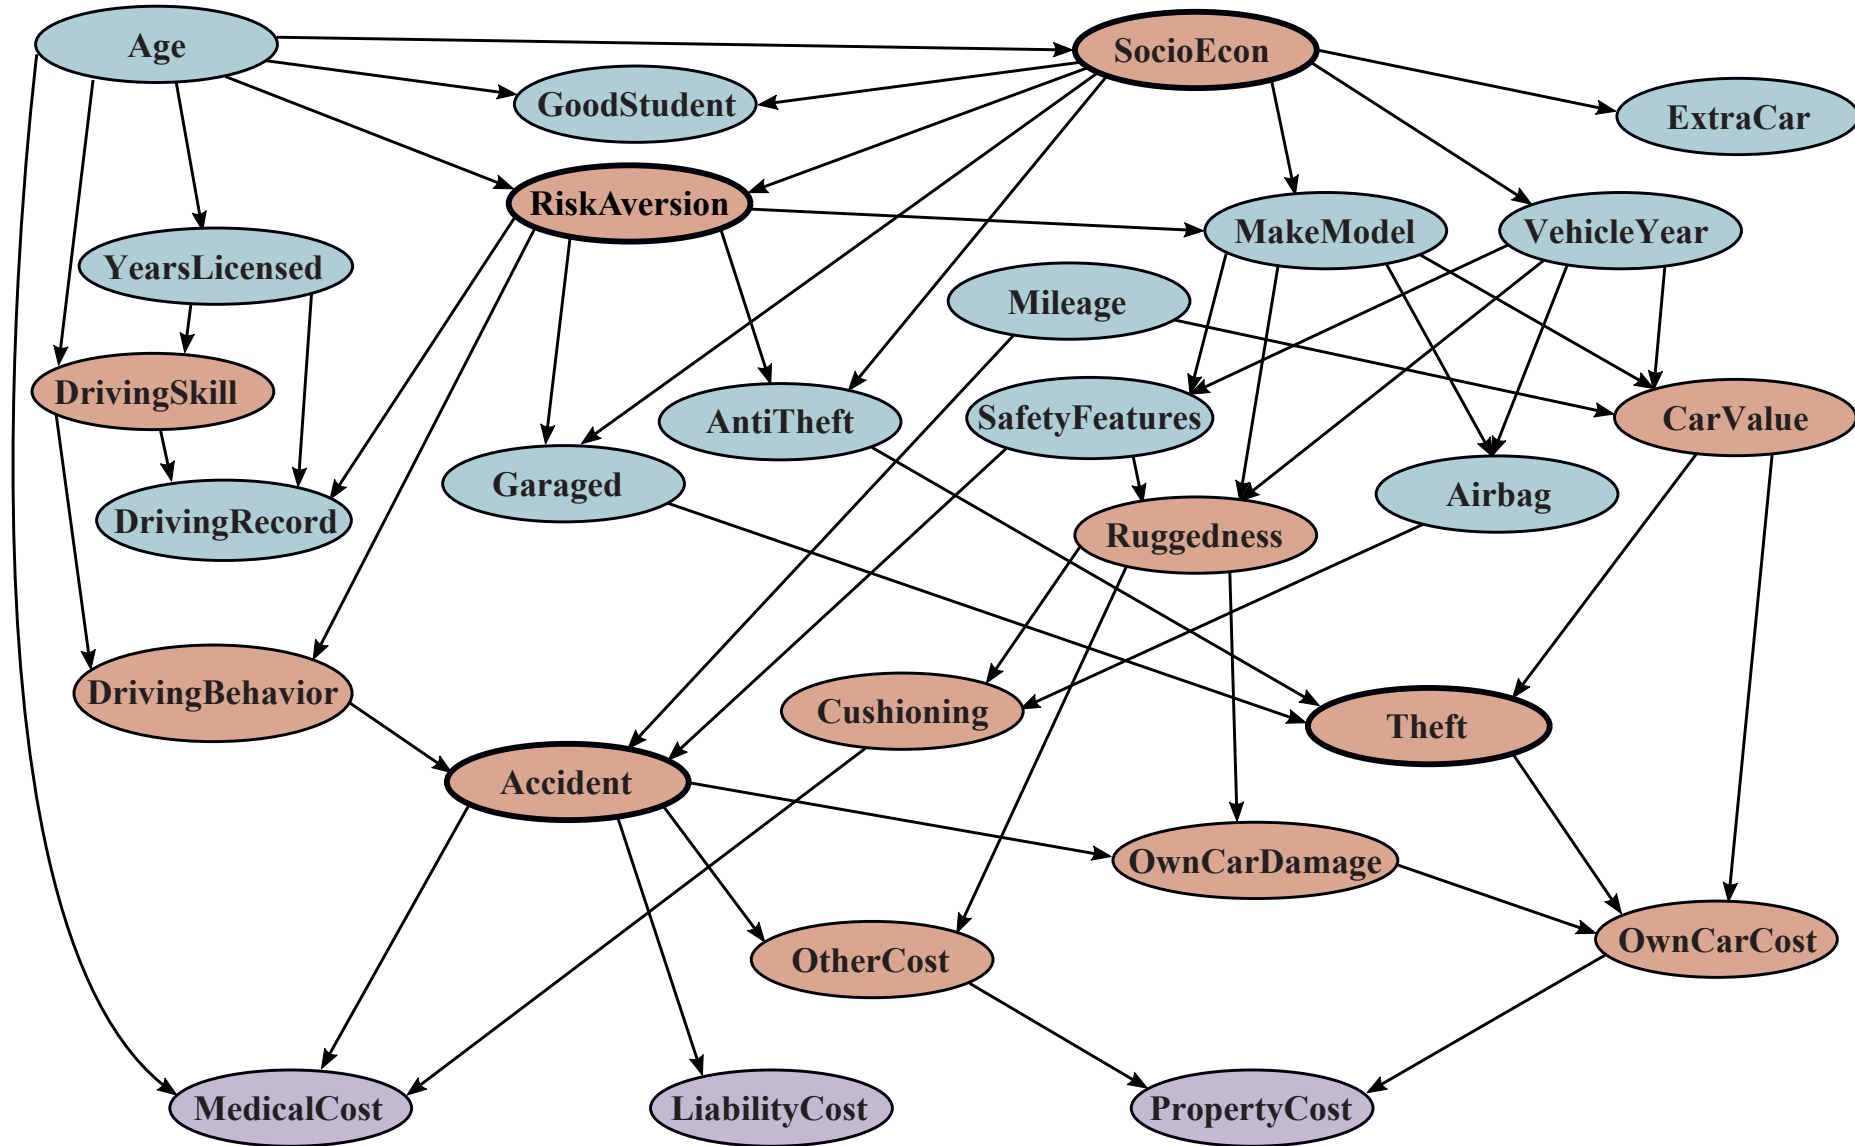
Example：烟雾警报

□ 变量：

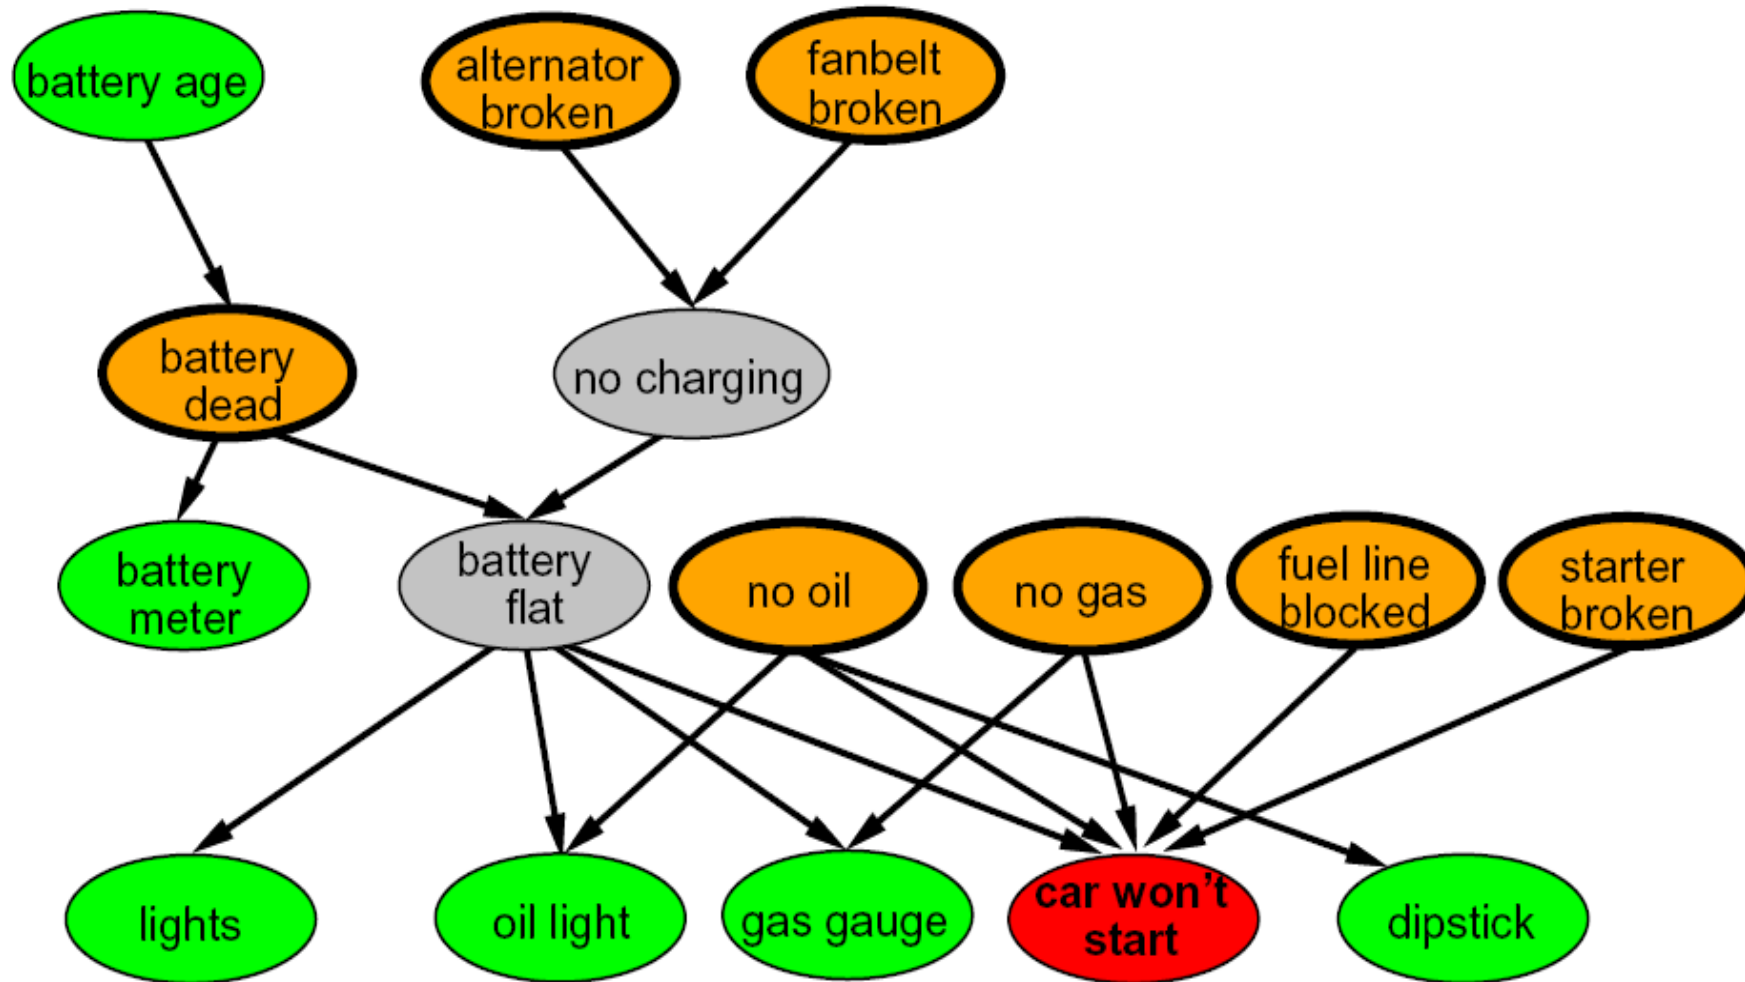
- F: 着火
- S: 烟雾
- A: 烟雾警报



Example Bayes Net: Car Insurance



Example Bayes Net: Car Won't Start

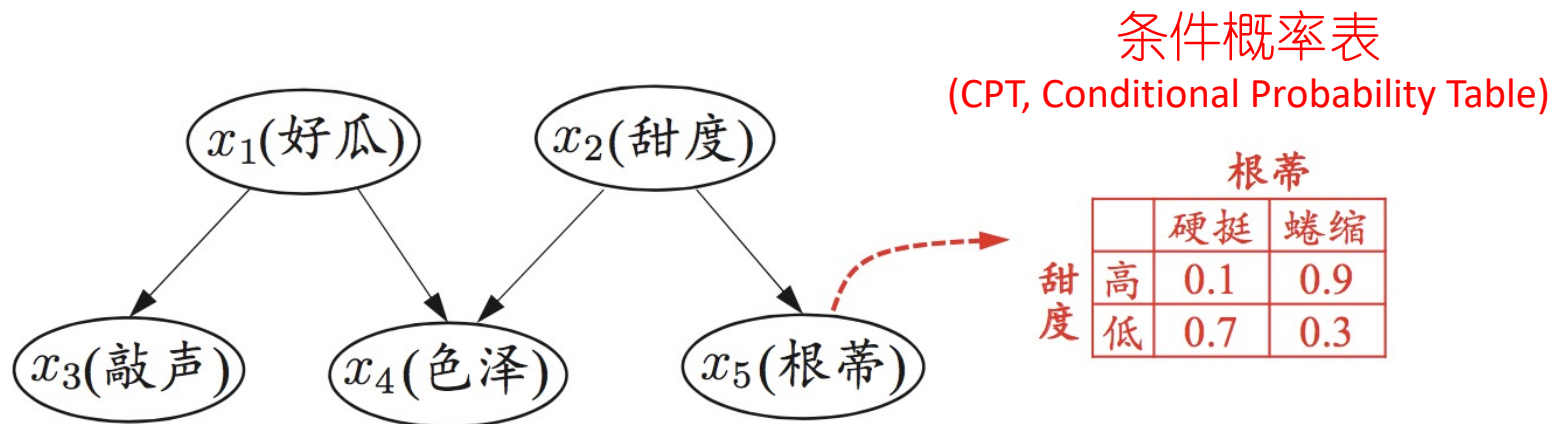


贝叶斯网的语法语义



贝叶斯网：Syntax

- 每个节点对应一个随机变量
- 一组有向边，没有有向回路（有向无环图，DAG）
- 每个节点有一个条件概率分布 $P(X_i | Parents(X_i))$ ，量化其父节点对该节点的影响
 - 条件概率表 (Conditional Probability Table, CPT)



Bayes net = Topology (graph) + Local Conditional Probabilities

例子：防盗报警器


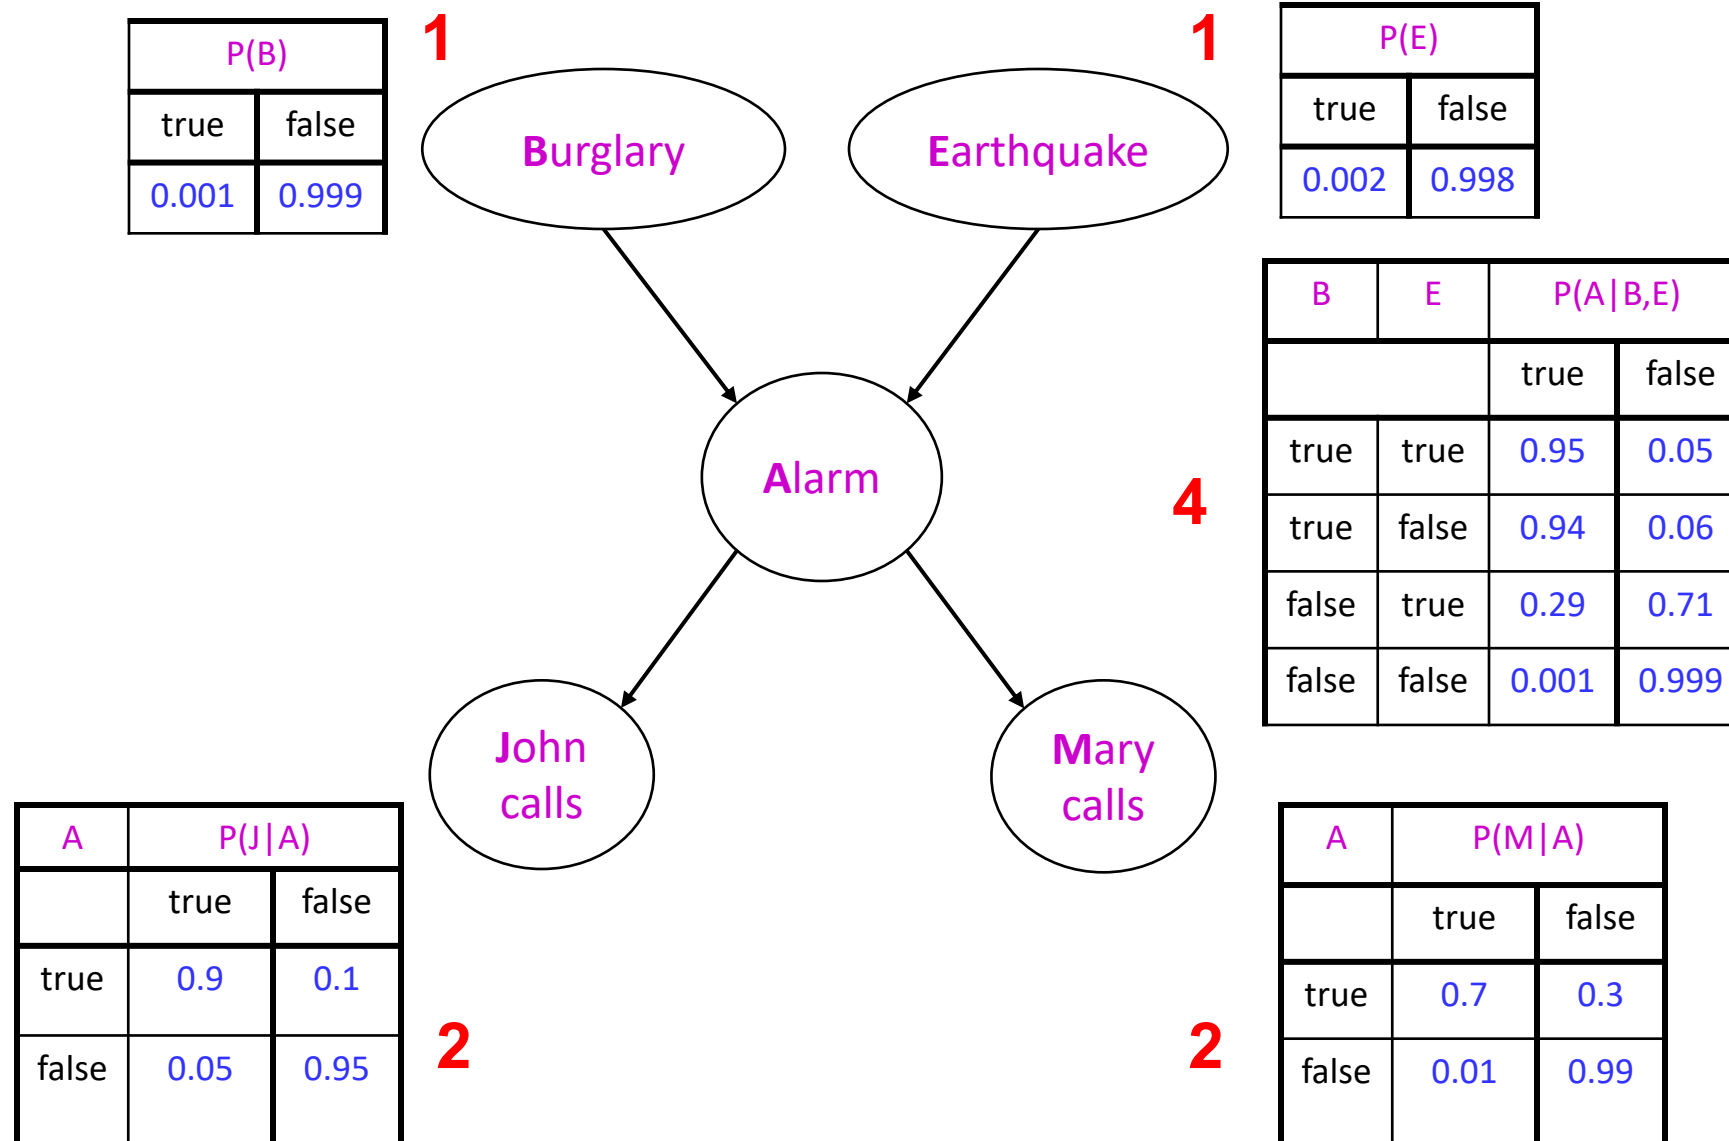
你家里安装了一个新防盗报警器，这个报警器对于探测小偷闯入很可靠，但偶尔也会对轻微的地震有反应。你有两个邻居John和Mary，他们承诺在你工作时听到警报声就给你打电话。John听到警报声总是会给你打电话，但有时候会把电话铃声当成警报声，Mary喜欢大声听音乐，因此有时候听不见警报声。给定他们是否给你打电话，怎么估计有人入室盗窃的概率？

变量：Burglar、Earthquake、Alarm、JohnCalls、MaryCalls

网络结构反映了因果关系：

- 小偷闯入影响警报
- 地震影响警报
- 警报导致Mary打电话
- 警报导致John打电话

例子：防盗报警器



每个CPT表中自由变量的数目？

- 父节点: d_1, \dots, d_k
- 当前节点: d
- 每一行求和为1

$$(d - 1) \prod_i d_i$$

大纲


- 不确定环境
- 概率论基础
- 贝叶斯网：表示
- 贝叶斯网：语法语义
- 贝叶斯网：精确推理
- 贝叶斯网：近似推理

Global Semantic


□ 完整的联合分布可以由局部条件分布的乘积得到：

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(x_i))$$


Example: Coin flip



$$P(h, h, t, h) = ?$$



Example: Traffic



$$P(R)$$

+r	1/4
-r	3/4

$$P(T|R)$$

+r

+t	3/4
-t	1/4

-r


+t	1/2
-t	1/2

$$P(R, T)$$

+r	+t	3/16
+r	-t	1/16
-r	+t	6/16
-r	-t	6/16

例如：

P(B)	
true	false
0.001	0.999



A	P(J A)	
	true	false
true	0.9	0.1
false	0.05	0.95

P(E)	
true	false
0.002	0.998

B	E	P(A B,E)	
		true	false
true	true	0.95	0.05
true	false	0.94	0.06
false	true	0.29	0.71
false	false	0.001	0.999

A	P(M A)	
	true	false
true	0.7	0.3
false	0.01	0.99

$$P(b, \neg e, a, \neg j, \neg m)$$

$$= P(b) P(\neg e) P(a|b, \neg e) P(\neg j|a) P(\neg m|a)$$

$$= .001 \times .998 \times .94 \times .1 \times .3 = .000028$$


紧致性(compactness)

□ 假设：

- n 个随机变量
- 取值集合的大小 d
- 最大父节点的数目 k

□ 完全联合分布： $O(d^n)$

□ 贝叶斯网： $O(nd^{k+1})$



都可以描述完全联合分布，但是贝叶斯网更节省空间，并且更容易获取local CPT