

机器学习导论-线性模型

Introduction to Machine Learning-Linear Model

李文斌

<https://cs.nju.edu.cn/liwenbin>

liwenbin@nju.edu.cn

2024年03月12日

线性可分性

□ 数据的线性可分性 (Linear separability)

令 X_0 和 X_1 表示 n 维欧氏空间的两个点集。如果存在 $n + 1$ 个实数: $w_1, w_2, \dots, w_n, k$, 使得任意 $x \in X_0$, 满足 $\sum_{i=1}^n w_i x_i > k$; 同时任意 $x \in X_1$, 满足 $\sum_{i=1}^n w_i x_i < k$, 那么

X_0 和 X_1 是线性可分的。





$$w^T x > k$$

$$w^T x < k$$

线性可分性

□ 数据的线性可分性 (Linear separability)

令 X_0 和 X_1 表示 n 维欧氏空间的两个点集。如果存在 $n + 1$ 个实数: $w_1, w_2, \dots, w_n, k$, 使得任意 $x \in X_0$, 满足 $\sum_{i=1}^n w_i x_i > k$; 同时任意 $x \in X_1$, 满足 $\sum_{i=1}^n w_i x_i < k$, 那么 X_0 和 X_1 是线性可分的。

		Linear separable	Linear non-separable
直线 line 超平面 hyperplane	2D	 A 2D plot showing two classes of data points (red and blue) separated by a green line. The red points are above the line and the blue points are below it.	 A 2D plot showing two classes of data points (red and blue) that cannot be separated by a single green line. Two arrows point to misclassified points: a red point below the line and a blue point above the line.
	3D	 A 3D plot showing two classes of data points (red and blue) separated by a green hyperplane. The red points are above the plane and the blue points are below it.	 A 3D plot showing two classes of data points (red and blue) that cannot be separated by a single green hyperplane. Two arrows point to misclassified points: a red point below the plane and a blue point above the plane.

感知机


□ 感知机 (Perceptron)

- 1957年由Frank Rosenblatt提出，是神经网络与支持向量机的基础
- 一个典型的二分类线性分类模型，属于判别模型

感知机

□ 感知机 (Perceptron)

- 1957年由Frank Rosenblatt提出，是神经网络与支持向量机的基础
- 一个典型的二分类线性分类模型，属于判别模型




w 为法向量，决定超平面的方向；

b 为位移项，决定了超平面与原点之间的距离

$$f(\mathbf{x}) = \text{sign}(w^T \mathbf{x} + b)$$

$$\text{sign}(x) = \begin{cases} +1, & x \geq 0 \\ -1, & x \leq 0 \end{cases} \quad \text{符号函数}$$

线性模型



□ **线性模型(linear model)**: 试图学得一个通过属性的线性组合来进行预测的函数

- 一般形式: $f(\mathbf{x}) = w_1x_1 + w_2x_2 + \cdots + w_dx_d + b$
- 向量形式: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$
- 特点: 简单、基本、可理解性好

线性回归

□ 线性回归(linear regression) 求解目标:

- 优化参数, 使得预测值接近真实值

$$f(x_i) = wx_i + b \text{ 使得 } f(x_i) \simeq y_i$$

参数 w 和输入变量 x_i 是标量

- 令均方误差最小化, 有 $(w^*, b^*) = \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2$
 $= \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2$

- 对 $E_{(w, b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$ 进行最小二乘参数估计

- **NOTE:** 出现离散属性值, 如果有序, 则连续化; 否则, 转化为 k 维向量

线性回归

□ 线性回归(linear regression) 求解步骤:

- 分别对 w 和 b 求导:

$$\frac{\partial E(w,b)}{\partial w} = 2 \left(w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right)$$
$$\frac{\partial E(w,b)}{\partial b} = 2 \left(mb - \sum_{i=1}^m (y_i - wx_i) \right)$$

- 令导数等于0, 得到闭式(closed-form)解:

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left(\sum_{i=1}^m x_i \right)^2} \quad b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$

- 注: $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$, 即均值

多元线性回归

□ 多元(multi-variate)线性回归求解步骤:

- 参数 $\mathbf{w}$ 和输入变量 $\mathbf{x}_i$ 都是 d 维向量

$$f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b \text{ 使得 } f(\mathbf{x}_i) \simeq y_i$$

$$\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id}) \quad y_i \in \mathbb{R}$$

多元线性回归

□ 多元(multi-variate)线性回归求解步骤:

- 参数 $\mathbf{w}$ 和输入变量 $\mathbf{x}_i$ 都是 d 维向量

$$f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b \text{ 使得 } f(\mathbf{x}_i) \simeq y_i$$

$$\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id}) \quad y_i \in \mathbb{R}$$

- 把 $\mathbf{w}$ 和 b 吸收入向量形式 $\hat{\mathbf{w}} = (\mathbf{w}; b)$, 数据集表示为

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix} \quad \mathbf{y} = (y_1; y_2; \dots; y_m)$$

多元线性回归

□ 多元(multi-variate)线性回归求解步骤:

- 同样采用最小二乘法求解, 有

$$\hat{\mathbf{w}}^* = \arg \min_{\hat{\mathbf{w}}} (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})^T (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}) \longrightarrow \text{欧式距离的平方}$$

- 令 $E_{\hat{\mathbf{w}}} = (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})^T (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})$, 对 $\hat{\mathbf{w}}$ 求导:

$$\frac{\partial E_{\hat{\mathbf{w}}}}{\partial \hat{\mathbf{w}}} = 2\mathbf{X}^T (\mathbf{X}\hat{\mathbf{w}} - \mathbf{y}) = \mathbf{0} \text{ 可解出 } \hat{\mathbf{w}}$$

可以参考《MatrixCookbook》公式 (84)

多元线性回归

□ 多元(multi-variate)线性回归求解步骤:

- 同样采用最小二乘法求解, 有

$$\hat{\mathbf{w}}^* = \arg \min_{\hat{\mathbf{w}}} (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})^T (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})$$

- 令 $E_{\hat{\mathbf{w}}} = (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})^T (\mathbf{y} - \mathbf{X}\hat{\mathbf{w}})$, 对 $\hat{\mathbf{w}}$ 求导:

$$\frac{\partial E_{\hat{\mathbf{w}}}}{\partial \hat{\mathbf{w}}} = 2\mathbf{X}^T (\mathbf{X}\hat{\mathbf{w}} - \mathbf{y}) = 0 \text{ 可解出 } \hat{\mathbf{w}}$$

涉及矩阵求逆!

- 结论:

- 若 $\mathbf{X}^T \mathbf{X}$ 满秩或正定, 则 $\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$
- 若 $\mathbf{X}^T \mathbf{X}$ 不满秩或非正定, 则可以解出多个 $\hat{\mathbf{w}}$


此时需求助于归纳偏好, 或引入正则化 (regularization)

线性模型的变化

□ 对于样例 (x, y) , $y \in \mathbb{R}$, 若希望线性模型的预测值逼近真实标记, 则得到线性回归模型 $y = \mathbf{w}^T \mathbf{x} + b$

如何令预测值逼近 y 的衍生物?

- 若令 $\ln y = \mathbf{w}^T \mathbf{x} + b$, 则得到对数线性回归 (log-linear regression)
- 实际是在用 $e^{\mathbf{w}^T \mathbf{x} + b}$ 逼近 y , 实现非线性映射



广义(generalized)线性模型

□ 一般形式: $y = g^{-1}(w^T x + b)$



单调可微的**联系函数** (link function)

□ 令 $g(\cdot) = \ln(\cdot)$ 则得到对数线性回归

$$\ln y = w^T x + b$$

二分类任务

线性回归模型产生的实值输出 $z = \mathbf{w}^T \mathbf{x} + b$
期望输出 $y \in \{0,1\}$ } 找 z 和 y 的
联系函数

二分类任务

线性回归模型产生的实值输出 $z = \mathbf{w}^T \mathbf{x} + b$
期望输出 $y \in \{0,1\}$ } 找 z 和 y 的联系函数

□ 单位阶跃函数 (unit-step function)


$$y = \begin{cases} 0, & z < 0 \\ 0.5, & z = 0 \\ 1, & z > 0 \end{cases}$$

性质不好, 不连续
需要寻找代替

□ 对数几率函数 (logistic function)

$$y = \frac{1}{1 + e^{-z}}$$

单调可微、任意阶可导
一种Sigmoid函数



注意: Logistic与“逻辑”没有任何关系

对数几率回归

□ “对数几率回归” (logistic regression) 简称 “对率回归”

- 无需事先假设数据分布
- 可得到 “类别” 的近似概率预测
- 可直接应用现有数值优化算法求取最优解
- **是分类算法**

□ 以对数几率函数为联系函数

几率(odds), 反映了 x 作为正例的相对可能性

$$y = \frac{1}{1 + e^{-z}} \quad \longrightarrow \quad y = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad \longrightarrow \quad \ln \frac{y}{1 - y} = \mathbf{w}^T \mathbf{x} + b$$

“对数几率” (log odds, 亦称 logit)

对数几率回归

□ 对数几率回归求解思路：将 y 看作后验概率估计 $p(y = 1 | x)$

$$\ln \frac{y}{1-y} = \mathbf{w}^T \mathbf{x} + b \quad \text{可写为} \quad \ln \frac{p(y = 1 | \mathbf{x})}{p(y = 0 | \mathbf{x})} = \mathbf{w}^T \mathbf{x} + b$$

□ 可以使用 **“极大似然法”** (maximum likelihood method)

□ 给定数据集 $\{(\mathbf{x}_i, y_i)\}_{i=1}^m$, 最大化 “对数似然” 函数

$$\ell(\mathbf{w}, b) = \sum_{i=1}^m \ln p(y_i | \mathbf{x}_i; \mathbf{w}, b)$$

对数几率回归

□ 令 $\beta = (\mathbf{w}; b)$, $\hat{\mathbf{x}} = (\mathbf{x}; 1)$, 则 $\mathbf{w}^T \mathbf{x} + b$ 可简写为 $\beta^T \hat{\mathbf{x}}$

□ 再令 $p_1(\hat{\mathbf{x}}_i; \beta) = p(y = 1 \mid \hat{\mathbf{x}}; \beta) = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$




$$p_0(\hat{\mathbf{x}}_i; \beta) = p(y = 0 \mid \hat{\mathbf{x}}; \beta) = 1 - p_1(\hat{\mathbf{x}}_i; \beta) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

对数几率回归


- 令 $\beta = (\mathbf{w}; b)$, $\hat{\mathbf{x}} = (\mathbf{x}; 1)$, 则 $\mathbf{w}^T \mathbf{x} + b$ 可简写为 $\beta^T \hat{\mathbf{x}}$
- 再令 $p_1(\hat{\mathbf{x}}_i; \beta) = p(y = 1 \mid \hat{\mathbf{x}}; \beta) = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$
 $p_0(\hat{\mathbf{x}}_i; \beta) = p(y = 0 \mid \hat{\mathbf{x}}; \beta) = 1 - p_1(\hat{\mathbf{x}}_i; \beta) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$
- 似然项可以重写成 $p(y_i \mid \mathbf{x}_i; \mathbf{w}_i, b) = y_i p_1(\hat{\mathbf{x}}_i; \beta) + (1 - y_i) p_0(\hat{\mathbf{x}}_i; \beta)$
- 于是, 最大化似然函数 $\ell(\mathbf{w}, b) = \sum_{i=1}^m \ln p(y_i \mid \mathbf{x}_i; \mathbf{w}, b)$
等价于最小化 $\ell(\beta) = \sum_{i=1}^m \left(-y_i \beta^T \hat{\mathbf{x}}_i + \ln \left(1 + e^{\beta^T \hat{\mathbf{x}}_i} \right) \right)$

高阶可导连续凸函数, 可用经典的数值优化方法如梯度下降法/牛顿法

回归线性模型做“分类”




如何“直接”做分类？



广义线性模型；
通过“联系函数”

例如，对率回归

线性判别分析 (Linear Discriminant Analysis)



由于将样例投影到一条直线（低维空间），因此也被视为一种“监督降维”技术

LDA的目标

□ 给定数据集 $\{(\mathbf{x}_i, y_i)\}_{i=1}^m$

- 第 i 类示例的集合 X_i
- 第 i 类示例的均值向量 μ_i
- 第 i 类示例的协方差矩阵 Σ_i
- 两类样本的中心在直线上的投影: $\mathbf{w}^T \mu_0$ 和 $\mathbf{w}^T \mu_1$
- 两类样本的协方差: $\mathbf{w}^T \Sigma_0 \mathbf{w}$ 和 $\mathbf{w}^T \Sigma_1 \mathbf{w}$

□ 要求

- 同类样例的投影点尽可能接近 $\rightarrow \mathbf{w}^T \Sigma_0 \mathbf{w} + \mathbf{w}^T \Sigma_1 \mathbf{w}$ 尽可能小
- 异类样例的投影点尽可能远离 $\rightarrow \|\mathbf{w}^T \mu_0 - \mathbf{w}^T \mu_1\|_2^2$ 尽可能大

LDA的目标

□ 给定数据集 $\{(\mathbf{x}_i, y_i)\}_{i=1}^m$

- 第 i 类示例的集合 X_i
- 第 i 类示例的均值向量 μ_i
- 第 i 类示例的协方差矩阵 Σ_i
- 两类样本的中心在直线上的投影: $\mathbf{w}^T \mu_0$ 和 $\mathbf{w}^T \mu_1$
- 两类样本的协方差: $\mathbf{w}^T \Sigma_0 \mathbf{w}$ 和 $\mathbf{w}^T \Sigma_1 \mathbf{w}$

□ 要求

- 同类样例的投影点尽可能接近 $\rightarrow \mathbf{w}^T \Sigma_0 \mathbf{w} + \mathbf{w}^T \Sigma_1 \mathbf{w}$ 尽可能小
- 异类样例的投影点尽可能远离 $\rightarrow \|\mathbf{w}^T \mu_0 - \mathbf{w}^T \mu_1\|_2^2$ 尽可能大

□ 于是最大化:

$$J = \frac{\|\mathbf{w}^T \mu_0 - \mathbf{w}^T \mu_1\|_2^2}{\mathbf{w}^T \Sigma_0 \mathbf{w} + \mathbf{w}^T \Sigma_1 \mathbf{w}} = \frac{\mathbf{w}^T (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T \mathbf{w}}{\mathbf{w}^T (\Sigma_0 + \Sigma_1) \mathbf{w}}$$

LDA的目标

□ 类内散度矩阵 (within-class scatter matrix)

$$\begin{aligned}\mathbf{S}_w &= \mathbf{\Sigma}_0 + \mathbf{\Sigma}_1 \\ &= \sum_{\mathbf{x} \in X_0} (\mathbf{x} - \boldsymbol{\mu}_0)(\mathbf{x} - \boldsymbol{\mu}_0)^T + \sum_{\mathbf{x} \in X_1} (\mathbf{x} - \boldsymbol{\mu}_1)(\mathbf{x} - \boldsymbol{\mu}_1)^T\end{aligned}$$

□ 类间散度矩阵 (between-class scatter matrix)

$$\mathbf{S}_b = (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T$$

□ LDA的目标: 最大化广义瑞利商 (generalized Rayleigh quotient)

$$J = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}} \quad \begin{array}{l} \mathbf{w} \text{ 成倍缩放不影响} \\ J \text{ 值仅考虑方向} \end{array}$$

LDA的求解思路

□ 令 $\mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1$, 最大化广义瑞利商等价形式为

$$\begin{aligned} \min_{\mathbf{w}} & -\mathbf{w}^T \mathbf{S}_b \mathbf{w} \\ \text{s.t. } & \mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1 \end{aligned}$$

□ 运用拉格朗日乘子法, 有: $\mathbf{S}_b \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$

$$\text{由 } \mathbf{S}_b \text{ 定义, 有: } \mathbf{S}_b \mathbf{w} = (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}$$

□ 注意到 $(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}$ 是标量, 令其等于 λ

$$\text{于是: } \mathbf{w} = \mathbf{S}_w^{-1}(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)$$

□ 实践中通常是进行奇异值分解 $\mathbf{S}_w = \mathbf{U} \boldsymbol{\Sigma} \mathbf{V}^T$

$$\text{然后 } \mathbf{S}_w^{-1} = \mathbf{V} \boldsymbol{\Sigma}^{-1} \mathbf{U}^T$$

LDA推广到多类

□ 假定有 N 个类

- 全局散度矩阵 $\mathbf{S}_t = \mathbf{S}_b + \mathbf{S}_w = \sum_{i=1}^m (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$
- 类内散度矩阵 $\mathbf{S}_w = \sum_{i=1}^N \mathbf{S}_{w_i} \quad \mathbf{S}_{w_i} = \sum_{\mathbf{x} \in X_i} (\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)^T$
- 类间散度矩阵 $\mathbf{S}_b = \mathbf{S}_t - \mathbf{S}_w = \sum_{i=1}^N m_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^T$

□ 多分类LDA有多种实现方法：采用 $\mathbf{S}_b, \mathbf{S}_w, \mathbf{S}_t$ 中的任何两个

$$\max_{\mathbf{W}} \frac{\text{tr}(\mathbf{W}^T \mathbf{S}_b \mathbf{W})}{\text{tr}(\mathbf{W}^T \mathbf{S}_w \mathbf{W})} \Rightarrow \mathbf{S}_b \mathbf{W} = \lambda \mathbf{S}_w \mathbf{W} \quad \mathbf{W} \in \mathbb{R}^{d \times (N-1)}$$


$\mathbf{W}$ 闭式解是 $\mathbf{S}_w^{-1} \mathbf{S}_b$ 的 $d' (\leq N - 1)$ 个最大非零广义特征值对应的特征向量组成的矩阵

多分类学习

□ 拆解法：将一个多分类任务拆分为若干个二分类任务求解


➤ OvO

- 训练 $N(N-1)/2$ 个分类器，存储开销和测试时间大
- 训练只用两个类的样例，训练时间短



➤ OvR

- 训练 N 个分类器，存储开销和测试时间小
- 训练用到全部训练样例，训练时间长




预测性能取决于具体数据分布，多数情况下两者差不多

多分类学习

□ 纠错输出码 (Error Correcting Output Code)


多对多(Many vs Many, MvM): 将若干类作为正类, 若干类作为反类

编码: 对 N 个类别做 M 次划分, 每次将一部分类别划为正类, 一部分划为反类




M 个二类任务;
(原)每类对应一个长为 M 的编码

距离最小的类为
最终结果



解码: 测试样本交给 M 个分类器预测



长为 M 的预测结果编码

多分类学习

	f_1	f_2	f_3	f_4	f_5	海明距离	欧氏距离
$C_1 \rightarrow$	-1	+1	-1	+1	+1	3	$2\sqrt{3}$
$C_2 \rightarrow$	+1	-1	-1	+1	-1	4	4
$C_3 \rightarrow$	-1	+1	+1	-1	+1	1	2
$C_4 \rightarrow$	-1	-1	+1	+1	-1	2	$2\sqrt{2}$
测试示例 $\rightarrow$	-1	-1	+1	-1	+1		

(a) 二元 ECOC 码

[Dietterich and Bakiri,1995]

	f_1	f_2	f_3	f_4	f_5	f_6	f_7	海明距离	欧氏距离
$C_1 \rightarrow$	-1	-1	+1	+1	-1	+1	+1	4	4
$C_2 \rightarrow$	-1	0	0	0	+1	-1	0	2	2
$C_3 \rightarrow$	+1	+1	-1	-1	-1	+1	-1	5	$2\sqrt{5}$
$C_4 \rightarrow$	-1	+1	0	+1	-1	0	+1	3	$\sqrt{10}$
测试示例 $\rightarrow$	-1	+1	+1	-1	+1	-1	+1		

(b) 三元 ECOC 码

[Allwein et al. 2000]

- ECOC编码对分类器错误有一定容忍和修正能力，编码越长、纠错能力越强
- 对同等长度的编码，理论上来说，任意两个类别之间的编码距离越远，则纠错能力越强

类别不平衡 (class-imbalance)

- 不同类别的样本比例相差很大；“小类”往往更重要
- 基本思路：

若 $\frac{y}{1-y} > 1$ 则预测为正类



若 $\frac{y}{1-y} > \frac{m^+}{m^-}$ 则预测为正类

- 基本策略——“再缩放” (rescaling):

$$\frac{y'}{1-y'} = \frac{y}{1-y} \times \frac{m^-}{m^+}$$

- 然而精确估计 $\frac{m^+}{m^-}$ 通常很困难!

- 常见类别不平衡方法：

- 过采样 (oversampling), 例如: SMOTE
- 欠采样 (undersampling), 例如: EasyEnsemble
- 阈值移动 (threshold-moving)

谢谢!

联系方式: liwenbin@nju.edu.cn

更多信息: <https://cs.nju.edu.cn/liwenbin>

Linux的使用和常用命令

助教：李兵

522023330043@smail.nju.edu.cn

2024年3月5日

目录

- ❑ **Linux相关**

- ❑ **Linux的使用**

- ❑ **Linux常用命令介绍**


- ❑ **总结**

Linux相关

□ Linux的诞生

□ 创始人 Linus Torvalds (林纳斯 托瓦兹)

□ 时间 1991



PS:现有的操作系统不好用, 于是创始人决心自己写一个保护模式下的操作系统, 这就是Linux的原型。



Linux相关

□ Linux的组成

- Linux系统内核（CPU调度，内存调度等）
- 系统级应用程序（文件管理等）

内核提供最核心的功能（**开源**，可以查看并修改）

系统应用程序：可以理解为出厂自带程序



Linux相关

□ 开源

- 可以修改内核，集成系统程序
- 内核+系统级程序(封装) = Linux发行版 (centos,ubuntu,fedora,Debian,puppy等)



目录

□ Linux相关


□ Linux的使用

□ Linux常用命令介绍

□ 总结

Linux的使用

- 操作系统的使用
 - 图形化页面使用操作系统
 - 命令形式使用操作系统




获得图形化反馈进行使用

```
(base) [muzi@localhost ~]$ ls
Atom Desktop Downloads Miniconda3-latest-L
data Documents miniconda3 Music
(base) [muzi@localhost ~]$ mkdir atom
(base) [muzi@localhost ~]$ cd atom
(base) [muzi@localhost atom]$ touch hello.txt
(base) [muzi@localhost atom]$ ls
hello.txt
(base) [muzi@localhost atom]$
```

获得字符反馈进行使用

Linux的使用

□ 操作系统的使用



```
Microsoft Windows [版本 10.0.22621.3155]
(c) Microsoft Corporation。保留所有权利。

C:\Users\Administrator>cd ..

C:\Users>cd ..

C:\>dir
驱动器 C 中的卷没有标签。
卷的序列号是 123D-1A1B

C:\ 的目录


2023/09/16  14:01                20 config.ini
2023/11/10  14:39            12,288 DumpStack.log
2023/09/16  14:00      <DIR>      LenovoDrivers
2022/05/07  13:24      <DIR>      PerfLogs
2024/02/28  11:07      <DIR>      Program Files
2024/01/22  11:52      <DIR>      Program Files (x86)
2024/03/02  13:48      <DIR>      texlive
2023/09/25  18:12      <DIR>      Users
2024/02/24  03:51      <DIR>      Windows

                2 个文件          12,308 字节
                7 个目录 321,573,376,000 可用字节

C:\>
```


Linux的使用

□ 操作系统的使用



```
muzi@localhost:~  
File Edit View Search Terminal Help  
(base) [muzi@localhost ~]$ ls  
atom Desktop miniconda3 Pictures Videos  
atom Documents Miniconda3-latest-Linux-x86_64.sh Public  
data Downloads Music Templates  
(base) [muzi@localhost ~]$
```

Linux的使用

□ 发行版的选择

- Centos (主)
- ubuntu

□ 安装系统

- 虚拟机 (主) (默认大家会安装并且安装成功)
- WSL (Windows Subsystem for Linux , 系统自带)
 - 可以在Windows系统中获得Linux系统环境, 并完全直连计算机硬件。

目录

- Linux相关
- Linux的使用
- **Linux常用命令介绍**
- 总结

Linux常用命令介绍

❑ Linux应用商店 (centos)

- ❑ yum命令安装软件(包软件管理器，自动化安装配置Linux软件，自动解决依赖)
- ❑ yum [-y] [install | remove | search] 软件名称
- ❑ -y :表示自动确认
- ❑ Install 分别表示安装，卸载，搜索。

❑ 注：

- ❑ 需要root权限（可以su进行切换，或sudo提升权限）
- ❑ 使用该命令需要连接网络

❑ ： 范例

- ❑ yum install/remove/search wget
- ❑ yum update installed

Linux常用命令介绍

□ Linux命令格式

command + -options + parameter

- command: 命令本身
- -options: 可选项, 控制命令的行为细节
- parameter: 命令参数, 多用于指向目标

Linux常用命令介绍

□ 文件展示命令 (ls)

□ ls命令 (ls [-a -l -h] [路径])

- 展示路径下的内容
- 无参数：表示平铺当前工作目录下面的内容
- -a (all) ：表示列出全部文件，包括隐藏文件或者隐藏文件夹
- -l (list) ：以列表的形式展示内容，并展示更多信息
- -a -l, -al, -la
- -h ：以易于阅读形式列出文件大小 (K,M,G) ,必须搭配l一起使用 (如ls -lh)

Linux常用命令介绍

- ❑ 目录切换命令(cd pwd)
- ❑ cd 命令 (cd [路径])
 - ❑ 切换到想要去的目录
 - ❑ 不带参数，表示回到主目录。（即用户的home目录）
 - ❑ 带参数，表示切换到哪个目录下
 - ❑ 注意相对路径和绝对路径 cd /home/lb/Desktop = cd Desktop
 - ❑ 注意特殊路径符（. 表示当前目录 .. 表示上一级目录 ~表示主目录）
- ❑ pwd命令 (pwd)
 - ❑ 查看当前工作目录

Linux常用命令介绍

- 创建文件夹/文件命令 (**mkdir touch**)
- **mkdir**命令 (**mkdir [-p] [路径]**) (注意需要的权限等)
 - 用于在相应位置创建新的文件夹
 - 参数必填，表示创建文件夹的路径，绝对相对均可
 - -p可选，用于一次性创建多个层级目录
- **touch**命令 (**touch [路径]**)
 - 用于在相应位置创建新的文件
 - 参数必填，无选项，相对/绝对/特殊路径符均可

Linux常用命令介绍

- 查看文件命令 (**cat more**)
- 查看文件命令 (**cat [路径]**)
 - 查看相应路径的文件
 - 参数必填，无选项，相对/绝对/特殊路径符均可
- 查看文件命令 (**more [路径]**)
 - 查看相应路径的文件
 - 参数必填，无选项，相对/绝对/特殊路径符均可，可以通过空格翻页

Linux常用命令介绍

- 文件操作命令(cp mv rm)

- cp命令 (cp [-r] [路径1] [路径2])

- 用于复制文件或者文件夹
- -r选项用于复制文件夹
- 路径1：表示被复制的文件/文件夹
- 路径2：表示要复制去的地方

- mv命令 (mv [路径1] [路径2])

- 移动文件或者文件夹
- 路径1：被移动的文件或者文件夹
- 路径2：要移动去的地方（需要确保目标存在）

Linux常用命令介绍

- 文件操作命令(cp mv rm)
- rm命令 (rm [-r -f] [路径1] [路径2]...[路径n])
 - 用于删除文件或者文件夹
 - -r选项用于删除文件夹
 - -f选项表示强制删除 (force)
 - 路径之间用空格隔开, 表示删除的文件或者文件夹的路径
 - rm命令支持通配符*
 - 慎用 rm -rf/ rm -rf /*

Linux常用命令介绍

- ❑ 查找命令 (**which find**)
- ❑ which命令 (**which 查找的命令**)
 - ❑ 可以用which查看使用的一系列的程序文件的存放位置
- ❑ find命令 (**find 起始路径 -name 文件名**)
 - ❑ 按照文件名字搜索文件
 - ❑ 可以与通配符使用，达到模糊查询的效果。
- ❑ find命令 (**find 起始路径 -size +/- -n[kMG]**)
 - ❑ 按照文件大小搜索文件
 - ❑ +/-表示大于和小于，n表示数字大小，kMG表示单位

Linux常用命令介绍

- ❑ 其他常用命令 (`grep` `wc` 管道符 `echo` `tail` 重定向符 `vi` `vim`编辑器)
- ❑ `grep`命令 (`grep [-n] 关键字 [路径]`)
 - ❑ 在文件中通过关键字过滤文件行
 - ❑ `-n` : 可选, 表示显示匹配的行号
 - ❑ 关键字: 表示需要过滤的关键字
 - ❑ 路径: 表示需要过滤的文件所在的路径, 可作为内容输入端口
- ❑ `wc`命令 (`wc [-c -m -l -w] [路径]`)
 - ❑ 统计文件的行数, 单词数量等等。
 - ❑ `c` (bytes) , `m` (字符) , `l` (行数) , `w` (单词数量)
 - ❑ 路径: 被统计的文件, 可作为内容输入端口

Linux常用命令介绍

- 其他常用命令 (grep wc 管道符 echo tail 重定向符 vi vim编辑器)
- 管道符 | (|)
 - 左边命令的输出, 作为右边命令的输入
- echo (echo 想要输出的内容)
 - 在命令行中输出指定的内容
 - 注意与 '可以结合使用
 - 注意与重定向符> (>>) 结合使用 (左侧命令的结果, 覆盖 (追加) 写入右侧)

Linux常用命令介绍

- ❑ 其他常用命令 (grep wc 管道符 echo tail 重定向符 vi vim编辑器)
- ❑ tail (tail [-f -num] [路径])
 - ❑ 查看文件尾部内容，跟踪文件最新修改
 - ❑ -f表示持续跟踪
 - ❑ -num表示查看尾部多少行，默认值为10
- ❑ vi(vim) (vi(vim) [路径])
 - ❑ Linux中最经典的文本编辑器，vim是vi的加强版，兼容所有vi指令并且具有shell程序编辑功能。
 - ❑ Command模式：敲击的按键编辑器都理解为命令，不能进行文本编辑。
 - ❑ Insert模式：可以对文件进行编辑，点击insert键即可。
 - ❑ 底线命令模式：用于文件的保存和退出。

Linux常用命令介绍

□ 其他常用命令 (**grep wc 管道符 echo tail 重定向符 vi vim编辑器**)

□ 示例

- 使用vim 2024.txt进行文件编辑，此时进入了命令模式。
- 按i或者insert,进入输入模式。
- 输入自己想要输入的内容。
- 按esc,退回命令模式
- 按:,进入底线命令模式
- 输入wq,表示保存并退出。

Linux常用命令介绍

□ 命令行模式常用命令

命令	说明
x、X	x是删除下一个字符，X是删除上一个字符 如果想删除10个字符，那就" 10x "
dd	剪切（删除）光标所在行 如果想要删除20行，那就" 20dd "
yy	复制光标所在行 如果想要复制20行，那就" 20yy "
p、P	p是粘贴到下一行，P是粘贴到上一行
u	撤销
Ctrl+r	反撤销
.(小数点)	重复上一个动作
gg、G	gg是回到第一行，G是回到最后一行 如果想要回到第20行，那就" 20G "
y1G、yG	y1G是复制当前行前面的所有数据，yG是复制当前行之后的全部数据
d1G、dG	d1G是删除当前行前面的所有数据，dG是删除当前行之后的全部数据
v、V、Ctrl+v	v是光标起始和结束之间的文本会被选中，V是光标起始和结束之间的所有行被选中，Ctrl+v是光标起始和结束之间构成的矩形区域被选中

Linux的使用

□ 编辑模式常用命令

命令	说明
i、I	i是从光标所在位置开始输入，I是光标所在行第一个非空白字符开始输入
a、A	a是从光标所在的下一个字符开始输入，A是从光标所在行的最后一个字符开始输入
o、O	o是从光标所在行的下一行新的一行开始输入，O是从光标所在行的上一行新的一行开始输入
r、R	r是取代光标所在的字符一次，R是依次取代光标所在字符

□ 底线命令模式常用命令

命令	说明
:w	保存
:q	退出
:wq 或 ZZ	保存并退出
:q! 或 ZQ	不保存退出
:set nu	显示行号
:set nonu	隐藏行号
:/搜索的文本	搜索
:%s/要替换的字符/替换后的字符/g	全局替换文本

目录

- Linux相关
- Linux的使用
- Linux常用命令介绍
- 总结

总结

- ❑ 文件展示命令 (**ls**)
- ❑ 目录切换相关命令 (**cd/pwd**)
- ❑ 创建文件/文件夹命令 (**touch/mkdir**)
- ❑ 查看文件命令 (**cat/more**)
- ❑ 文件操作命令 (**cp/mv/rm**)
- ❑ 查找命令 (**which/find**)
- ❑ 其他常用命令 (**grep/wc/管道符/echo/tail/重定向符/vi/vim编辑器**)

谢谢!