

机器学习导论-持续学习

Introduction to Machine Learning-Continual Learning

李文斌

<https://cs.nju.edu.cn/liwenbin>


liwenbin@nju.edu.cn

2024年05月28日

背景引入

深度学习的困境

深度学习凭借优异的性能在图像识别、自然语言处理、视频分析等任务中取得巨大的成功！



灾难性遗忘现象

[Kolouri et al. arXiv 2019]

当面对**分布差异大的序列任务学习**，深度学习往往会出现**迅速破坏之前学到的旧任务知识**的现象，即**灾难性遗忘**（Catastrophic forgetting）

从神经科学的角度

人类等高级动物天生具备**终生学习能力**，能够利用旧任务的知识帮助新任务的学习，同时将新任务知识整合进现有知识体系




“活到老学到老”

从神经科学的角度

人类等高级动物天生具备**终生学习能力**，能够利用旧任务的知识帮助新任务的学习，同时将新任务知识整合进现有知识体系

□ 一些生物学和神经科学的发现：

- ✓ 稳定性-可塑性平衡
- ✓ 互补学习系统理论




受此启发，学术界开始研究如何在**记忆旧知识**的同时**通过迁移**加快**新任务**的学习，使模型在**序列任务数据**中持续不断的学习范式——**持续学习 (continual learning)**

持续学习概念简介

任务定义

持续学习：研究从**持续到来的不同任务**中学习并积累知识，逐渐扩充模型，也称为增量学习（incremental learning）、终生学习（lifelong learning）

✓ 任务顺序到来：当前任务的数据在后续任务中不再出现，即数据以流的形式存在



□ 稳定性-可塑性平衡

- ✓ 可塑性：模型能从新任务中学到所需的知识
- ✓ 稳定性：模型能尽量保留完成旧任务的必备经验

灾难性遗忘

模型在持续学习过程中，学习了新任务或数据之后，几乎彻底遗忘掉之前获得的知识，导致在旧任务上的性能大幅下降

□ 根本原因

- ✓ 传统离线非序列任务：深度模型可以重复不断地交错访问和学习任务数据中的知识直到模型饱和
- ✓ 真实序列或在线场景：旧任务和数据无法被交错访问和读取，导致旧任务的知识及其关联的模型参数逐渐被新任务和数据擦除和覆盖

研究现状




Figure 1: General trend of the number of papers on continual learning in computer vision published in top-ranked conferences during the past six years. The plot shows consistent growth in recent literature.

- 2019-2024年，贝勒医学院、加州理工、中科院、清华大学等国内外学术机构和学者针对持续学习问题分别在 **Nature Communications** 和 **Nature Machine Intelligence** 发表了多篇研究成果
- 2016-2021年，在机器学习、计算机视觉方向的各大顶会上，持续学习的文章也逐年递增

研究现状

Papers

2024

- Expandable Subspace Ensemble for Pre-Trained Model-Based Class-Incremental Learning (CVPR2024)[paper][code]
- Pre-trained Vision and Language Transformers Are Few-Shot Incremental Learners (CVPR2024)[paper][code]
- Orchestrate Latent Expertise: Advancing Online Continual Learning with Multi-Level Supervision and Reverse Self-Distillation (CVPR2024)[paper][code]
- Elastic Feature Consolidation For Cold Start Exemplar-Free Incremental Learning (ICLR2024)[paper][code]
- Function-space Parameterization of Neural Networks for Sequential Learning (ICLR2024)[paper]
- Progressive Fourier Neural Representation for Sequential Video Compilation (ICLR2024)[paper]
- Kalman Filter Online Classification from non-Stationary Data (ICLR2024)[paper]
- Continual Momentum Filtering on Parameter Space for Online Test-time Adaptation (ICLR2024)[paper]
- TAIL: Task-specific Adapters for Imitation Learning with Large Pretrained Models (ICLR2024)[paper]
- Class Incremental Learning via Likelihood Ratio Based Task Prediction (ICLR2024)[paper][code]
- The Joint Effect of Task Similarity and Overparameterization on Catastrophic Forgetting — An Analytical Model (ICLR2024)[paper]
- Prediction Error-based Classification for Class-Incremental Learning (ICLR2024)[paper][code]
- Adapting Large Language Models via Reading Comprehension (ICLR2024)[paper][code]
- Accurate Forgetting for Heterogeneous Federated Continual Learning (ICLR2024)[paper]
- Fixed Non-negative Orthogonal Classifier: Inducing Zero-mean Neural Collapse with Feature Dimension Separation (ICLR2024)[paper]
- A Probabilistic Framework for Modular Continual Learning (ICLR2024)[paper]
- A Unified and General Framework for Continual Learning (ICLR2024)[paper]
- Continual Learning on a Diet: Learning from Sparsely Labeled Streams Under Constrained Computation (ICLR2024)[paper]

- Continual Learning of Language Models (ICLR2023)[paper]
- Progressive Prompts: Continual Learning for Language Models without Forgetting (ICLR2023)[paper]
- Is Forgetting Less a Good Inductive Bias for Forward Transfer? (ICLR2023)[paper]
- Online Boundary-Free Continual Learning by Scheduled Data Prior (ICLR2023)[paper]
- Incremental Learning of Structured Memory via Closed-Loop Transcription (ICLR2023)[paper]
- Better Generative Replay for Continual Federated Learning (ICLR2023)[paper]
- 3EF: Class-Incremental Learning via Efficient Energy-Based Expansion and Fusion (ICLR2023)[paper]
- Progressive Voronoi Diagram Subdivision Enables Accurate Data-free Class-Incremental Learning (ICLR2023)[paper]
- Learning without Prejudices: Continual Unbiased Learning via Benign and Malignant Forgetting (ICLR2023)[paper]
- Building a Subspace of Policies for Scalable Continual Learning (ICLR2023)[paper]
- A Model or 603 Exemplars: Towards Memory-Efficient Class-Incremental Learning (ICLR2023)[paper]
- Continual evaluation for lifelong learning: Identifying the stability gap (ICLR2023)[paper]
- Continual Unsupervised Disentangling of Self-Organizing Representations (ICLR2023)[paper]
- Warping the Space: Weight Space Rotation for Class-Incremental Few-Shot Learning (ICLR2023)[paper]
- Neural Collapse Inspired Feature-Classifer Alignment for Few-Shot Class-Incremental Learning (ICLR2023)[paper]
- On the Soft-Subnetwork for Few-Shot Class Incremental Learning (ICLR2023)[paper]
- Task-Aware Information Routing from Common Representation Space in Lifelong Learning (ICLR2023)[paper]
- Error Sensitivity Modulation based Experience Replay: Mitigating Abrupt Representation Drift in Continual Learning (ICLR2023)[paper]
- Neural Weight Search for Scalable Task Incremental Learning (WACV2023)[paper]
- Attribution-aware Weight Transfer: A Warm-Start Initialization for Class-Incremental Semantic Segmentation (WACV2023)[paper]
- FeTrIL: Feature Translation for Exemplar-Free Class-Incremental Learning (WACV2023)[paper]
- Do Pre-trained Models Benefit Equally in Continual Learning? (WACV2023)[paper][code]
- Sparse Coding in a Dual Memory System for Lifelong Learning (AAAI2023)[paper][code]

2022



- Balanced softmax cross-entropy for incremental learning with and without memory (CVIU)[paper]
- Incremental Prompting: Episodic Memory Prompt for Lifelong Event Detection (COLING2022)[paper][code]
- Online Continual Learning through Mutual Information Maximization (ICML2022)[paper]
- Improving Task-free Continual Learning by Distributionally Robust Memory Evolution (ICML2022)[paper]
- Forget-free Continual Learning with Winning Subnetworks (ICML2022)[paper]
- NISPA: Neuro-Inspired Stability-Plasticity Adaptation for Continual Learning in Sparse Networks (ICML2022)[paper]
- Continual Learning via Sequential Function-Space Variational Inference (ICML2022)[paper]
- A Theoretical Study on Solving Continual Learning (NeurIPS2022)[paper][code]
- ACIL: Analytic Class-Incremental Learning with Absolute Memorization and Privacy Protection (NeurIPS2022)[paper]
- Beyond Not-Forgetting: Continual Learning with Backward Knowledge Transfer (NeurIPS2022)[paper]
- Memory Efficient Continual Learning with Transformers (NeurIPS2022)[paper]
- Margin-Based Few-Shot Class-Incremental Learning with Class-Level Overfitting Mitigation (NeurIPS2022)[paper][code]
- Disentangling Transfer in Continual Reinforcement Learning (NeurIPS2022)[paper]
- Task-Free Continual Learning via Online Discrepancy Distance Learning (NeurIPS2022)[paper]
- A simple but strong baseline for online continual learning: Repeated Augmented Rehearsal (NeurIPS2022)[paper]
- S-Prompts Learning with Pre-trained Transformers: An Occam's Razor for Domain Incremental Learning (NeurIPS2022)[paper]
- Lifelong Neural Predictive Coding: Learning Cumulatively Online without Forgetting (NeurIPS2022)[paper]
- Few-Shot Continual Active Learning by a Robot (NeurIPS2022)[paper]
- Continual learning: a feature extraction formalization, an efficient algorithm, and fundamental obstructions(NeurIPS2022)[paper]
- SparCL: Sparse Continual Learning on the Edge(NeurIPS2022)[paper]
- CLIMB: A Continual Learning Benchmark for Vision-and-Language Tasks (NeurIPS2022)[paper][code]
- Continual Learning In Environments With Polynomial Mixing Times (NeurIPS2022)[paper][code]
- Exploring Example Influence in Continual Learning (NeurIPS2022)[paper][code]
- ALIFE: Adaptive Logit Regularizer and Feature Replay for Incremental Semantic Segmentation (NeurIPS2022)[paper]
- On the Effectiveness of Lipschitz-Driven Rehearsal in Continual Learning (NeurIPS2022)[paper][code]

2022-2024年，关于持续学习基础理论和应用场景的研究依旧火热

与相关方向的联系

□ 经典机器/深度学习


- ✓ 只关注单个任务、单一目标的最优表现，假设数据离线存储并且可以反复访问
- ✓ **持续学习**：关注流式序列任务学习，假设任务流式访问并且只能访问一次，核心目标在于取得所有任务平均最优表现



与相关方向的联系

□ 迁移学习


- ✓ 只在单个源任务上进行学习，并且只关注目标任务上的性能
- ✓ **持续学习**：希望所有学过的任务平均最好



与相关方向的联系

□ 多任务学习


- ✓ 并行学习多个不同类型的相关任务，让这些任务在学习过程中共享知识，利用多个任务之间的相关性来改进模型在每个任务上的性能和泛化能力，同时还假设数据是离线的、不同任务使用相同数据
- ✓ **持续学习**：假设数据是流式的，串行地学习多个同类型任务，不同任务使用的数据是完全不同的



与相关方向的联系

□ 元学习

- ✓ 目的在于学习大量被构造的辅助任务后，能够在少量样本的情况下加快在目标任务上的学习和泛化，但是对于辅助数据的假设仍然是离线的，并且训练任务间存在交叉和重叠，更加关注目标任务的性能
- ✓ **持续学习**：更多关注所有任务的平均性能



持续学习场景介绍

场景设定

广义的持续学习：任务之间完全不同

- ✓ 任务类型：计算机视觉、自然语言处理、视频与语音处理等
- ✓ 任务目的：分类、检测、分割、生成等
- ✓ 数据类型：灰度/RGB图像、点云、文本、视频、音频等

现阶段很难展开研究！！！！

简化任务和数据类型，重点关注灾难性遗忘问题，设定了三种常见场景：

- ✓ 任务增量学习 (task-incremental learning)
- ✓ 类别增量学习 (class-incremental learning)
- ✓ 域增量学习 (domain-incremental learning)

Table 1: Overview of the three continual learning scenarios.

<i>Scenario</i>	<i>Required at test time</i>
Task-IL	Solve tasks so far, task-ID provided
Domain-IL	Solve tasks so far, task-ID not provided
Class-IL	Solve tasks so far <i>and</i> infer task-ID

场景设定

广义的持续学习：任务之间完全不同

- ✓ 任务类型：计算机视觉、自然语言处理、视频与语音处理等
- ✓ 任务目的：分类、检测、分割、生成等
- ✓ 数据类型：灰度/RGB图像、点云、文本、视频、音频等

现阶段很难展开研究！！！！

简化任务和数据类型，重点关注灾难性遗忘问题，设定了三种常见场景：

- ✓ 任务增量学习 (task-incremental learning)
- ✓ 类别增量学习 (class-incremental learning)
- ✓ 域增量学习 (domain-incremental learning)




Figure 1: Schematic of split MNIST task protocol.

Table 2: Split MNIST according to each scenario.

Task-IL	With task given, is it the 1 st or 2 nd class? (e.g., 0 or 1)
Domain-IL	With task unknown, is it a 1 st or 2 nd class? (e.g., in [0, 2, 4, 6, 8] or in [1, 3, 5, 7, 9])
Class-IL	With task unknown, which digit is it? (i.e., choice from 0 to 9)

场景设定

□ 任务增量学习

- ✓ 不同时刻到来的数据分属于不同的任务，在一个时间段内我们可以获得当前任务的全部数据，并且假设测试推理阶段，任务的编号（task-ID）是可知的
- ✓ 因为测试阶段任务编号可知，所以训练阶段不同任务的输出相互独立，即最终学到的模型是多头的（multi-head），为每个任务提供单独的输出层


因此，针对任务增量场景，模型在训练和测试阶段均会提供数据对应的任务编号

场景设定

□ 任务增量学习

- ✓ 不同时刻到来的数据分属于不同的任务，在一个时间段内我们可以获得当前任务的全部数据，并且假设测试推理阶段，任务的编号（task-ID）是可知的
- ✓ 因为测试阶段任务编号可知，所以训练阶段不同任务的输出相互独立，即最终学到的模型是多头的（multi-head），为每个任务提供单独的输出层

因此，针对任务增量场景，模型在训练和测试阶段均会提供数据对应的任务编号



场景设定

□ 类别增量学习



- ✓ 不同时刻到来的数据属于同一类型任务的不同类别，随着训练的进行逐步增加输出类别，即类别空间是逐渐扩充的
- ✓ 不同于任务增量学习场景，类别增量学习场景在测试阶段不知道任务的编号（训练阶段知道任务编号），比任务增量场景更具挑战性

场景设定



□ 类别增量学习

- ✓ 不同时刻到来的数据属于同一类型任务的不同类别，随着训练的逐步增加输出类别，即类别空间是逐渐扩充的
- ✓ 不同于任务增量学习场景，类别增量学习场景在测试阶段不知道任务的编号（训练阶段知道任务编号），比任务增量场景更具挑战性

T_1




T_2



场景设定

□ 域增量学习

- ✓ 不同时刻到来的数据属于不同任务，但是任务之间的类别空间是相同的，只是数据的分布（域）发生了变化，前后两个任务的数据不再满足独立同分布假设



场景设定

□ 三种设定的比较

1. **Availability of Task/Distribution Labels**: during training and/or testing
2. **Task/Shift Boundaries**: during training and/or testing
3. **Experience Content**: examples of [same|new] classes
4. **Classification Problem**: [Unique|Partitioned]

Name	Task Labels	Boundaries	Classes	Problem
<i>Class-Incremental</i>	no	yes	new	unique
<i>Task-Incremental</i>	yes	yes	new	partitioned
<i>Domain-Incremental</i>	no	yes	same	unique
<i>Task-Free</i>	no	no	any	unique
<i>Task-Agnostic</i>	no	no	any	partitioned
...	...	...	...	...

持续学习设置


常用数据集

- ✓ 10 类别数据集：CIFAR10、MNIST
- ✓ 100/200类别数据集：CIFAR-100、mini-ImageNet、 Tiny-ImageNet (200类)

100类别数据集的划分方式：

- ✓ 五个任务， 每个任务二十个类
- ✓ 二十个任务， 每个任务五个类
- ✓ 十一个任务， 第一个任务五十个类， 其他每个任务五个类

10类别数据集划分（以MNIST为例）：



评估指标

将数据集划分为 T 个任务，持续学习算法在这 T 个任务上依次进行训练与测试，得到一个 $T \times T$ 的精度矩阵 $\mathbf{R}$ ，其中 $R_{i,j}$ 表示模型学过任务 i 后在任务 j 上的测试分类精度

对于具体的 $R_{i,j}$,

- ✓ 若 $i > j$ ，则刻画的是经过任务 i 后，任务 j 被遗忘的程度
- ✓ 若 $i \leq j$ ，则反映了模型将任务 i 的知识迁移到任务 j 上的能力

$$\text{Accuracy} = \frac{1}{T} \sum_{i=1}^T R_{T,i}$$

$$\text{BWT: Backward Transfer} = \frac{1}{T-1} \sum_{i=1}^{T-1} R_{T,i} - R_{i,i}$$

$$\text{FWT: Forward Transfer} = \frac{1}{T-1} \sum_{i=2}^T R_{i-1,i} - R_{0,i}$$

Forgetting = - BWT 刻画遗忘

Transferring = FWT 刻画迁移

		Test on			
		Task 1	Task 2		Task T
Rand Init.		$R_{0,1}$	$R_{0,2}$		$R_{0,T}$
After Training	Task 1	$R_{1,1}$	$R_{1,2}$		$R_{1,T}$
	Task 2	$R_{2,1}$	$R_{2,2}$		$R_{2,T}$
	⋮				
	Task T-1	$R_{T-1,1}$	$R_{T-1,2}$		$R_{T-1,T}$
	Task T	$R_{T,1}$	$R_{T,2}$		$R_{T,T}$

持续学习方法分类

方法分类

❑ 基于回放的方法 (replay-based)


- ✓ 使用各种方式保留之前任务的知识

❑ 基于约束的方法 (constraint-based)

- ✓ 使用正则项、知识蒸馏等技术来约束模型

❑ 基于结构的方法 (architecture-based)

- ✓ 通过动态地修改模型结构来实现持续学习



基于回放的方法

□ 方法核心

通过**让旧任务数据出现**在后续任务的训练过程中，缓解模型灾难性遗忘的程度

□ 根据获得旧任务数据的方式

✓ 采样回放方法


使用一个固定大小的内存空间用来**保存从旧任务数据**中采样出的一小部分样本

✓ 生成回放方法

基于GAN来训练并保存一个能够合成当前任务数据的**生成模型**，并在后续任务的训练过程中通过合成大量旧任务数据用于训练

✓ 伪样本回放方法

借助分类模型本身，通过**对随机输入进行不断的优化**，最终合成旧任务数据



基于约束的方法

□ 方法核心

设法通过**设计模型参数更新过程**来保证模型在学习新任务时不会降低在旧任务上的表现

□ 根据约束的方式

✓ 参数约束方法


通过衡量各个模型参数的重要性，并**限制重要参数的更新**来保证模型性能的稳定

✓ 梯度约束方法

将模型在任务上的表现转换为关于**模型参数的带约束优化问题**，通过求解得到模型参数梯度的可行空间，并将模型参数梯度投影至可行空间中，得到模型参数实际更新的梯度

✓ 数据约束方法

通过让当前模型**模仿旧模型副本**，来防止模型在学习过程中过度遗忘旧知识



基于结构的方法

□ 方法核心

考虑**为不同任务分配不同的网络结构**、模型参数等，防止模型在学习新任务时覆盖在旧任务上学到的知识，保证模型的稳定性，彻底避免灾难性遗忘


□ 根据实现角度的不同

✓ 参数隔离方法

一类静态的方法，通常会固定模型容量，为每个任务分配不同的模型参数

✓ 模型拓展方法

更加动态与灵活，没有限定模型的大小，考虑为新任务开辟新的网络子结构，并且在学习新任务的时候固定已经学好的网络部分



持续学习方法介绍

方法分类

❑ 基于回放的方法 (replay-based)


✓ 采样回放方法、生成回放方法、伪样本回放方法

❑ 基于约束的方法 (constraint-based)

✓ 参数约束方法、梯度约束方法、数据约束方法

❑ 基于结构的方法 (architecture-based)

✓ 参数隔离方法、模型拓展方法




采样回放方法

□ 方法核心

该类方法采用的策略是学习完每个任务后保存一部分当前任务的原始样本在固定大小的内存空间里，并在后续任务的学习过程中进行样本回放

□ 代表模型

- iCaRL (CVPR 2017)
- EEIL (ECCV 2018)
- **Rainbow Memory (CVPR 2021)**
- BiRT (ICML 2023)
- CIM-based CIL (CVPR 2023)



- [1] iCaRL: Incremental Classifier and Representation Learning. CVPR 2017.
- [2] End-to-End Incremental Learning. ECCV 2018.
- [3] Rainbow Memory: Continual Learning with a Memory of Diverse Samples. CVPR 2021.
- [4] BiRT: Bio-inspired Replay in Vision Transformers for Continual Learning. ICML 2023.
- [5] Class-Incremental Exemplar Compression for Class-Incremental Learning. CVPR 2023.

Rainbow Memory (CVPR 2021)

□ 动机


只允许保存固定大小、部分旧类样本 → 保存哪些样本更好？

□ 已有的工作：

- iCaRL[1]: 选择保存样本特征最接近类别原型的样本（更能代表这个类）
- EEIL[2]: 选择随机保存样本

□ 本文的核心思想

保存的样本应该具有 “**多样性**”：不仅要保存具有 “**代表性**” 的样本，还要保存具有 “**辨别性**” 的样本



Rainbow Memory (CVPR 2021)

□ 问题1：怎样衡量“代表性”和“辨别性”？

本文假设：靠近分类边界的样本更具有**辨别力**，靠近分布中心的样本更具有**代表性**

□ 问题2：如何计算样本所处位置？

方案1：计算两两样本特征之间的距离得到相对位置（**计算量太大**）

本文：通过样本的**分类不确定性**来估计每个样本的相对位置

不确定性越高，越靠近分类边界

□ 问题3：什么是样本的“分类不确定性”？

如果一个样本在施加一点扰动以后，分类器不能将其分类为正确类别，则代表该样本的“分类不确定性”较高

Rainbow Memory (CVPR 2021)


□ 如何计算样本的不确定性

对该样本通过施加不同的转换, 得到多个扰动样本。通过模型对多个扰动样本的输出的方差来衡量样本的不确定性

$$S_c = \sum_{t=1}^T 1_c \operatorname{argmax}_{\hat{c}} p(y = \hat{c} | \hat{x}_t)$$

$$u(x) = 1 - \frac{1}{T} \max_c S_c$$

- ✓ T 代表扰动样本数量
- ✓ c 代表类别
- ✓ $\hat{x}_t$ 代表一个扰动样本
- ✓ 1_c 是指示函数
- ✓ S_c 表示有多少个扰动样本的类别被预测为 c
- ✓ $u(x)$ 表示样本 x 的不确定性



Rainbow Memory (CVPR 2021)

内存更新流程


Algorithm 1 Diversity-Aware Memory Update

```
1: Input:  $K$  denotes memory size,  $N_t$  denotes the number of seen classes until task  $t$ ,  $\mathcal{D}_t^S$  denotes stream data at task  $t$ ,  $\mathcal{D}_{t-1}^M$  denotes exemplars stored in an episodic memory after task  $t-1$ .  
2: Output:  $\mathcal{D}_t^M$  exemplars after learning task  $t$ .  
3:  $\mathcal{D}_t^M = \{\}$  ▷ New exemplars from scratch  
4:  $k_c = \text{floor}(K/N_t)$  ▷ Class-balanced sampling  
5: for  $c = 1, 2, \dots, N_t$  do  
6:    $\mathcal{D}_c = \{(x, y) | y = c, (x, y) \in \mathcal{D}_t^S \cup \mathcal{D}_{t-1}^M\}$   
7:   Sort  $\mathcal{D}_c$  by  $u(x)$  computed by (4)  
8:   for  $j = 1, 2, \dots, k_c$  do  
9:      $i = j * |\mathcal{D}_c| / k_c$  ▷  $|\mathcal{D}_c|/k_c$  step-size indexing  
10:     $\mathcal{D}_t^M += \mathcal{D}_c[i]$   
11:   end for  
12: end for
```

为了使保存的样本能够更好的覆盖特征空间（**多样性**），按照不确定性排序后，均匀选取样本

模型训练流程：

1. 借助保存的样本与当前任务数据训练模型
2. 更新内存
3. 进入下一个任务，跳转至步骤1



生成回放方法

□ 方法核心

不同于采样回放方法直接采样原始样本，生成回放方法往往基于GAN，通过训练一个能够**生成旧类样本的生成网络**，并将其保存下来用于后续任务学习过程中随时生成旧类样本，变向地解决持续学习中不能接触旧样本的限制

□ 代表模型

- DGR (NeurIPS 2017)
- DGM (CVPR 2019)

[6] Continual learning with deep generative replay. NeurIPS 2017.

[7] Learning to remember: A synaptic plasticity driven framework for continual learning. CVPR 2019.

DGR: Deep Generative Replay

□ 特点


借助生成对抗网络GAN模型来得到一个能够不断生成旧类数据的生成器

□ 优点

不直接保存旧样本（一定程度上避免隐私问题）、能够源源不断地生成旧类样本

□ 缺点

生成模型的训练难度大



序列训练-算法示意图

Scholar 代表一组 $\langle G, S \rangle$

- ✓ G 是一个生成模型, 用来生成所有旧任务的样本
- ✓ S 是一个分类模型, 负责对所有任务的样本进行分类

通过 Scholar_i 以及 Task_{i+1} 的数据来训练 Scholar_{i+1}

DGR: Deep Generative Replay

□ 算法流程

1. 借助上个任务的 $Scholar_{i-1}$, 生成旧任务的数据 (x', y') , 将其与当前任务数据 x 相混合, 训练生成器 G_i , 使其重建累积的输入空间, 即能够重构所有任务样本

2. 用合成的旧样本对 (x', y') , 以及当前任务的数据 (x, y) , 训练求解器 S_i , 使其能够分类所有类别样本, 其训练损失为:

r 代表真实/生成样本之间的比例, 用来调节新旧任务之间的重要性

$$L_{train}(\theta_i) = r \mathbb{E}_{(x, y) \sim D_i} [L(S(x; \theta_i), y)] + (1 - r) \mathbb{E}_{x' \sim G_{i-1}} [L(S(x'; \theta_i), S(x'; \theta_{i-1}))]$$

其中 $S(x; \theta_i), S(x; \theta_{i-1})$ 表示新/旧求解器 S 对于样本 x 的输出


DGR: Deep Generative Replay

□ 算法流程


1. 借助上个任务的 $Scholar_{i-1}$, 生成旧任务的数据 (x', y') , 将其与当前任务数据 x 相混合, 训练生成器 G_i , 使其重建累积的输入空间即能够重构所有任务样本
2. 用合成的旧样本对 (x', y') , 以及当前任务的数据 (x, y) , 训练求解器 S_i , 使其能够分类所有类别样本, 其训练损失为:

$$L_{train}(\theta_i) = r\mathbb{E}_{(x,y)\sim D_i}[L(S(x; \theta_i), y)] + (1 - r) \mathbb{E}_{x'\sim G_{i-1}}[L(S(x'; \theta_i), S(x'; \theta_{i-1}))]$$

其中 $S(x; \theta_i), S(x; \theta_{i-1})$ 表示新/旧求解器 S 对于样本 x 的输出



(a) 训练生成器



(b) 训练求解器


伪样本回放方法

□ 方法核心

通常会把输入的随机噪声作为可学习参数，固定模型参数，通过梯度下降的方式优化输入，最终将随机噪声优化为伪样本，其核心在于如何合成出包含丰富旧类信息的伪样本用来传递旧类知识，减轻灾难性遗忘

□ 代表模型

- DeepInversion (CVPR 2020)
- Always Be Dreaming (ICCV 2021)
- CF-IL (ICLR 2022)



[8] Dreaming to Distill: Data-free Knowledge Transfer via DeepInversion. CVPR 2020.

[9] Always Be Dreaming: A New Approach for Data-Free Class-Incremental Learning. ICCV 2021.

[10] Looking Back on Learned Experiences for Class/Task Incremental Learning. ICLR 2022.

CF-IL: Cost-Free Incremental Learning

□ 动机

保存样本的做法在实际应用中会受到很大的限制（隐私问题），使用生成模型会增加训练难度，能否直接借助分类模型来合成样本

□ 问题：如何合成样本？

将随机输入噪声看做**可学习**参数，通过梯度下降将噪声优化为图像

□ 已有的工作：

DeepInversion[6]指出：如果在合成时不对样本的中间特征施加约束，容易导致合成样本所包含的类别信息不足。因此，借助BN层的参数设计惩罚项辅助样本的合成

□ 本文的核心思想

借助**混淆矩阵**中所包含的类别相似性信息辅助样本的生成

CF-IL: Cost-Free Incremental Learning

□ 为什么优化输入噪声可以用来合成样本？

将随机输入噪声看做**可学习**参数，通过梯度下降将噪声优化为图像



Figure 5: Class-conditional 224×224 samples obtained by DeepInversion, given only a ResNet-50 classifier trained on ImageNet and no additional information. Note that the images depict classes in contextually correct backgrounds, in realistic scenarios. Best viewed in color.

DeepInversion [6]

CF-IL: Cost-Free Incremental Learning

□ 样本合成的具体做法

通过保留上个任务结束时分类的混淆矩阵 CM ，在合成类别 i 的样本时，取 CM 第 i 行，作为类别 i 的软标签的参考值。通过从狄利克雷分布中不断采样出随机向量 v ，只有当 v 与参考值 CM_i 足够接近时，才会用 v 来合成类别 i 的样本。

□ 混淆矩阵（也称误差矩阵）

		Predicted condition	
		Cancer	Non-cancer
Actual condition	Total	8 + 4 = 12	
	Cancer	6	2
	Non-cancer	1	3

		Predicted condition	
		Positive (PP)	Negative (PN)
Actual condition	Positive (P)	True positive (TP)	False negative (FN)
	Negative (N)	False positive (FP)	True negative (TN)

		Predicted condition		Sources: [22][23][24][25][26][27][28][29][30] view · talk · edit	
		Positive (PP)	Negative (PN)	Informedness, bookmaker informedness (BM) = TPR + TNR - 1	Prevalence threshold (PT) $= \frac{\sqrt{TPR \times FPR} - FPR}{TPR - FPR}$
Actual condition	Positive (P)	True positive (TP), hit	False negative (FN), type II error, miss, underestimation	True positive rate (TPR), recall, sensitivity (SEN), probability of detection, hit rate, power $= \frac{TP}{P} = 1 - FNR$	False negative rate (FNR), miss rate $= \frac{FN}{P} = 1 - TPR$
	Negative (N)	False positive (FP), type I error, false alarm, overestimation	True negative (TN), correct rejection	False positive rate (FPR), probability of false alarm, fall-out $= \frac{FP}{N} = 1 - TNR$	True negative rate (TNR), specificity (SPC), selectivity $= \frac{TN}{N} = 1 - FPR$
		Prevalence $= \frac{P}{P+N}$	Positive predictive value (PPV), precision $= \frac{TP}{PP} = 1 - FDR$	False omission rate (FOR) $= \frac{FN}{PN} = 1 - NPV$	Positive likelihood ratio (LR+) $= \frac{TPR}{FPR}$
		Accuracy (ACC) $= \frac{TP+TN}{P+N}$	False discovery rate (FDR) $= \frac{FP}{PP} = 1 - PPV$	Negative predictive value (NPV) $= \frac{TN}{PN} = 1 - FOR$	Negative likelihood ratio (LR-) $= \frac{FNR}{TNR}$
		Balanced accuracy (BA) $= \frac{TPR+TNR}{2}$	F ₁ score $= \frac{2PPV \times TPR}{PPV+TPR} = \frac{2TP}{2TP+FP+FN}$	Fowlkes-Mallows index (FM) $= \sqrt{PPV \times TPR}$	Markedness (MK), delta P (Δp) $= PPV + NPV - 1$
				Matthews correlation coefficient (MCC) $= \frac{TPR \times TNR - \sqrt{FNR \times FPR \times FOR \times FDR}}{\sqrt{TPR \times TNR \times PPV \times NPV}}$	Diagnostic odds ratio (DOR) $= \frac{LR+}{LR-}$
					Threat score (TS), critical success index (CSI), Jaccard index $= \frac{TP}{TP+FN+FP}$


CF-IL: Cost-Free Incremental Learning

□ 样本合成的具体做法

通过保留上个任务结束时分类的混淆矩阵 CM ，在合成类别 i 的样本时，取 CM 第 i 行，作为类别 i 的软标签的参考值。通过从狄利克雷分布中不断采样出随机向量 v ，只有当 v 与参考值 CM_i 足够接近时，才会用 v 来合成类别 i 的样本。


此处，隐含一个**一致性假设**：

$CM_{i,j}$ 越大，则代表类别 i, j 更相似→样本软标签在类别 i, j 上的值尽可能大



CF-IL: Cost-Free Incremental Learning

□ 样本合成的具体做法



1. 约束：向量足够接近参考值
2. 选取参考值
3. 不断采样，直到满足约束
4. 将随机噪声输入优化为样本

Algorithm 2: Mem. Recovery Paradigm

Input : Learner model parameters $\theta_{\mathcal{L}}$,
Transfer set size K , Confusion
Matrix CM

Output : Transfer set $\mathcal{S}$

Require: Dirichlet distribution
parameters α, β , Thresh. η ,
Temperature for distillation τ

k : number of classes from $\mathcal{L}$

$p : K/k$ // Number of samples
per class

$\mathcal{S} \leftarrow \{\}$

Constraint $\mathcal{F}(\mathcal{X}, \gamma) \leftarrow (\|\mathcal{X} - \gamma\|_2^2 < \eta)$

for $i = 1 : k$ **do**

$\gamma \leftarrow CM^i$

for $j = 1 : p$ **do**

do

Sample $\mathcal{V}_j^i \leftarrow$
 $\text{Dir}(d, \beta \times \alpha^i)$
 $\mathcal{V}_j^{*i} \leftarrow \mathcal{V}_j^i$

while Constraint $\mathcal{F}(\mathcal{V}_j^i, \gamma)$
passed

Initialize x_j^i to random noise
 $\bar{x}_j^i \leftarrow \text{optimize } x_j^i \text{ with}$
 $\ell_{CE}(\mathcal{V}_j^{*i}, \mathcal{L}(x_j^i, \theta_{\mathcal{L}}, \tau))$

$\mathcal{S} \leftarrow \mathcal{S} \cup \bar{x}_j^i$

CF-IL: Cost-Free Incremental Learning

□ 算法流程

Algorithm 1: data-free Incremental Learning

Input : Task sequence set T , Transfer set size

K , Learner model parameters θ_L

Require: Confusion Matrix CM from $\mathcal{L}$,

Incremented class(es) $\mathcal{I}$

// memory recovery paradigm

$S \leftarrow \mathcal{R}(\theta_L, K, CM)$

L : number of samples in $\mathcal{I}$

// store network outputs and Ground Truth for S with pre-update parameters

for (x, y) in S **do**

$\mathcal{O} \leftarrow \mathcal{L}(x; \theta_L)$

// form combined training set

$\mathcal{D} \leftarrow \bigcup_{i=1}^{i=L} \{(x^i, y^i, -) : x^i \in \mathcal{I}_t\} \cup \bigcup_{j=1}^{j=K} \{(x^j, y^j, \mathcal{O}^j) : x^j \in S_t\}$

// define a two-parted loss function

$\ell_{Total} = \sum_{(x, y, \mathcal{O}) \in \mathcal{D}} [\sum_{i=1}^N \ell_{CE}(\mathcal{L}(x^i; \theta_L), y^i)] + \lambda [\sum_{j=1}^K \ell_{KD}(\mathcal{L}(x^j; \theta_L), \mathcal{O}^j)]$

// optimize the network for the total loss

for (x, y) in $\text{range}(K + L)$ **do**


 sample a batch b_1 form $\mathcal{D}$, where $(x, y, \mathcal{O}) \in S$

 sample a batch b_2 form $\mathcal{D}$, where $(x, y) \in \mathcal{I}$

 update θ_L by taking a SGD step on $b_1 + b_2$

 loss $\ell_{Total}(\theta_L)$

1. 合成样本集合 S
2. 同时对合成的样本保存模型的输出 $\mathcal{O}$
3. 对所有样本计算CE-Loss, 对旧样本额外计算知识蒸馏损失



方法分类

❑ 基于回放的方法 (replay-based)


✓ 采样回放方法、生成回放方法、伪样本回放方法

❑ 基于约束的方法 (constraint-based)

✓ 参数约束方法、梯度约束方法、数据约束方法

❑ 基于结构的方法 (architecture-based)

✓ 参数隔离方法、模型拓展方法



参数约束方法


□ 方法核心

该类方法的主要思想是限制对旧任务性能影响较大的参数的更新，防止重要参数的更新导致模型对旧类知识的灾难性遗忘

□ 代表模型

- EWC (PNAS 2017)
- IMM (NeurIPS 2017)
- MAS (ECCV 2018)

■ 任务1的低损失区域
□ 任务2的低损失区域



[11] Overcoming catastrophic forgetting in neural networks. PNAS 2017.

[12] Overcoming catastrophic forgetting by incremental moment matching. NeurIPS 2017.

[13] Memory aware synapses: Learning what (not) to forget. ECCV 2018.


EWC: Elastic Weight Consolidation

□ 动机

网络的过参数化会导致有可能在任务A的最佳参数 θ_A^* 的附近找一个对于任务B而言的最佳参数 θ_B^* 。对模型参数施加弹性约束，使得限制重要参数的更新，放宽非重要参数的更新

□ 如何找到重要的参数

从概率的角度：神经网络训练中的优化参数 θ 的过程等价于给定数据 D ，找到参数最有可能的值，即 $p(\theta|D)$



EWC: Elastic Weight Consolidation

□ 如何找到重要的参数

$$\log p(\theta|\mathcal{D}) = \log p(\mathcal{D}|\theta) + \log p(\theta) - \log p(\mathcal{D})$$

贝叶斯定理

$$p(\theta|D) = \frac{p(\theta)p(D|\theta)}{p(D)}$$

- 假设数据 D 被分为 D_A, D_B 两部分 (D_A 代表前一任务, D_B 代表当前任务), 可将上式改写为:

$$\log p(\theta|\mathcal{D}) = \log p(\mathcal{D}_B|\theta) + \log p(\theta|\mathcal{D}_A) - \log p(\mathcal{D}_B)$$

- 等式左边表示参数在完整数据集上的后验概率; 右边将Task A, B分开, 一部分是在Task B上的损失 $\log p(D_B|\theta)$, 另一部分 $\log p(\theta|D_A)$ 则包含了哪些参数对Task A重要这一信息。

EWC: Elastic Weight Consolidation

□ 如何找到重要的参数

$$\log p(\theta|\mathcal{D}) = \log p(\mathcal{D}|\theta) + \log p(\theta) - \log p(\mathcal{D})$$

- 假设数据 $\mathcal{D}$ 被分为 $\mathcal{D}_A, \mathcal{D}_B$ 两部分 ($\mathcal{D}_A$ 代表前一任务, $\mathcal{D}_B$ 代表当前任务), 可将上式改写为:

$$\log p(\theta|\mathcal{D}) = \log p(\mathcal{D}_B|\theta) + \log p(\theta|\mathcal{D}_A) - \log p(\mathcal{D}_B)$$

- 等式左边表示参数在完整数据集上的后验概率; 右边将Task A, B分开, 一部分是在Task B上的损失 $\log p(\mathcal{D}_B|\theta)$, 另一部分 $\log p(\theta|\mathcal{D}_A)$ 则包含了哪些参数对Task A重要这一信息。
- 右侧的后验概率 $\log p(\theta|\mathcal{D}_A)$ 是无法得到的, 通过拉普拉斯近似将其近似为高斯分布, 并利用Fisher Information Matrix来衡量参数的重要性, 最终优化目标如下:

$$\mathcal{L}(\theta) = \mathcal{L}_B(\theta) + \sum_i \frac{\lambda}{2} F_i (\theta_i - \theta_{A,i}^*)^2$$

其中 F 表示Fisher Information matrix, θ_A^* 表示学习完task A时的模型参数

贝叶斯定理

$$p(\theta|\mathcal{D}) = \frac{p(\theta)p(\mathcal{D}|\theta)}{p(\mathcal{D})}$$

梯度约束方法

□ 方法核心

该类方法的主要思想是需要部分旧任务的信息，在学习新任务时，通过**直接对参数梯度进行矫正**，来保证模型的参数更新不会导致在旧任务上的性能下降

□ 代表模型


- GEM (NeurIPS 2017)
- A-GEM (ICLR 2019)
- Adam-NSCL (CVPR 2021)
- SPG (ICML23)

[14] Gradient episodic memory for continual learning. NeurIPS 2017.

[15] Efficient lifelong learning with A-GEM. ICLR 2019.

[16] Networks in null space of feature covariance for continual learning. CVPR 2021.

[17] Parameter-Level Soft-Masking for Continual Learning. ICML23



Adam-NSCL (CVPR 2021)

□ 动机


由于参数朝着某些方向更新会对之前的任务性能造成极大的破坏，限制参数在旧任务的“近似零空间”内更新，在保证旧任务的性能不受影响的情况下，学习新任务

□ 主要贡献

提出两条引理来保证模型的可塑性以及稳定性

- ✓ **可塑性**：指模型学习新任务的能力
- ✓ **稳定性**：指模型保留旧任务的能力

持续学习问题也可以被看作寻找可塑性与稳定性之间的平衡



Adam-NSCL (CVPR 2021)


□ 两条引理

$X_{p,t}^l, O_{p,t}^l$ 表示将任务 T_p 的数据 X_p 喂给经过任务 T_t 训练过的网络 f 时, 第 l 层的输入/输出特征 $O_{p,t}^l = X_{p,t}^l \tilde{w}_t^l, \quad X_{p,t}^{l+1} = \sigma_l(O_{p,t}^l)$

定义: 非中心特征协方差矩阵: $\tilde{\chi}_{t-1}^l = \frac{1}{\bar{n}_{t-1}} (\bar{X}_{t-1}^l)^T \bar{X}_{t-1}^l = \frac{1}{\bar{n}_{t-1}} \sum_{i=1}^{t-1} (X_{i,i}^l)^T X_{i,i}^l$

Condition 1. 若 $\tilde{\chi}_{t-1}^l \Delta w_{t,s}^l = 0$, 对任务 t 的训练过程中的任意步 s , 任意层 l 均成立

则: $f(X_p, \tilde{w}_t) = f(X_p, \tilde{w}_p)$, 对 $p = 1, \dots, t-1$ 成立



稳定性: 模型在旧任务上的表现不变

Condition 2. 若 $\Delta w_{t,s}$ 满足 $\langle \Delta w_{t,s}, g_{t,s} \rangle > 0$, 对任意步 s 均成立

则: 通过 $\Delta w_{t,s}$ 更新参数, 损失函数将会下降




可塑性: 模型在新任务上的损失下降

Adam-NSCL (CVPR 2021)

□ 算法流程

1. 把任务 $t-1$ 的数据喂给网络得到每一层的输入特征

2. 更新每一层的协方差矩阵



4. 将每一层梯度投影到对应层的零空间中

3. 通过奇异值分解得到每一层的近似零空间


数据约束方法

□ 方法核心

该类方法的主要思想是保存上个任务结束时的**模型副本**，并在学习新任务的过程中进行**知识蒸馏**。通常会使当前模型和副本在某个数据分布上的预测尽可能保持一致，通过模仿副本的方式，让模型在学习新知识的同时尽可能的保留旧知识。

□ 代表模型

- LwF (TPAMI 2017)
- DMC (WACV 2020)
- PRD (ICML 2023)



[18] Learning without forgetting. TPAMI 2017.

[19] Class-incremental learning via deep model consolidation. WACV 2020.


[20] Prototype-Sample Relation Distillation: Towards Replay-Free Continual Learning. ICML2023.

LwF: Learning without Forgetting

□ 动机


- 通过知识蒸馏，让模型的输出尽可能与旧模型的输出保持一致，从而使模型在训练过程中能够保留旧任务知识
- 对于一个CNN网络，将参数分为共享参数 θ_s 和任务特定参数 θ_o ，当新任务到来时，要增加新任务的参数 θ_n

(e) Learning without Forgetting




LwF: Learning without Forgetting

(a) Original Model




(b) Fine-tuning




新任务
微调

(c) Feature Extraction




只用特征

(d) Joint Training



联合训练
(天花板)

(e) Learning without Forgetting



引入
知识蒸馏

LwF: Learning without Forgetting

□ 算法流程

LEARNING WITHOUT FORGETTING:

Start with:

θ_s : shared parameters

θ_o : task specific parameters for each old task

X_n, Y_n : training data and ground truth on the new task

Initialize:

$Y_o \leftarrow \text{CNN}(X_n, \theta_s, \theta_o)$ // compute output of old tasks for new data

$\theta_n \leftarrow \text{RANDINIT}(|\theta_n|)$ // randomly initialize new parameters

Train:


Define $\hat{Y}_o \equiv \text{CNN}(X_n, \hat{\theta}_s, \hat{\theta}_o)$ // old task output

Define $\hat{Y}_n \equiv \text{CNN}(X_n, \hat{\theta}_s, \hat{\theta}_n)$ // new task output

$\theta_s^*, \theta_o^*, \theta_n^* \leftarrow \underset{\hat{\theta}_s, \hat{\theta}_o, \hat{\theta}_n}{\text{argmin}} \left(\lambda_o \mathcal{L}_{old}(Y_o, \hat{Y}_o) + \mathcal{L}_{new}(Y_n, \hat{Y}_n) + \mathcal{R}(\hat{\theta}_s, \hat{\theta}_o, \hat{\theta}_n) \right)$

1. 记录旧任务分类头对新任务数据的预测 Y_o
2. 训练时, 先固定 θ_s, θ_o , 训练 θ_n 至模型收敛
3. 训练 $\theta_s, \theta_o, \theta_n$ 至模型收敛

(e) Learning without Forgetting



正则项损失

分类损失: 新任务的分类损失

蒸馏损失: 保证旧任务知识不被遗忘

方法分类

❑ 基于回放的方法 (replay-based)


✓ 采样回放方法、生成回放方法、伪样本回放方法

❑ 基于约束的方法 (constraint-based)

✓ 参数约束方法、梯度约束方法、数据约束方法

❑ 基于结构的方法 (architecture-based)

✓ 参数隔离方法、模型拓展方法




参数隔离方法

□ 方法核心

固定模型容量，为每个任务分配不同的模型参数

□ 代表模型

- PackNet (CVPR 2018)
- Piggyback (ECCV 2018)
- MARK (NeurIPS 2021)



[21] Packnet: Adding multiple tasks to a single network by iterative pruning. CVPR 2018.

[22] Piggyback: Adapting a single network to multiple tasks by learning to mask weights. ECCV 2018.

[23] Optimizing reusable knowledge for continual learning via metalearning. NeurIPS 2021.


PackNet (CVPR 2018)

□ 动机

网络参数对于特定任务存在冗余现象。借助网络剪枝技术，利用大型深度网络中的冗余来释放参数，用于学习新任务

□ 核心方法

1. 在当前任务上训练之后，模型会对权重参数进行排序，并剪掉重要性较小的那些权重，最后对剪枝后的网络做少轮次的再训练以保证在当前任务上的性能
2. 后续任务的训练允许利用之前学到的参数，但不能做任何修改，只能修改被剪掉的子网络的权重




测试阶段：模型针对不同任务使用对应的掩码来激活各自的权重参数，完成推理任务

PackNet (CVPR 2018)

□ 问题：剪枝时如何衡量参数的重要性

本文通过参数的范数大小来衡量参数的重要性，每次剪枝选择最小的50%或75%的参数置0




橙色为Task 2的参数，每次剪枝
只会对当前任务的参数进行剪枝！

PackNet (CVPR 2018)

□ 问题：剪枝时如何衡量参数的重要性

本文通过参数的范数大小来衡量参数的重要性，每次剪枝选择最小的50%或75%的参数置0

- ✓ 任务 i 的参数可以被 i 之后的任务使用，但不可更改，因此需要为每个参数保存掩码
- ✓ 每个参数的掩码占 $\log_2 N$ bit (VGG-16模型537MB, 任务数量 $N = 4$ 时, 掩码所占内存大小为17 ~ 34MB)



橙色为Task 2的参数，每次剪枝只会对当前任务的参数进行剪枝！

此方法必须在任务增量场景下使用！

(测试时，只有知道测试样本的任务编号，才可以激活对应模型参数)


模型拓展方法

□ 方法核心

没有限定模型的大小，考虑为**新任务开辟新的网络子结构**，并且在学习新任务的时候固定已经学好的网络部分

□ 代表模型

- Expert Gate (CVPR 2017)
- CPG (NeurIPS 2019)
- IRU (ECCV 2022)
- DNE (CVPR 2023)
- BEEF (ICLR 2023)



[24] Expert gate: Lifelong learning with a network of experts. CVPR 2017.

[25] Compacting, picking and growing for unforgetting continual learning. NeurIPS 2019.

[26] Incremental task learning with incremental rank updates. ECCV 2022.


[27] Dense Network Expansion for Class Incremental Learning. CVPR 2023.

[28] BEEF: Bi-Compatible Class-Incremental Learning via Energy-Based Expansion and Fusion. ICLR 2023

CPG: Compacting, Picking and Growing

□ 动机

- ✓ Compacting: 新增任务时, 固定对旧任务重要的参数, 释放不重要的参数来学习新任务 (得到一个紧凑的模型)
- ✓ Picking: 用可区分的掩码, 选择关键的、部分的旧任务权重用于辅助新任务学习
- ✓ Growing: 先用释放的权重学习新任务, 如果性能不达标, 扩展网络, 将扩展参数和释放参数一起来学习新任务



CPG: Compacting, Picking and Growing

□ 算法流程

Algorithm 1: Compacting, Picking and Growing Continual Learning

Input: given task 1 and an original model trained on task 1.

Set an accuracy goal for task 1;

Alternatively remove small weights and re-train the remaining weights for task 1 via gradual pruning [51], whenever the accuracy goal is still hold;

Let the model weights preserved for task 1 be $\mathbf{W}_1^P$ (referred to as task-1 weights), and those that are removed by the iterative pruning be $\mathbf{W}_1^E$ (referred to as the released weights);

for task $k = 2 \cdots K$ (let the released weights of task k be $\mathbf{W}_k^E$) **do**

Set an accuracy goal for task k ;

Apply a mask $\mathbf{M}$ to the weights $\mathbf{W}_{1:k-1}^P$; train both $\mathbf{M}$ and $\mathbf{W}_{k-1}^E$ for task k , with $\mathbf{W}_{1:k-1}^P$ fixed;


If the accuracy goal is not achieved, expand the number of filters (weights) in the model, reset $\mathbf{W}_{k-1}^E$ and go to previous step;

Gradually prune $\mathbf{W}_{k-1}^E$ to obtain $\mathbf{W}_k^E$ (with $\mathbf{W}_{1:k-1}^P$ fixed) for task k , until meeting the accuracy goal;

$\mathbf{W}_k^P = \mathbf{W}_{k-1}^E \setminus \mathbf{W}_k^E$ and $\mathbf{W}_{1:k}^P = \mathbf{W}_{1:k-1}^P \cup \mathbf{W}_k^P$;

end

1. 对于初始网络不断剪枝、训练直到达到性能要求
2. 释放不重要的参数; $\mathbf{W}_1^P, \mathbf{W}_1^E$ 分别为重要/不重要的参数
3. 固定旧权重, 学习掩码 $\mathbf{M}$ 和权重 $\mathbf{W}_{k-1}^E$, 若无法达到性能要求, 则增加节点重新进行步骤3
4. 对当前任务参数进行剪枝、训练直到达到性能要求



持续学习应用

□ 边端 (Edge)

- ✓ 嵌入式系统、机器人学 (如自动驾驶汽车、机械臂)
- ✓ 隐私、效率、快速适应

□ 云端 (Cloud)

- ✓ AutoML、客户智能系统 (CI system) (如推荐系统)
- ✓ 可扩展性、效率、快速适应、低成本




Figure 1: Data flow in the Auto-Adaptive Machine Learning architecture. See text for details.

持续学习未来展望


基于预训练模型的持续学习

□ 基于提示学习 (prompt-learning) 的方法

- ✓ 使用可学习的提示池来增量学习领域知识

□ 代表工作

- L2P (CVPR 2022)
- DualPrompt (ECCV 2022)
- CODA-Prompt (CVPR 2023)



[29] Learning to Prompt for Continual Learning. CVPR 2022

[30] DualPrompt: Complementary Prompting for Rehearsal-free Continual Learning. ECCV 2022

[31] CODA-Prompt: COntinual Decomposed Attention-based Prompting for Rehearsal-Free Continual Learning. CVPR 2023


基于预训练模型的持续学习

□ 基于模型混合的方法

- ✓ 增量阶段学习任务特定的知识模块，然后合并

□ 代表工作

- ESN (AAAI 2023)
- LAE (ICCV 2023)
- EASE (CVPR 2024)



[32] Isolation and Impartial Aggregation: A Paradigm of Incremental Learning without Interference. AAAI 2023

[33] A Unified Continual Learning Framework with General Parameter-Efficient Tuning. ICCV 2023

[34] Expandable Subspace Ensemble for Pre-Trained Model-Based Class-Incremental Learning. CVPR 2024

理论研究

- 目前已有持续学习工作主要是朝着**如何防止模型遗忘**这一目标而努力，遗忘可以认为是模型在学习新知识的过程中参数的更新破坏了原本被编码在参数中的旧知识

理论研究和支撑仍然不足！

- ✓ 如何学到一组能够同时兼容新旧知识的模型参数的理论支撑？
- ✓ 基于回放的方法中，如何减轻训练数据中的类别不平衡问题？
- ✓ 基于约束的方法中，如何快速求解带约束的优化问题？

.....

新的问题设定

- 现有工作的问题设定主要集中在任务数据量充足、监督信息完备、任务编号信息可知等完美假设的场景

□ 更贴近实际场景设置的方向

- ✓ 小样本类别增量学习 (few-shot class-incremental learning)
- ✓ 无监督持续学习 (unsupervised continual learning)
- ✓ 在线持续学习 (online continual learning)
- ✓ 通用持续学习 (general/task-free continual learning)

.....


新的应用场景

□ 除了图像分类.....

- ✓ 增量目标检测 (incremental object detection)
- ✓ 终生生成对抗网络 (lifelong GAN)
- ✓ 持续语义分割 (continual semantic segmentation)
- ✓ 持续动作识别 (continual action recognition)
- ✓ 持续文本分类 (continual learning on text classification)
- ✓ 终生行人重识别 (lifelong person Re-Identification)
- ✓ 单颗粒冷冻电子显微术中的粒子筛选 (particle picking) ,
辅助完成生物大分子的原子结构测定 (Nature communications 2022)

大模型时代的研究

□ 大模型的启示



定期用新数据更新LLM可能会导致灾难性的遗忘问题

如何采用高效和有效的方法将特定知识“持续注入”LLM依然是个悬而未决的问题

谢谢!

联系方式: liwenbin@nju.edu.cn

更多信息: <https://cs.nju.edu.cn/liwenbin>